

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО»
КАФЕДРА ІНФОРМАТИКИ ТА ПРОГРАМНОЇ ІНЖЕНЕРІЇ

КУРСОВА РОБОТА

з дисципліни «Аналіз даних в інформаційних системах»

на тему: «Аналіз комерційного та нагородного успіху фільмів»

Студента 2 курсу ІП-33 групи

Спеціальності: 121

«Інженерія програмного забезпечення»

Соколова Олександра Вячеславовича

«ПРИЙНЯВ» з оцінкою

доц. Ліхоузова Т.А. / доц. Олійник Ю.О.

Підпис

Дата

Київ - 2025 рік

Національний технічний університет України “КПІ ім. Ігоря Сікорського”

Кафедра інформатики та програмної інженерії

Дисципліна Аналіз даних в інформаційно-управляючих системах

Спеціальність 121 "Інженерія програмного забезпечення"

Курс 2 Група ІІІ-33

Семестр 4

ЗАВДАННЯ

на курсову роботу студента

Соколова Олександра Вячеславовича

1.Тема роботи Аналіз комерційного та нагородного успіху фільмів

2.Строк здачі студентом закінченої роботи 04.06.2025

3. Вхідні дані до роботи методичні вказівки до курсової роботи, обрані дані з сайту

<https://www.kaggle.com/datasets/danielgrijalvas/movies>

<https://www.kaggle.com/datasets/unanimad/the-oscar-award>

<https://www.kaggle.com/datasets/parthdande/movies-box-office-collection-data-2000-2024>

<https://www.kaggle.com/datasets/alessandrolobello/the-ultimate-film-statistics-dataset-for-ml>

4.Зміст розрахунково-пояснювальної записки (перелік питань, які підлягають розробці)

1.Постановка задачі

2.Аналіз предметної області

3.Розробка сховища даних

4.Інтелектуальний аналіз даних

5.Перелік графічного матеріалу (з точним зазначенням обов'язкових креслень)

6.Дата видачі завдання 16.04.2025

КАЛЕНДАРНИЙ ПЛАН

№ п/п	Назва етапів курсової роботи	Термін виконання етапів роботи	Підписи керівника, студента
1.	Отримання теми курсової роботи	11.03.2025	
2.	Визначення зовнішніх джерел даних		
3.	Пошук та вивчення літератури з питань курсової роботи		
4.	Розробка моделі сховища даних		
4.	Розробка ETL процесів		
5.	Обґрунтування методів інтелектуального аналізу даних		
6.	Застосування та порівняння ефективності методів інтелектуального аналізу даних		
7.	Підготовка пояснювальної записки		
8.	Здача курсової роботи на перевірку		
9.	Захист курсової роботи	05.06.2025	

Студент

(підпис)

Соколов О. В.

(прізвище, ім'я, по батькові)

Керівник

(підпис)

доц. Ліхоузова Т.А

(прізвище, ім'я, по батькові)

Керівник

(підпис)

доц. Олійник Ю.О.

(прізвище, ім'я, по батькові)

АНОТАЦІЯ

Пояснювальна записка до курсової роботи: 68 сторінок, 34 рисунки, 4 таблиці, 8 посилань.

Об'єкт дослідження: датасети з інформацією про фільми, касові збори та нагороди «Оскар».

Предмет дослідження: моделі та методи аналізу та прогнозування.

Мета роботи: аналіз та прогнозування комерційного та нагородного успіху фільмів.

Задачі: проектування та реалізація сховища даних та ETL процесів, а також реалізація програмного забезпечення для отримання даних зі сховища та їх подальшого аналізу та моделювання.

Дана курсова робота включає в себе: опис проектування, створення та заповнення сховища даних за даною задачею за допомогою фізичної моделі бази даних; опис створення програмного забезпечення для інтелектуального аналізу даних, їх графічного відображення за допомогою різних моделей; оцінку якості та порівняльний аналіз побудованих моделей.

Результати роботи можуть бути корисними для кіностудій.

СХОВИЩЕ ДАНИХ, МОДЕЛЬ ПРОГНОЗУВАННЯ, ІНТЕЛЕКТУАЛЬНИЙ АНАЛІЗ ДАНИХ, ФІЗИЧНА МОДЕЛЬ БАЗИ ДАНИХ, ELT ПРОЦЕСИ, ЛІНІЙНА РЕГРЕСІЯ, RANDOM FOREST CLASIFIER, XGBOOST.

ЗМІСТ

ВСТУП	5
1.ПОСТАНОВКА ЗАДАЧІ	7
2.АНАЛІЗ ПРЕДМЕТНОЇ ОБЛАСТІ	9
3.РОЗРОБКА СХОВИЩА ДАНИХ	11
3.1.РОЗРОБКА МОДЕЛІ СХОВИЩА ДАНИХ.....	11
3.2.РОЗРОБКА ETL ПРОЦЕСІВ	19
3.3.ЗАВАНТАЖЕННЯ ДАНИХ ЗА ДОПОМОГОЮ ETL ПРОЦЕСІВ....	20
4.ІНТЕЛЕКТУАЛЬНИЙ АНАЛІЗ ДАНИХ	37
4.1.ОБҐРУНТУВАННЯ ВИБОРУ МЕТОДІВ ІНТЕЛЕКТУАЛЬНОГО АНАЛІЗУ ДАНИХ	37
4.2. МАТЕМАТИЧНА МОДЕЛЬ ПРОГНОЗУВАННЯ ЧАСОВИХ ПРОМІЖКІВ	38
4.3.ПРАКТИЧНЕ ЗАСТОСУВАННЯ МОДЕЛЕЙ ПРОГНОЗУВАННЯ ЧАСОВИХ ПРОМІЖКІВ	40
4.4.ПОРІВНЯННЯ ЕФЕКТИВНОСТІ МЕТОДІВ ІНТЕЛЕКТУАЛЬНОГО АНАЛІЗУ	56
ВИСНОВКИ	58
ПЕРЕЛІК ПОСИЛАНЬ	60
ДОДАТОК А ТЕКСТИ ПРОГРАМНОГО КОДУ	61

ВСТУП

У сучасному інформаційному суспільстві кінематограф залишається однією з найвпливовіших галузей індустрії розваг, яка поєднує в собі мистецтво, комерцію та технології. Щороку випускаються сотні фільмів, що змагаються не лише за прихильність глядачів, а й за престижні нагороди, прибутки у прокаті та позитивні відгуки критиків. Проте не всі стрічки, що отримують високі оцінки, досягають фінансового успіху, і навпаки – деякі комерційно успішні фільми не здобувають визнання серед експертів або журі кінопремій. У зв'язку з цим виникає актуальна задача – проаналізувати чинники, що впливають на успіх фільму в різних вимірах: комерційному та нагородному.

У рамках даної курсової роботи проведено аналіз фільмів із застосуванням методів інтелектуального аналізу даних. Для цього було сформовано та оброблено вибірку з релевантними характеристиками стрічок, такими як бюджет, касові збори, жанр, рік випуску, рейтинг, наявність нагород тощо.

У процесі реалізації було побудовано модель сховища даних, що базується на фізичній структурі бази даних, розробленій за допомогою SQL-запитів. Застосовано процеси ETL для завантаження та попередньої обробки інформації. Основний аналіз проводився за допомогою алгоритмів машинного навчання, реалізованих на мові програмування Python 3 з використанням бібліотек Pandas, scikit-learn, Matplotlib та інших.

У якості системи керування базами даних використано PostgreSQL. Метою роботи є виявлення закономірностей та побудова моделей, що дозволяють оцінити ймовірність комерційного чи нагородного успіху фільму на основі його характеристик.

1. ПОСТАНОВКА ЗАДАЧІ

Виконання даної курсової роботи передбачає реалізацію повного циклу дослідження на тему аналізу комерційного та нагородного успіху фільмів на основі їхніх характеристик. Основна мета полягає в вивченні предметної області – особливостей кіноіндустрії, факторів, що впливають на прибутковість фільмів (бюджет, жанр, рейтинг, тривалість) та критеріїв нагородного успіху, зокрема участі та перемог у премії «Оскар».

На першому етапі буде здійснено попередню обробку даних: завантаження, очищення та об'єднання даних із кількох джерел. Підготовлені дані включатимуть такі параметри, як назва фільму, бюджет, касові збори, жанр, рейтинг, тривалість, участь у церемоніях нагородження тощо. На основі цих даних буде проведено первинний статистичний аналіз для виявлення загальних закономірностей, розподілу значень, кореляційних зв'язків та потенційних факторів впливу на комерційний і нагородний успіх.

Основна задача полягає в проведенні детального аналізу даних для оцінки впливу різних характеристик фільмів на їхню успішність у двох напрямках: комерційна успішність (високі касові збори) та нагородна успішність (наявність номінацій або нагород). Аналіз включатиме візуалізацію розподілів, кореляційний аналіз, оцінку важливості ознак та порівняння результатів для виявлення ключових факторів успіху.

Для реалізації проєкту буде використано мову програмування Python із бібліотеками Pandas, Matplotlib, Seaborn, а також сховище даних на базі PostgreSQL. Створена структура даних забезпечує гнучкість для масштабування дослідження та проведення детального аналізу залежно від поставлених цілей.

2. АНАЛІЗ ПРЕДМЕТНОЇ ОБЛАСТІ

Кінематограф – одна з наймасштабніших індустрій сучасного світу, яка поєднує мистецтво, технології та великий бізнес. Щороку на екрани виходять сотні фільмів, кожен з яких претендує на комерційний успіх у прокаті та визнання з боку критиків і професійних кіноакадемій. Проте досягнення високих касових зборів або перемога в престижних кінопреміях, таких як «Оскар», залежать від багатьох взаємопов'язаних факторів: бюджету, жанру, акторського складу, режисера, країни виробництва, маркетингу, відгуків аудиторії тощо.

Аналіз таких факторів із застосуванням сучасних інструментів обробки та аналізу даних дозволяє виявити приховані закономірності, які не є очевидними навіть для досвідчених продюсерів або критиків. З розвитком технологій штучного інтелекту, машинного навчання та аналітики з'явилась можливість будувати точні моделі, які дозволяють оцінити або передбачити ймовірність комерційного й нагородного успіху фільму ще до його виходу.

У межах цього дослідження буде проаналізовано структуровані дані, що включають інформацію про характеристики фільмів, їхні бюджети, касові збори, рейтинг IMDb, участь у церемоніях нагородження, тощо. Дані було зібрано з декількох відкритих джерел (Kaggle, IMDb, BoxOffice) та об'єднано у багатовимірне сховище даних. Це сховище дозволяє ефективно формувати навчальні вибірки для подальшого моделювання.

Курсова робота є актуальною для представників кіноіндустрії, аналітиків, інвесторів та дослідників культурних процесів. Побудовані моделі можуть бути використані для ухвалення стратегічних рішень у сфері виробництва та просування фільмів, прогнозування прибутковості, а також виявлення типових ознак стрічок, що отримують нагороди.

У програмному забезпеченні буде реалізовано наступну функціональність, що включає в себе:

- проектування сховища даних;
- завантаження та обробку даних;

- створення ETL процесів для завантаження і оновлення даних;
- обробку та підготовку даних до моделювання;
- аналіз факторів впливу;
- використання декількох моделей;
- графічне відображення отриманих результатів та їх аналіз.

3. РОЗРОБКА СХОВИЩА ДАНИХ

3.1 Розробка моделі сховища даних

Для виконання курсової роботи було обрано декілька наборів даних з сайту <https://www.kaggle.com/>, які пов'язані з індустрією кіно-фільмів.

Файл movies.csv містить інформацію про 6820 фільмів випущених в 1986-2016 роках, 220 фільмів на кожен рік. Джерело: <https://www.kaggle.com/danielgrijalvas/movies>.

Таблиця 3.1 – Структура movies.csv

Назва поля	Призначення
name	Name of the movie
budget	The budget of a movie
company	The production company
country	Country of origin
director	The director
genre	Main genre of the movie.
gross	Revenue of the movie
rating	Rating of the movie (R, PG, etc.)
released	Release date (YYYY-MM-DD)
runtime	Duration of the movie
score	Imdb user rating
votes	Number of user votes
star	Main actor/actress
writer	Writer of the movie
year	Year of release

Файл the_oscar_award.csv містить інформацію про результати конкурсу «Оскар» з 1927 по 2025 роки. Джерело: <https://www.kaggle.com/datasets/unanimad/the-oscar-award>.

Таблиця 3.2 – Структура the_oscar_award.csv

Назва поля	Призначення
year_film	Film screened at
year_ceremony	Ceremony happened at
ceremony	Number of ceremony
category	Name of the category (as per official nomination)
canon_category	Name of the category, consistent across years
name	Slash separated names of the nominees
film	Film's title
winner	True if winner

Файли “2000-2009 Movies Box Office Collection.csv”, “2010-2024 Movies Box Office Collection.csv” і “2024 Movies Box Office Collection.csv” містять інформацію про касові збори фільмів з 2000 по 2024 роки відповідно. Джерело: <https://www.kaggle.com/datasets/parthdande/movies-box-office-collection-data-2000-2024>.

Таблиця 3.3 – Структура файлів “Movies Box Office Collection”

Назва поля	Призначення
Rank	Rank of a film
Release Group	Name of a film
Worldwide	Worldwide revenue
Domestic	The total earnings (in USD) from the domestic market (e.g., United States)
Domestic_percent	The percentage of the movie's total revenue that was earned domestically.
Foreign	The total earnings (in USD) from international markets (outside the domestic market)
Foreign_percent	The percentage of the movie's total revenue that was earned from foreign markets.
year	The release year of the movie.

Файл «movie_statistic_dataset.csv» містить загальну інформацію про фільм, режисера, бюджети. Джерело: <https://www.kaggle.com/datasets/alessandrolobello/the-ultimate-film-statistics-dataset-for-ml>.

Таблиця 3.4 – Структура файлу “movie_statistic_dataset.csv”

Назва поля	Призначення
Movie_title	Movie name
Production_date	Date of production
Genres	Genres
Runtime_minutes	Runtime in minutes
Director_name (primaryName)	Name of the director
Director_professions (primaryProfession)	Director professions
Director_birthYear	Director year of birth
Director_deathYear	Director year of death
Movie_averageRating	Average rating
Movie_numberOfVotes	Number of votes
Approval_Index	Is a normalized indicator (on scale 0-10) calculated by multiplying the logarithm of the number of
Production_budget	Production budget in \$
Domestic_gross	Domestic gross in \$
Worldwide_gross	Worldwide gross in \$

3.2 Підготовка даних

Для зручної подальшої роботи з даними, було створено нові csv файли на основі обраних наборів даних. Зміни, які були зроблені:

1. Box Office:
 - a. Видалення колонки "Rank".
 - b. Очищення колонок Worldwide, Domestic, Foreign: видалення ком, перетворення значень на числа.
 - c. Очищення колонок Domestic_percent та Foreign_percent: видалення знаків %, заміна <0.1 на 0, перетворення значень на десяткові числа (ділення на 100).
 - d. Перетворення значення року (year) в ціле число.
 - e. Перейменування колонок для узгодження з базою даних.
2. Movies:
 - a. Очищення колонок score та votes (перетворення на числові значення, заміна помилок на NaN).
 - b. Очищення колонок budget та gross (перетворення на числові значення).
 - c. Очищення колонки runtime (перетворення на числове значення).
 - d. Обробка дат випуску (вилучення формату дати і перетворення в datetime).
 - e. Видалення рядків без дат випуску.
 - f. Перетворення року на ціле число.
3. Oscar Awards:
 - a. Видалення рядків з відсутніми значеннями.
 - b. Перетворення колонок year_film, year_ceremony та ceremony в цілі числа.
 - c. Перетворення колонки winner в булевий тип.
4. Movie Budget:
 - a. Перейменування колонок для узгодження з базою даних.

- b. Очищення колонок `runtime_minutes`, `movie_average_rating`, `movie_number_of_votes`, `approval_index`, `production_budget`, `domestic_gross`, `worldwide_gross` (перетворення на числові значення, заміна помилок на NaN).
- c. Очищення дати виробництва (`production_date`), перетворення на `datetime`.
- d. Очищення колонок `director_birth_year` та `director_death_year`, заміна недійсних значень на NaN.
- e. Перетворення колонок `director_birth_year` та `director_death_year` на цілі числа.
- f. Форматування колонок `director_professions` та `genres` у відповідний формат для бази даних (масиви).
- g. Заміна недійсних значень на NaN.

Код створення оновлених CSV файлів на Python:

```
import pandas as pd
import os

os.makedirs("da_lab1/clean_data", exist_ok=True)

def clean_box_office_data(file_path, output_path):
    """Clean specific columns in the box office dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df = df.drop(columns=["Rank"])

    df["Worldwide"] = df["Worldwide"].replace({",": ""},
regex=True).astype(float)
    df["Domestic"] = df["Domestic"].replace({",": ""},
regex=True).astype(float)
    df["Foreign"] = df["Foreign"].replace({",": ""},
regex=True).astype(float)

    df["Domestic_percent"] = (
        df["Domestic_percent"]
        .replace({",": ""}, "%": "", "<0.1": "0"}, regex=True)
        .astype(float)
        / 100
    )
    df["Foreign_percent"] = (
        df["Foreign_percent"]
        .replace({",": ""}, "%": "", "<0.1": "0"}, regex=True)
        .astype(float)
        / 100
    )

    df["year"] = df["year"].astype(int)

    df = df.rename(
        columns={
            "Release Group": "release_group",
            "Worldwide": "worldwide",
            "Domestic": "domestic",
            "Domestic_percent": "domestic_percent",
            "Foreign": "foreign",
            "Foreign_percent": "foreign_percent",
```



```

        "year": "year",
    }
)

df.to_csv(output_path, index=False)
print(f"✅ Cleaned data saved to {output_path}")

def clean_movie_data(file_path, output_path):
    """Clean specific columns in the movie dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df["score"] = pd.to_numeric(df["score"], errors="coerce")

    df["votes"] = (
        df["votes"]
        .apply(lambda x: int(float(x)) if pd.notnull(x) else None)
        .astype(pd.Int64Dtype())
    )

    df["budget"] = pd.to_numeric(df["budget"], errors="coerce")
    df["gross"] = pd.to_numeric(df["gross"], errors="coerce")

    df["runtime"] = pd.to_numeric(df["runtime"], errors="coerce")

    df["released"] = df["released"].str.extract(r"([a-zA-Z]+\s\d{1,2},\s\d{4})")[0]
    df["released"] = pd.to_datetime(df["released"], errors="coerce")

    df = df.dropna(subset=["released"])

    df["year"] = df["year"].astype(int)

    df.to_csv(output_path, index=False)
    print(f"✅ Cleaned data saved to {output_path}")

def clean_oscar_award_data(file_path, output_path):
    """Clean specific columns in the oscar award dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df = df.dropna()

```

```

df["year_film"] = df["year_film"].astype(int)
df["year_ceremony"] = df["year_ceremony"].astype(int)
df["ceremony"] = df["ceremony"].astype(int)

df["winner"] = df["winner"].astype(bool)

df.to_csv(output_path, index=False)
print(f"✅ Cleaned data saved to {output_path}")

def clean_movie_budget_data(file_path, output_path):
    """Clean specific columns in the movie budget dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df = df.rename(
        columns={
            "movie_title": "movie_title",
            "production_date": "production_date",
            "genres": "genres",
            "runtime_minutes": "runtime_minutes",
            "director_name": "director_name",
            "director_professions": "director_professions",
            "director_birthYear": "director_birth_year",
            "director_deathYear": "director_death_year",
            "movie_averageRating": "movie_average_rating",
            "movie_numOfVotes": "movie_number_of_votes",
            "approval_Index": "approval_index",
            "Production budget $": "production_budget",
            "Domestic gross $": "domestic_gross",
            "Worldwide gross $": "worldwide_gross",
        }
    )

    df["runtime_minutes"] = pd.to_numeric(df["runtime_minutes"],
errors="coerce")
    df["movie_average_rating"] = pd.to_numeric(
        df["movie_average_rating"], errors="coerce"
    )
    df["movie_number_of_votes"] = pd.to_numeric(
        df["movie_number_of_votes"], errors="coerce"
    ).astype("Int64")
    df["approval_index"] = pd.to_numeric(df["approval_index"],
errors="coerce")
    df["production_budget"] = pd.to_numeric(df["production_budget"],
errors="coerce")

```

```

df["domestic_gross"] = pd.to_numeric(df["domestic_gross"],
errors="coerce")
df["worldwide_gross"] = pd.to_numeric(df["worldwide_gross"],
errors="coerce")

df["production_date"] = pd.to_datetime(df["production_date"],
errors="coerce")

df["director_birth_year"] = df["director_birth_year"].replace(
    ["-", "\\N", "alive"], pd.NA
)
df["director_death_year"] = df["director_death_year"].replace(
    ["-", "\\N", "alive"], pd.NA
)

df["director_birth_year"] =
df["director_birth_year"].astype(pd.Int64Dtype())
df["director_death_year"] =
df["director_death_year"].astype(pd.Int64Dtype())

df["director_professions"] = df["director_professions"].apply(
    lambda x: "{" + x.replace(",", " ") + "}" if pd.notnull(x) else
None
)

df["genres"] = df["genres"].apply(
    lambda x: "{" + ",".join(x.split(",")) + "}" if pd.notnull(x)
else None
)

df.replace({"-": pd.NA, "{-}": pd.NA}, inplace=True)

df.to_csv(output_path, index=False)
print(f"✅ Cleaned data saved to {output_path}")

clean_box_office_data(
    "da_lab1/data/box_office.csv", "da_lab1/clean_data/box_office.csv"
)

clean_movie_data("da_lab1/data/movies.csv",
"da_lab1/clean_data/movies.csv")

clean_oscar_award_data(
    "da_lab1/data/oscar_award.csv", "da_lab1/clean_data/oscar_award.csv"
)

```

```
clean_movie_budget_data(  
    "da_lab1/data/movie_budget.csv",  
    "da_lab1/clean_data/movie_budget.csv"  
)
```

```
print("✅ Data cleaning complete! Cleaned files are in 'clean_data/'")
```


3.3 Stage зона

Stage-зона (проміжна зона зберігання) – це ключовий компонент архітектури сховища даних, який використовується для первинного завантаження, зберігання та попередньої обробки сирих даних перед їх трансформацією і перенесенням у основну аналітичну модель. Її основна функція – забезпечення буферної області, де дані можуть бути очищені, уніфіковані та нормалізовані без впливу на цілісність основного сховища.

У процесі реалізації курсової роботи stage-зона була створена як окрема схема staging у базі даних PostgreSQL. У цій схемі розміщено кілька таблиць, структура яких відповідає форматам вихідних CSV-файлів, отриманих з очищених даних з відкритих джерел (Kaggle). Дані були завантажені у stage-зону безпосередньо через SQL-команди.

Код створення stage зони:

```
CREATE SCHEMA IF NOT EXISTS staging;
```

```
CREATE TABLE staging.box_office
```

```
(
    id                SERIAL PRIMARY KEY,
    release_group     TEXT                NOT NULL,
    worldwide         NUMERIC(15, 2) NOT NULL,
    domestic          NUMERIC(15, 2) NOT NULL,
    domestic_percent  NUMERIC(5, 2)  NOT NULL,
    "foreign"         NUMERIC(15, 2) NOT NULL,
    foreign_percent   NUMERIC(5, 2)  NOT NULL,
    year              INTEGER           NOT NULL
);
```

```
CREATE TABLE staging.movie_budget
```

```
(
    id                SERIAL PRIMARY KEY,
    movie_title       TEXT                NOT NULL,
    production_date   DATE                NOT NULL,
    genres            TEXT                NOT NULL,
    runtime_minutes   NUMERIC(5, 1) NOT NULL,
    director_name     TEXT                NULL,
    director_professions TEXT[],
    director_birth_year INTEGER           NULL,
    director_death_year INTEGER           NULL,
    movie_average_rating NUMERIC(3, 1) NOT NULL,
    movie_number_of_votes BIGINT          NOT NULL,
    approval_index     NUMERIC(5, 2) NOT NULL,
    production_budget  NUMERIC(15, 2) NOT NULL,
    domestic_gross     NUMERIC(15, 2) NOT NULL,
    worldwide_gross    NUMERIC(15, 2) NOT NULL
);
```

```
CREATE TABLE staging.movies
```

```
(
    id                SERIAL PRIMARY KEY,
    name              TEXT                NOT NULL,
    rating            TEXT                NULL,
    genre             TEXT                NOT NULL,
    year              INTEGER           NOT NULL,
    released          DATE                NOT NULL,
    score             NUMERIC(3, 1) NULL,
    votes             BIGINT            NULL,
    director          TEXT                NULL,
```

```

writer    TEXT          NULL,
star      TEXT          NULL,
country   TEXT          NULL,
budget    NUMERIC(15, 2) NULL,
gross     NUMERIC(15, 2) NULL,
company   TEXT          NULL,
runtime   NUMERIC(5, 1)  NULL
);

CREATE TABLE staging.oscar_awards
(
    id          SERIAL PRIMARY KEY,
    year_film   INTEGER NOT NULL,
    year_ceremony INTEGER NOT NULL,
    ceremony    INTEGER NOT NULL,
    category    TEXT     NOT NULL,
    canon_category TEXT   NOT NULL,
    name        TEXT     NOT NULL,
    film        TEXT     NOT NULL,
    winner      BOOLEAN NOT NULL
);

```

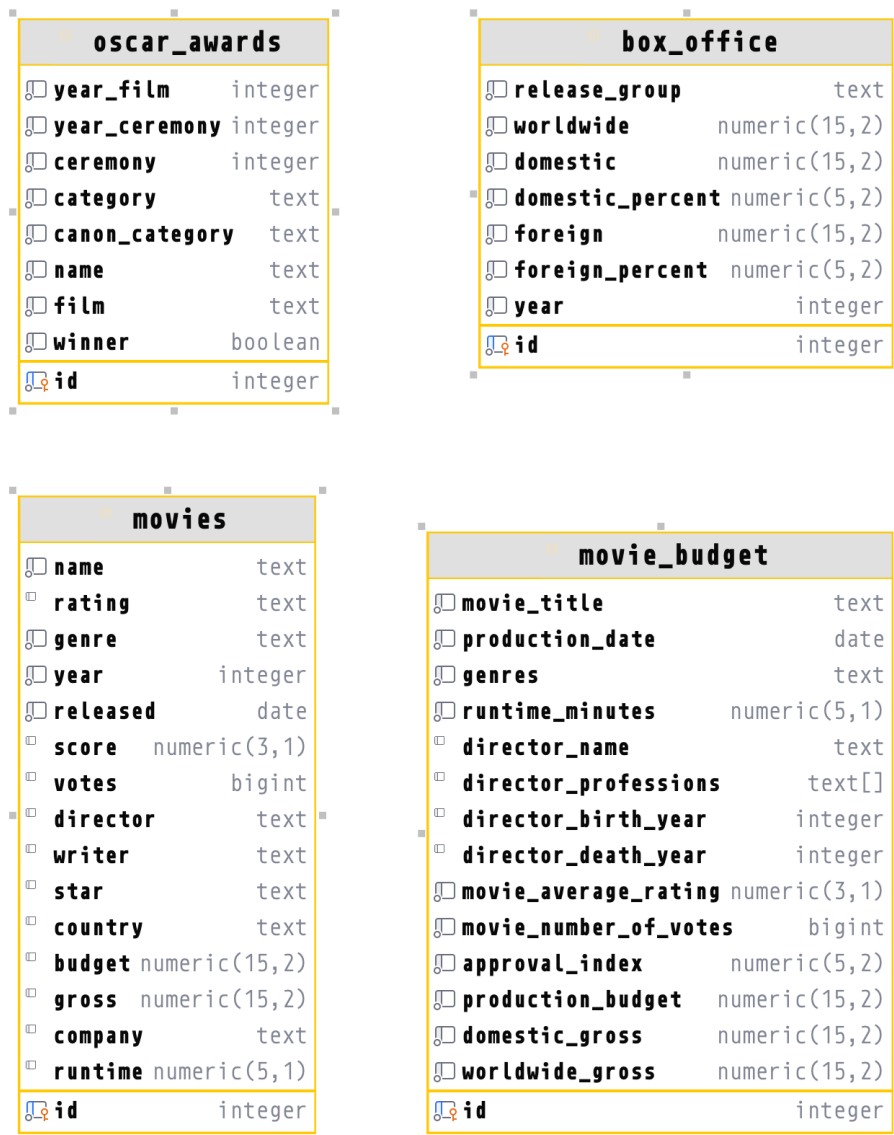



Рис. 3.3 – Діаграма сутностей stage зони

Таблиця box_office містить:

1. id – це автоматично збільшуване ціле число (SERIAL), яке використовується як первинний ключ для ідентифікації кожного запису.
2. release_group – текстове поле (TEXT), яке зберігає назву групи фільмів або франшизи, до якої належить фільм.
3. worldwide – числове поле (NUMERIC(15, 2)), яке містить загальні світові збори фільму в доларах США.
4. domestic – числове поле (NUMERIC(15, 2)), яке містить суму зборів фільму в домашньому (вітчизняному) ринку (наприклад, США).
5. domestic_percent – числове поле (NUMERIC(5, 2)), яке відображає відсоток зборів фільму, отриманих на вітчизняному ринку.

6. `foreign` – числове поле (`NUMERIC(15, 2)`), яке містить збори фільму на міжнародному ринку.
7. `foreign_percent` – числове поле (`NUMERIC(5, 2)`), яке відображає відсоток зборів фільму, отриманих на міжнародному ринку.
8. `year` – ціле число (`INTEGER`), яке містить рік випуску фільму.

Таблиця `movie_budget` містить:

1. `id` – це автоматично збільшуване ціле число (`SERIAL`), яке використовується як первинний ключ для ідентифікації кожного запису.
2. `movie_title` – текстове поле (`TEXT`), яке містить назву фільму.
3. `production_date` – дата (`DATE`), яка вказує на дату виробництва фільму.
4. `genres` – текстове поле (`TEXT`), яке містить жанри фільму, розділені комами.
5. `runtime_minutes` – числове поле (`NUMERIC(5, 1)`), яке вказує тривалість фільму в хвилинах.
6. `director_name` – текстове поле (`TEXT`), яке зберігає ім'я режисера фільму.
7. `director_professions` – масив текстових значень (`TEXT[]`), який містить професії режисера (наприклад, режисер, продюсер тощо).
8. `director_birth_year` – ціле число (`INTEGER`), яке вказує рік народження режисера.
9. `director_death_year` – ціле число (`INTEGER`), яке вказує рік смерті режисера (якщо застосовно).
10. `movie_average_rating` – числове поле (`NUMERIC(3, 1)`), яке містить середній рейтинг фільму.
11. `movie_number_of_votes` – велике ціле число (`BIGINT`), яке містить кількість голосів за фільм.

12. `approval_index` – числове поле (`NUMERIC(5, 2)`), яке є індексом схвалення фільму, розрахованим як логарифм кількості голосів, помножений на середній рейтинг.

13. `production_budget` – числове поле (`NUMERIC(15, 2)`), яке містить бюджет виробництва фільму в доларах.

14. `domestic_gross` – числове поле (`NUMERIC(15, 2)`), яке містить збори фільму на вітчизняному ринку в доларах.

15. `worldwide_gross` – числове поле (`NUMERIC(15, 2)`), яке містить збори фільму на світовому рівні в доларах.

Таблиця `movies` містить:

1. `id` – це автоматично збільшуване ціле число (`SERIAL`), яке використовується як первинний ключ для ідентифікації кожного запису.

2. `name` – текстове поле (`TEXT`), яке містить назву фільму.

3. `rating` – текстове поле (`TEXT`), яке вказує рейтинг фільму (наприклад, R, PG тощо).

4. `genre` – текстове поле (`TEXT`), яке містить основний жанр фільму.

5. `year` – ціле число (`INTEGER`), яке містить рік випуску фільму.

6. `released` – дата (`DATE`), яка вказує на дату виходу фільму.

7. `score` – числове поле (`NUMERIC(3, 1)`), яке вказує оцінку фільму на IMDb.

8. `votes` – велике ціле число (`BIGINT`), яке містить кількість голосів на IMDb.

9. `director` – текстове поле (`TEXT`), яке містить ім'я режисера фільму.

10. `writer` – текстове поле (`TEXT`), яке містить ім'я сценариста фільму.

11. `star` – текстове поле (`TEXT`), яке містить ім'я головного актора чи актриси.

12. `country` – текстове поле (`TEXT`), яке містить країну виробництва фільму.

13. `budget` – числове поле (`NUMERIC(15, 2)`), яке містить бюджет фільму (може бути нульовим, якщо не вказано).
14. `gross` – числове поле (`NUMERIC(15, 2)`), яке містить загальні збори фільму.
15. `company` – текстове поле (`TEXT`), яке містить назву компанії, яка виробила фільм.
16. `runtime` – числове поле (`NUMERIC(5, 1)`), яке містить тривалість фільму в хвилинах.

Таблиця `oscar_awards` містить:

1. `id` – це автоматично збільшуване ціле число (`SERIAL`), яке використовується як первинний ключ для ідентифікації кожного запису.
2. `year_film` – ціле число (`INTEGER`), яке вказує рік, у якому фільм був випущений.
3. `year_ceremony` – ціле число (`INTEGER`), яке вказує рік церемонії вручення Оскарів.
4. `ceremony` – ціле число (`INTEGER`), яке вказує на номер церемонії.
5. `category` – текстове поле (`TEXT`), яке містить назву категорії нагороди.
6. `canon_category` – текстове поле (`TEXT`), яке містить стандартну назву категорії, яка використовується на всіх церемоніях.
7. `name` – текстове поле (`TEXT`), яке містить імена номінантів, розділені слешем.
8. `film` – текстове поле (`TEXT`), яке містить назву фільму, який був номінований.
9. `winner` – булеве значення (`BOOLEAN`), яке вказує, чи виграв фільм в цій категорії.

Код заповнення stage зони:

```
COPY staging.box_office (release_group, worldwide, domestic,  
domestic_percent, "foreign", foreign_percent, year)  
FROM '/private/tmp/box_office.csv' DELIMITER ',' CSV HEADER;  
  
COPY staging.movies (name, rating, genre, year, released, score, votes,  
director, writer, star, country, budget, gross, company, runtime)  
FROM '/private/tmp/movies.csv' DELIMITER ',' CSV HEADER;  
  
COPY staging.oscar_awards(year_film, year_ceremony, ceremony, category,  
canon_category, name, film, winner)  
FROM '/private/tmp/oscar_award.csv' DELIMITER ',' CSV HEADER;  
  
COPY staging.movie_budget (movie_title, production_date, genres,  
runtime_minutes, director_name, director_professions,  
director_birth_year, director_death_year, movie_average_rating,  
movie_number_of_votes, approval_index, production_budget,  
domestic_gross, worldwide_gross)  
FROM '/private/tmp/movie_budget.csv' DELIMITER ',' CSV HEADER;
```

	1	2	3	4	5	6	7	8
id	1	2	3	4	5	6	7	8
release_group	Mission: Impossible II	Gladiator	Cast Away	What Women Want	Dinosaur	How the Grinch Stole Christmas	Meet the Parents	The Perfe
worldwide	546388108.00	460583960.00	429632142.00	374111707.00	349822765.00	345842198.00	330444045.00	32871843
domestic	215409889.00	187705427.00	233632142.00	182811707.00	137748063.00	260745620.00	166244045.00	18261843
domestic_percent	0.39	0.41	0.54	0.49	0.39	0.75	0.50	0.56
foreign	330978219.00	272878533.00	196000000.00	191300000.00	212074702.00	85096578.00	164200000.00	14610000
foreign_percent	0.61	0.59	0.46	0.51	0.61	0.25	0.50	0.44
year	2000	2000	2000	2000	2000	2000	2000	2000

Рис. 3.4 – Таблиця stage зони box_office

movie_budget [data_analysis@docker]

box_office [data_analysis@docker] movie_budget [data_analysis@docker] x

1-500 of 501+ | Tx: Auto | DDL | CSV | Download | Filter | Search

WHERE ORDER BY

	1	2	3	4	5
id	1	2	3	4	5
movie_title	Avatar: The Way of Water	Avengers: Endgame	Pirates of the Caribbean: On Stranger Tides	Avengers: Age of Ultron	Avengers
production_date	2022-12-09	2019-04-23	2011-05-20	2015-04-22	2018-04-
genres	{Action,Adventure,Fantasy}	{Action,Adventure,Drama}	{Action,Adventure,Fantasy}	{Action,Adventure,Sci-Fi}	{Action,
runtime_minutes	192.0	181.0	137.0	141.0	149.0
director_name	James Cameron	<null>	Rob Marshall	Joss Whedon	<null>
director_professions	{writer,producer,director}	<null>	{director,miscellaneous,producer}	{writer,producer,director}	<null>
director_birth_year	1954	<null>	1960	1964	<null>
director_death_year	<null>	<null>	<null>	<null>	<null>
movie_average_rating	7.8	8.4	6.6	7.3	8.4
movie_number_of_votes	277543	1143642	533763	870573	1091968
approval_index	7.06	8.49	6.27	7.21	8.46
production_budget	460000000.00	400000000.00	379000000.00	365000000.00	300000000.00
domestic_gross	667830256.00	858373000.00	241071802.00	459005868.00	67881548
worldwide_gross	2265935552.00	2794731755.00	1045713802.00	1395316979.00	20483597

SUM: Not enough values

Рис. 3.5 – Таблица stage зоны movie_budget

movies [data_analysis@docker]

box_office [data_analysis@docker] movie_budget [data_analysis@docker] movies [data_analysis@docker] x

1-500 of 501+ | Tx: Auto | DDL | CSV | Download | Filter | Search

WHERE ORDER BY

	1	2	3	4	5	6	7
id	80	81	82	83	84	85	86
name	The Shining	The Blue Lagoon	Star Wars: Episode V – The Empire Strikes Back	Airplane!	Caddyshack	Friday the 13th	The E
rating	R	R	PG	PG	R	R	R
genre	Drama	Adventure	Action	Comedy	Comedy	Horror	Actio
year	1980	1980	1980	1980	1980	1980	1980
released	1980-06-13	1980-07-02	1980-06-20	1980-07-02	1980-07-25	1980-05-09	1980-
score	8.4	5.8	8.7	7.7	7.3	6.4	7.9
votes	927000	65000	1200000	221000	108000	123000	18800
director	Stanley Kubrick	Randal Kleiser	Irvin Kershner	Jim Abrahams	Harold Ramis	Sean S. Cunningham	John
writer	Stephen King	Henry De Vere Stacpoole	Leigh Brackett	Jim Abrahams	Brian Doyle-Murray	Victor Miller	Dan /
star	Jack Nicholson	Brooke Shields	Mark Hamill	Robert Hays	Chevy Chase	Betsy Palmer	John
country	United Kingdom	United States	United States	United Stat.	United States	United States	Unite
budget	19000000.00	4500000.00	18000000.00	3500000.00	6000000.00	550000.00	27000
gross	46998772.00	58853106.00	538375067.00	83453539.00	39846344.00	39754601.00	11522
company	Warner Bros.	Columbia Pictures	Lucasfilm	Paramount P.	Orion Pictures	Paramount Pictures	Unive
runtime	146.0	104.0	124.0	88.0	98.0	95.0	133.0

SUM: Not enough values

Рис. 3.6 – Таблица stage зоны movies

	1	2	3	4	5	6
id	1	2	3	4	5	6
year_film	1927	1927	1927	1927	1927	1927
year_ceremony	1928	1928	1928	1928	1928	1928
ceremony	1	1	1	1	1	1
category	ACTOR	ACTOR	ACTOR	ACTOR	ACTRESS	ACTRESS
canon_category	ACTOR IN A LEADING ROLE	ACTOR IN A LEADING ROLE	ACTOR IN A LEADING ROLE	ACTOR IN A LEADING ROLE	ACTRESS IN A LEADING ROLE	ACTRESS IN A LEADING ROLE
name	Richard Barthelmess	Richard Barthelmess	Emil Jannings	Emil Jannings	Louise Dresser	Janet Gaynor
film	The Noose	The Patent Leather Kid	The Last Command	The Way of All Flesh	A Ship Comes In	7th Heaven
winner	false	false	true	true	false	true

Рис. 3.7 – Таблиця stage зони oscar_awards

Дані було успішно завантажено до stage зони.

3.4 Модель основного сховища

Основна (аналітична) зона – це ключова складова сховища даних, призначена для тривалого зберігання, агрегування та аналітичного оброблення очищених, нормалізованих даних. Саме ця частина сховища реалізує багатовимірну модель даних, що дозволяє ефективно виконувати аналітичні запити, будувати зведені таблиці, візуалізації та формувати навчальні вибірки для подальшого інтелектуального аналізу.

У межах курсової роботи основна зона була реалізована як окрема схема main у СУБД PostgreSQL. Модель побудована за принципами схеми "зірка" (star schema), яка включає:

1. фактові таблиці – містять вимірювані значення (збори, рейтинги, нагороди тощо);
2. таблиці вимірів (dimension) – зберігають описові характеристики фільмів, режисерів, акторів, сценаристів, нагород тощо.

Код створення main зони:

```
CREATE SCHEMA IF NOT EXISTS main;
```

```
CREATE TABLE main.dim_movie
(
    movie_id      SERIAL PRIMARY KEY,
    title         TEXT          NOT NULL,
    release_date  DATE          NOT NULL,
    year         INTEGER        NOT NULL,
    genre         TEXT          NOT NULL,
    rating        TEXT          NULL,
    runtime_minutes NUMERIC(5, 1) NULL,
    budget        NUMERIC(15, 2) NULL,
    production_company TEXT      NULL,
    country       TEXT          NULL
);
```

```
CREATE TABLE main.dim_director
(
    director_id SERIAL PRIMARY KEY,
    name        TEXT      NOT NULL,
    birth_year  INTEGER NULL,
    death_year  INTEGER NULL,
    professions TEXT[]   NULL
);
```

```
CREATE TABLE main.dim_oscar_category
(
    category_id SERIAL PRIMARY KEY,
    category    TEXT NOT NULL,
    canon_category TEXT NOT NULL
);
```

```
CREATE TABLE main.dim_star
(
    star_id SERIAL PRIMARY KEY,
    name    TEXT NOT NULL
);
```

```
CREATE TABLE main.dim_writer
(
    writer_id SERIAL PRIMARY KEY,
    name      TEXT NOT NULL
);
```

```
CREATE TABLE main.fact_box_office
```



```

(
    fact_id          SERIAL PRIMARY KEY,
    movie_id         INTEGER REFERENCES main.dim_movie (movie_id),
    worldwide        NUMERIC(15, 2) NOT NULL,
    domestic         NUMERIC(15, 2) NOT NULL,
    domestic_percent NUMERIC(5, 2)  NOT NULL,
    "foreign"        NUMERIC(15, 2) NOT NULL,
    foreign_percent  NUMERIC(5, 2)  NOT NULL,
    year            INTEGER          NOT NULL
);

CREATE TABLE main.fact_movie_performance
(
    fact_id          SERIAL PRIMARY KEY,
    movie_id         INTEGER REFERENCES main.dim_movie (movie_id),
    director_id      INTEGER REFERENCES main.dim_director
(director_id),
    average_rating   NUMERIC(3, 1)  NOT NULL,
    number_of_votes  BIGINT          NOT NULL,
    approval_index   NUMERIC(5, 2)  NOT NULL,
    production_budget NUMERIC(15, 2) NOT NULL,
    domestic_gross   NUMERIC(15, 2) NOT NULL,
    worldwide_gross  NUMERIC(15, 2) NOT NULL
);

CREATE TABLE main.fact_oscar_awards
(
    fact_id          SERIAL PRIMARY KEY,
    movie_id         INTEGER REFERENCES main.dim_movie (movie_id),
    category_id      INTEGER REFERENCES main.dim_oscar_category
(category_id),
    ceremony         INTEGER NOT NULL,
    year_film        INTEGER NOT NULL,
    year_ceremony    INTEGER NOT NULL,
    winner           BOOLEAN NOT NULL
);

CREATE TABLE main.movie_stars
(
    movie_id INTEGER REFERENCES main.dim_movie (movie_id),
    star_id  INTEGER REFERENCES main.dim_star  (star_id),
    PRIMARY KEY (movie_id, star_id)
);

CREATE TABLE main.movie_writers
(

```

```

movie_id INTEGER REFERENCES main.dim_movie (movie_id),
writer_id INTEGER REFERENCES main.dim_writer (writer_id),
PRIMARY KEY (movie_id, writer_id)
);

```




Рис. 3.8 – Діаграма сутностей main зони

Таблиця dim_movie – це таблиця виміру, яка містить основну інформацію про фільми. Вона використовується для зберігання атрибутів фільмів, таких як назва, жанр, рік випуску, бюджет та країна виробництва. Вона дозволяє проводити аналіз фільмів за різними характеристиками, такими як жанр або рік випуску.

Таблиця `dim_director` – це таблиця виміру, яка містить інформацію про режисерів фільмів. Вона дозволяє пов'язувати фільми з їх режисерами та здійснювати аналіз на основі кар'єри та впливу режисера на успіх фільму. Ця таблиця також містить дані про професії режисера.

Таблиця `dim_oscar_category` – це таблиця виміру, яка зберігає категорії нагород Оскара. Вона допомагає класифікувати фільми за номінаціями та дозволяє аналізувати результати Оскарів у різних категоріях.

Таблиця `dim_star` – це таблиця виміру, яка містить інформацію про акторів, що знімалися у фільмах. Вона дозволяє встановлювати зв'язки між фільмами та акторами для аналізу їх впливу на популярність фільмів.

Таблиця `dim_writer` – це таблиця виміру, яка зберігає дані про сценаристів фільмів. Вона дозволяє здійснювати аналіз творчості сценаристів та їхнього впливу на успіх фільмів.

Таблиця `fact_box_office` – це фактова таблиця, яка містить дані про касові збори фільмів. Вона містить інформацію про збори на внутрішньому ринку, міжнародному ринку, а також відсоткове співвідношення цих зборів до загальних доходів фільму. Ця таблиця є основним джерелом для аналізу фінансового успіху фільмів.

Таблиця `fact_movie_performance` – це фактова таблиця, яка зберігає дані про продуктивність фільмів, включаючи середній рейтинг, кількість голосів, індекс схвалення, а також бюджет і збори. Вона дозволяє оцінити успішність фільму з точки зору аудиторії та фінансів.

Таблиця `fact_oscar_awards` – це фактова таблиця, яка містить дані про нагороди Оскара. Вона зберігає інформацію про переможців та номінантів у різних категоріях на кожній церемонії Оскара. Ця таблиця дозволяє аналізувати успіх фільмів у різних номінаціях та церемоніях.

Таблиця `movie_stars` – це таблиця зв'язку, яка відображає зв'язки між фільмами та акторами. Вона дозволяє здійснювати аналіз впливу конкретних акторів на успіх фільмів та взаємодію між фільмами та їх зірками.

Таблиця movie_writers – це таблиця зв'язку, яка зберігає зв'язки між фільмами та сценаристами. Вона дозволяє досліджувати взаємозв'язок між сценаристами та фільмами, які вони написали.

director_id	name	birth_year	death_year	professions
1	Matt Piedmont	<null>	<null>	{writer,director,producer}
2	Craig R. Baxley	<null>	<null>	{stunts,assistant_director,director}
3	Feroz Abbas Khan	<null>	<null>	{director,writer}
4	Jesse V. Johnson	1971	<null>	{stunts,director,writer}
5	John Carpenter	1948	<null>	{soundtrack,writer,composer}
6	Brett Haley	1983	<null>	{director,writer,producer}
7	Walter Salles	1956	<null>	{director,producer,writer}
8	George Hickenlooper	1963	2010	{director,writer,producer}
9	Nigel Cole	1959	<null>	{director,actor,assistant_director}
10	Ashish R. Mohan	<null>	<null>	{assistant_director,actor,casting_director}
11	D.W. Griffith	1875	1948	{director,writer,producer}
12	David Singleton	<null>	<null>	{producer,director,script_department}
13	Nelson Dilipkumar	1984	<null>	{director,writer}
14	Louis C.K.	1967	<null>	{writer,producer,actor}
15	Kasi Lemmons	1961	<null>	{actress,director,producer}
16	Tim Hill	1958	<null>	{writer,producer,director}
17	Mateo Gil	1972	<null>	{writer,director,assistant_director}
18	Dito Montiel	1965	<null>	{director,writer,soundtrack}
19	Denis Villeneuve	1967	<null>	{director,writer,editor}
20	Robert Duvall	1931	<null>	{actor,producer,soundtrack}
21	Roberto Benigni	1952	<null>	{actor,writer,director}
22	Fred Walton	<null>	<null>	{director,writer,actor}
23	Henry Selick	1952	<null>	{director,animation_department,writer}
24	Michael Caton-Jones	1957	<null>	{director,producer,actor}
25	Paul Verhoeven	1938	<null>	{director,producer,writer}
26	Matthew Hastings	1967	<null>	{producer,director,music_department}

Рис 3.9 – Заповнена таблиця main зони “dim_director”

movie_id	title	release_date	year	genre	rating	runtime_minutes	budget	production_company	country	valid_from	valid_to	is_current
1	Henry & June	1990-10-05	1990	Biography	NC-17	136.0	<null>	Universal Pictures	United States	2025-03-14	<null>	true
2	That Was Then... This Is Now	1985-11-08	1985	Crime	R	102.0	<null>	Media Ventures	United States	2025-03-14	<null>	true
3	I Love You Phillip Morris	2011-01-07	2009	Biography	R	98.0	13000000.00	EuropaCorp	France	2025-03-14	<null>	true
4	Sideways	2004-10-22	2004	Comedy	R	127.0	16000000.00	Fox Searchlight Pictures	United States	2025-03-14	<null>	true
5	Moving	1988-03-04	1988	Comedy	R	89.0	<null>	Warner Bros.	United States	2025-03-14	<null>	true
6	The Interview	2014-12-24	2014	Action	R	112.0	44000000.00	Columbia Pictures	United States	2025-03-14	<null>	true

Рис 3.10 – Заповнена таблиця main зони “dim_movie”

category_id	category	canon_category
1	ANIMATED SHORT FILM	SHORT FILM (Animated)
2	MUSIC (Music Score of a Dramatic Picture)	MUSIC (Original Score)
3	CINEMATOGRAPHY (Black-and-White)	CINEMATOGRAPHY (Black-and-White)
4	SPECIAL EFFECTS	VISUAL EFFECTS
5	MAKEUP	MAKEUP AND HAIRSTYLING
6	ART DIRECTION (Color)	ART DIRECTION (Color)
7	SPECIAL ACHIEVEMENT AWARD	SPECIAL ACHIEVEMENT AWARD
8	BEST MOTION PICTURE	BEST PICTURE
9	VISUAL EFFECTS	VISUAL EFFECTS
10	ACTOR IN A SUPPORTING ROLE	ACTOR IN A SUPPORTING ROLE
11	MUSIC (Music Score—substantially original)	MUSIC (Original Score)
12	WRITING (Motion Picture Story)	WRITING (Original Story)
13	ENGINEERING EFFECTS	VISUAL EFFECTS
14	SPECIAL ACHIEVEMENT AWARD (Sound Effects)	SPECIAL ACHIEVEMENT AWARD (Sound Effects)
15	WRITING	WRITING (Adapted Screenplay)
16	SHORT SUBJECT (Two-reel)	SHORT SUBJECT (Two-reel)
17	SPECIAL FOREIGN LANGUAGE FILM AWARD	SPECIAL FOREIGN LANGUAGE FILM AWARD
18	FOREIGN LANGUAGE FILM	INTERNATIONAL FEATURE FILM
19	SHORT FILM (Live Action)	SHORT FILM (Live Action)
20	MUSIC (Score of a Musical Picture—original or adaptation)	MUSIC (Original Song Score or Adaptation Score)
21	UNIQUE AND ARTISTIC PICTURE	UNIQUE AND ARTISTIC PICTURE
22	WRITING (Screenplay Based on Material from Another Medium)	WRITING (Adapted Screenplay)
23	WRITING (Story and Screenplay—based on material not prev...	WRITING (Original Screenplay)
24	PRODUCTION DESIGN	ART DIRECTION
25	SHORT SUBJECT (One-reel)	SHORT SUBJECT (One-reel)
26	SPECIAL VISUAL EFFECTS	VISUAL EFFECTS

Рис 3.11 – Заповнена таблиця main зони “dim_oscар_category”

star_id	name
1	John Standing
2	Bette Davis
3	Scott Glenn
4	John Rhys-Davies
5	Peter Ustinov
6	Michael Reilly Burke
7	Cillian Murphy
8	Christina Applegate
9	Billy Zane
10	Sophia Loren
11	Sergio Castellitto
12	Chloë Sevigny
13	Agata Kulesza
14	Jane Adams
15	Miko Hughes
16	Constance Wu
17	Noémie Merlant
18	Amy Madigan
19	Richard Farnsworth
20	Edward Furlong
21	Melissa Joan Hart
22	Jennifer Jason Leigh
23	Demetrius Shipp Jr.
24	Coral Browne
25	Melanie Martinez
26	Louis Gossett Jr.

Рис 3.12 – Заповнена таблиця main зони “dim_star”

The screenshot shows a database application window with the title 'dim_writer [data_analysis@docker]'. The table 'dim_writer' is displayed with the following data:

writer_id	name
1	Tom O'Connor
2	Marianne Wibberley
3	Barry Michael Cooper
4	H.F. Saint
5	Tom Ropelewski
6	Etan Cohen
7	Richard Matheson
8	Vijay Krishna Acharya
9	J. David Stem
10	Georges Bataille
11	Scott M. Gimple
12	Robert Kurtzman
13	Noel Ashman
14	Seth Margolis
15	David Ambrose
16	Louis Venosta
17	Dan Gordon
18	Josh Goldsmith
19	Sabrina Dhawan
20	Dick Clement
21	Linda Palmer
22	Matthew Sand
23	Doug Taylor
24	Eric Bernt
25	Chris Sanders
26	Dan Hageman

Рис 3.13 – Заповнена таблиця main зони “dim_writer”

The screenshot shows a database application window with the title 'fact_box_office [data_analysis@docker]'. The table 'fact_box_office' is displayed with the following data:

fact_id	movie_id	worldwide	domestic	domestic_percent	foreign	foreign_percent	year
1	1	20768906.00	2037459.00	0.10	18731447.00	0.90	2009
2	2	109706931.00	71503593.00	0.65	38203338.00	0.35	2004
3	3	353133898.00	144001023.00	0.41	209332875.00	0.59	2004
4	4	68072848.00	24633730.00	0.36	43439118.00	0.64	2006
5	5	68349884.00	30113491.00	0.44	38236393.00	0.56	2002
6	6	41627431.00	24850922.00	0.60	16776509.00	0.40	2008
7	7	449220945.00	198542554.00	0.44	250678391.00	0.56	2001
8	8	204313400.00	100018837.00	0.49	104294563.00	0.51	2008
9	9	56722693.00	28848693.00	0.51	27874000.00	0.49	2016
10	10	1140703091.00	377027325.00	0.33	763654686.00	0.67	2003
11	11	94935764.00	66818548.00	0.70	28117216.00	0.30	2002
12	12	176506819.00	66486205.00	0.38	110020614.00	0.62	2012
13	13	25272752.00	23980304.00	0.95	1292448.00	0.05	2001
14	14	79799880.00	64460211.00	0.81	15339669.00	0.19	2015
15	15	76432727.00	50863742.00	0.67	25568985.00	0.34	2000
16	16	333535934.00	154696080.00	0.46	178839854.00	0.54	2005
17	17	10229331.00	10097538.00	0.99	131793.00	0.01	2001
18	18	89431890.00	2201923.00	0.03	87229967.00	0.98	2006
19	19	198413428.00	120908074.00	0.61	77505354.00	0.39	2004
20	20	67918658.00	40160800.00	0.59	27750578.00	0.41	2010
21	21	29907685.00	20264436.00	0.68	9643249.00	0.32	2006
22	22	16872671.00	14448589.00	0.86	2424082.00	0.14	2002
23	23	80547866.00	36661504.00	0.46	43886362.00	0.55	2010
24	24	35442935.00	19363565.00	0.55	16079370.00	0.45	2007
25	25	385680446.00	257730019.00	0.67	127950427.00	0.33	2009
26	26	101564935.00	56127162.00	0.55	45437773.00	0.45	2003

Рис 3.14 – Заповнена таблиця main зони “fact_box_office”

	1	2	3	4	5	6	7	8	9	10	11
fact_id	1	2	3	4	5	6	7	8	9	10	11
movie_id	4	4	6	9	9	10	10	13	13	16	16
director_id	3260	1426	<null>	2929	1095	1848	14	3483	1649	2727	893
average_rating	7.5	7.5	6.5	7.2	7.2	5.2	5.2	7.0	7.0	5.3	5.3
number_of_votes	194048	194048	336694	198381	198381	14584	14584	88925	88925	2843	2843
approval_index	6.59	6.59	5.95	6.33	6.33	3.54	3.54	5.74	5.74	2.97	2.97
production_budget	17000000.00	17000000.00	44000000.00	6500000.00	6500000.00	3500000.00	3500000.00	10000000.00	10000000.00	20000000.00	20000000.00
domestic_gross	71502303.00	71502303.00	6105175.00	4002293.00	4002293.00	3293258.00	3293258.00	25697647.00	25697647.00	18826490.00	18826490.00
worldwide_gross	109726800.00	109726800.00	12342632.00	20412841.00	20412841.00	3293258.00	3293258.00	25707698.00	25707698.00	18826490.00	18826490.00

Рис 3.15 – Заповнена таблиця main зони “fact_movie_performance”

	fact_id	movie_id	category_id	ceremony	year_film	year_ceremony	winner
1	1	1055	5	72	1999	2000	true
2	2	1033	5	75	2002	2003	false
3	3	918	5	83	2010	2011	false
4	4	815	5	67	1994	1995	true
5	5	565	5	74	2001	2002	true
6	6	564	5	81	2008	2009	false
7	7	537	5	61	1988	1989	true
8	8	477	5	61	1988	1989	false
9	9	368	5	71	1998	1999	false
10	10	297	5	83	2010	2011	false
11	11	127	5	63	1990	1991	true
12	12	87	5	82	2009	2010	true
13	13	51	5	76	2003	2004	true
14	14	2078	5	71	1998	1999	true
15	15	1945	5	70	1997	1998	false
16	16	1754	5	70	1997	1998	true
17	17	1678	5	55	1982	1983	false
18	18	1315	5	74	2001	2002	false
19	19	1314	5	58	1985	1986	true
20	20	1262	5	79	2006	2007	false
21	21	3216	5	72	1999	2000	false
22	22	3044	5	82	2009	2010	false
23	23	3011	5	62	1989	1990	true
24	24	2933	5	66	1993	1994	false
25	25	2912	5	62	1989	1990	false
26	26	2781	5	54	1981	1982	false

Рис 3.16 – Заповнена таблиця main зони “fact_oscar_awards”

	movie_id	star_id
1	12308	452
2	6991	2146
3	4560	1420
4	7137	192
5	4283	4935
6	13488	4530
7	1447	2511
8	1207	4072
9	494	3433
10	7279	2909
11	6976	2322
12	8330	4901
13	13159	3610
14	30	4593
15	5950	2030
16	3124	795
17	12503	2031
18	5208	1116
19	1696	3046
20	691	658
21	7012	4384
22	12940	955
23	364	4999
24	9249	1060
25	2440	3541
26	7938	3783

Рис 3.17 – Заповнена таблиця main зони “movie_stars”

	movie_id	writer_id
1	15218	6369
2	15218	1857
3	15217	7560
4	15217	3048
5	15216	6643
6	15216	2131
7	15215	8517
8	15215	4005
9	15214	6269
10	15214	1757
11	15213	6874
12	15213	2362
13	15212	5631
14	15212	1119
15	15211	4651
16	15211	139
17	15210	7929
18	15210	7293
19	15210	3417
20	15210	2781
21	15209	8966
22	15209	4454
23	15208	7113
24	15208	2601
25	15207	8969
26	15207	4457

Рис 3.18 – Заповнена таблиця main зони “movie_writers”

3.5 Завантаження змінених даних

База даних містить інформацію про фільми, режисерів, сценаристів, акторів, нагороди та касові збори. Деякі з цих даних можуть змінюватися з часом, тому застосовується SCD (Slowly Changing Dimensions) для їхнього правильного зберігання та обробки.

1. `dim_movie` – SCD Type 2 (збереження історії змін). Ця таблиця містить основну інформацію про фільми, зокрема назву, дату випуску, жанр, рейтинг, бюджет та інші характеристики.

Оскільки такі атрибути, як жанр, рейтинг та тривалість, можуть змінюватися з часом, використовується SCD Type 2:

Коли змінюється будь-який з цих атрибутів, створюється новий запис, що відображає оновлений стан фільму. Попередній запис позначається як неактуальний, але зберігається для аналізу історичних змін. Це дозволяє відстежувати зміни у характеристиках фільму та оцінювати їхній вплив на його популярність і фінансові результати.

2. `dim_director` – SCD Type 1 (перезапис значень). Таблиця містить інформацію про режисерів, включаючи ім'я, рік народження, рік смерті та професії. Оскільки зміни в цих даних зазвичай не потребують збереження історії, застосовується SCD Type 1. Якщо оновлюється будь-який з атрибутів (наприклад, стає відомим рік смерті режисера або змінюється перелік його професій), старе значення перезаписується.

Такий підхід підходить для випадків, коли важливо зберігати лише найактуальнішу інформацію.

3. `dim_oscar_category` – SCD Type 1 (перезапис значень). Ця таблиця містить категорії нагород «Оскар», які можуть змінюватися або уточнюватися з часом.

Застосовується SCD Type 1, оскільки історія змін у назвах категорій не є критично важливою. Якщо назва категорії змінюється або коригується, нове значення перезаписується, без збереження попередніх записів.

Це забезпечує підтримку актуальної класифікації нагород без дублювання даних.

4. dim_star та dim_writer – SCD Type 1 (перезапис значень). Таблиці містять інформацію про акторів та сценаристів, які брали участь у створенні фільмів.

Застосовується SCD Type 1, оскільки їхні імена та інші атрибути не потребують історичного збереження. Якщо змінюється ім'я (наприклад, у разі виправлення помилки або використання сценічного псевдоніма), запис перезаписується. Це дозволяє забезпечити актуальність даних без ускладнення моделі.

Код:

```
-- SCD Type 2
ALTER TABLE main.dim_movie
  ADD COLUMN valid_from DATE DEFAULT CURRENT_DATE,
  ADD COLUMN valid_to DATE NULL,
  ADD COLUMN is_current BOOLEAN DEFAULT TRUE;

-- 1. Оновлення dim_movie (SCD Type 2)
WITH new_movies AS (SELECT DISTINCT name AS title,
                                   released AS release_date,
                                   year,
                                   genre,
                                   rating,
                                   runtime,
                                   budget,
                                   company AS production_company,
                                   country
                    FROM staging.movies)

INSERT
INTO main.dim_movie (title, release_date, year, genre, rating,
runtime_minutes, budget, production_company, country,
                    valid_from, valid_to, is_current)
SELECT nm.*, CURRENT_DATE, NULL, TRUE
FROM new_movies nm
     LEFT JOIN main.dim_movie dm ON nm.title = dm.title AND nm.year
= dm.year
WHERE dm.movie_id IS NULL
     OR (dm.is_current = TRUE AND (
nm.genre <> dm.genre OR nm.rating <> dm.rating OR nm.runtime <>
dm.runtime_minutes
```

```

));

-- Закриття старих записів у разі змін
UPDATE main.dim_movie
SET valid_to    = CURRENT_DATE,
    is_current = FALSE
WHERE is_current = TRUE
    AND movie_id IN (SELECT old.movie_id
                     FROM main.dim_movie old
                     JOIN staging.movies new ON old.title =
new.name AND old.year = new.year
                     WHERE old.genre <> new.genre
                        OR old.rating <> new.rating
                        OR old.runtime_minutes <> new.runtime);

-- 2. Оновлення dim_director (SCD Type 1)
INSERT INTO main.dim_director (name, birth_year, death_year,
professions)
SELECT DISTINCT director_name, director_birth_year, director_death_year,
director_professions
FROM staging.movie_budget
WHERE director_name IS NOT NULL
ON CONFLICT (director_id) DO UPDATE
    SET birth_year    = EXCLUDED.birth_year,
        death_year    = EXCLUDED.death_year,
        professions    = EXCLUDED.professions;

-- 3. Оновлення dim_oscar_category
INSERT INTO main.dim_oscar_category (category, canon_category)
SELECT DISTINCT category, canon_category
FROM staging.oscar_awards
ON CONFLICT (category_id) DO NOTHING;

-- 4. Оновлення dim_star
INSERT INTO main.dim_star (name)
SELECT DISTINCT star
FROM staging.movies
WHERE star IS NOT NULL
ON CONFLICT (star_id) DO NOTHING;

-- 5. Оновлення dim_writer
INSERT INTO main.dim_writer (name)
SELECT DISTINCT writer
FROM staging.movies
WHERE writer IS NOT NULL
ON CONFLICT (writer_id) DO NOTHING;

```

3.6 Завантаження нових даних

База даних містить фактичні таблиці (`fact_box_office`, `fact_movie_performance`, `fact_oscar_awards`), а також зв'язкові таблиці (`movie_stars`, `movie_writers`), які можуть змінюватися з часом. Оскільки ці таблиці містять динамічні дані, використовується інкрементальне завантаження для оновлення та додавання нових записів без дублювання даних. Таблиці, до яких застосовується Incremental Load:

1. `fact_box_office` – оновлення фінансових показників. Ця таблиця містить інформацію про касові збори фільмів, які можуть оновлюватися з часом.

Якщо запис вже існує (за `movie_id` та `year`), дані про світові та локальні збори оновлюються. Якщо запису немає, він додається як новий.

Цей підхід дозволяє коригувати попередні фінансові дані, що змінюються після виходу фільму.

2. `fact_movie_performance` – оновлення рейтингів та зборів. Таблиця містить оцінки фільмів, кількість голосів та бюджетні показники.

Якщо запис вже існує (`movie_id`), оновлюються середній рейтинг, кількість голосів, касові збори. Якщо запису немає, додається новий.

Такий підхід важливий, оскільки рейтинг фільму та кількість голосів змінюються з часом (наприклад, через нові оцінки користувачів).

3. `fact_oscar_awards` – додавання нових переможців. Ця таблиця містить інформацію про номінації та перемоги на «Оскарі».

Якщо фільм вже був номінований у категорії (`movie_id`, `category_id`, `year_film`), запис не змінюється, щоб зберегти історичні дані. Якщо з'являється нова номінація або переможець, запис додається.

Це дозволяє коректно обробляти оновлення списку переможців та нові номінації.

4. movie_stars та movie_writers – унікальні зв'язки. Ці таблиці містять відношення фільмів до акторів (movie_stars) і сценаристів (movie_writers).

Якщо зв'язок вже існує, він не дублюється. Якщо актор або сценарист новий для фільму, запис додається. Це забезпечує правильне відображення касту та команди фільму без зайвих записів.

Код:

```
-- 1. Завантаження fact_box_office (оновлення даних)
INSERT INTO main.fact_box_office (movie_id, worldwide, domestic,
domestic_percent, "foreign", foreign_percent, year)
SELECT dm.movie_id, bo.worldwide, bo.domestic, bo.domestic_percent,
bo.foreign, bo.foreign_percent, bo.year
FROM staging.box_office bo
      JOIN main.dim_movie dm ON bo.release_group = dm.title AND
bo.year = dm.year
ON CONFLICT (movie_id, year) DO UPDATE SET worldwide =
EXCLUDED.worldwide,
                                           domestic =
EXCLUDED.domestic,
                                           domestic_percent =
EXCLUDED.domestic_percent,
                                           "foreign" =
EXCLUDED.foreign,
                                           foreign_percent =
EXCLUDED.foreign_percent;

-- 2. Завантаження fact_movie_performance (рейтинги та збори можуть
змінюватися)
INSERT INTO main.fact_movie_performance (movie_id, director_id,
average_rating, number_of_votes, approval_index,
                                           production_budget,
domestic_gross, worldwide_gross)
SELECT dm.movie_id,
       dd.director_id,
       mb.movie_average_rating,
       mb.movie_number_of_votes,
       mb.approval_index,
       mb.production_budget,
       mb.domestic_gross,
       mb.worldwide_gross
FROM staging.movie_budget mb
      JOIN main.dim_movie dm ON mb.movie_title = dm.title AND
mb.production_date = dm.release_date
      LEFT JOIN main.dim_director dd ON mb.director_name = dd.name
```

```

ON CONFLICT (movie_id) DO UPDATE SET average_rating =
EXCLUDED.average_rating,
                                number_of_votes =
EXCLUDED.number_of_votes,
                                approval_index =
EXCLUDED.approval_index,
                                domestic_gross =
EXCLUDED.domestic_gross,
                                worldwide_gross =
EXCLUDED.worldwide_gross;

-- 3. Завантаження fact_oscar_awards (можуть з'являтися нові переможці)
INSERT INTO main.fact_oscar_awards (movie_id, category_id, ceremony,
year_film, year_ceremony, winner)
SELECT dm.movie_id, dc.category_id, oa.ceremony, oa.year_film,
oa.year_ceremony, oa.winner
FROM staging.oscar_awards oa
      JOIN main.dim_movie dm ON oa.film = dm.title AND oa.year_film =
dm.year
      JOIN main.dim_oscar_category dc ON oa.category = dc.category
ON CONFLICT (movie_id, category_id, year_film) DO NOTHING;

-- 4. Завантаження зв'язків між фільмами та акторами
INSERT INTO main.movie_stars (movie_id, star_id)
SELECT DISTINCT dm.movie_id, ds.star_id
FROM staging.movies m
      JOIN main.dim_movie dm ON m.name = dm.title AND m.year =
dm.year
      JOIN main.dim_star ds ON m.star = ds.name
ON CONFLICT (movie_id, star_id) DO NOTHING;

-- 5. Завантаження зв'язків між фільмами та сценаристами
INSERT INTO main.movie_writers (movie_id, writer_id)
SELECT DISTINCT dm.movie_id, dw.writer_id
FROM staging.movies m
      JOIN main.dim_movie dm ON m.name = dm.title AND m.year =
dm.year
      JOIN main.dim_writer dw ON m.writer = dw.name
ON CONFLICT (movie_id, writer_id) DO NOTHING;

```

4.ІНТЕЛЕКТУАЛЬНИЙ АНАЛІЗ ДАНИХ

4.1 Обґрунтування вибору методів інтелектуального аналізу даних

Інтелектуальний аналіз даних (англ. Data Mining) – це процес виявлення значущих, раніше невідомих закономірностей, залежностей і трендів у великих обсягах даних. Його основна мета – перетворення сирих даних на корисну інформацію для прийняття обґрунтованих рішень. У контексті кіноіндустрії, де щорічно випускаються сотні фільмів, інтелектуальний аналіз дозволяє виявити фактори, що впливають на комерційний успіх стрічок або їхню ймовірність отримання престижних нагород, таких як «Оскар».

У межах даної курсової роботи поставлено завдання дослідити, які характеристики фільмів (жанр, бюджет, акторський склад, режисер, сценарист, рейтинг, дата релізу тощо) впливають на їхній комерційний успіх (касові збори) та ймовірність отримання нагород. Для цього необхідно вирішити дві основні задачі:

1. Регресійна задача – передбачення числових показників, таких як світові касові збори, рейтинг IMDb або індекс схвалення;
2. Класифікаційна задача – визначення ймовірності отримання фільмом номінації або перемоги в премії «Оскар».

Для вирішення зазначених задач було обрано три моделі машинного навчання, які зарекомендували себе як ефективні інструменти для аналізу табличних даних:

1. Logistic Regression;
2. Random Forest;
3. XGBoost (Extreme Gradient Boosting).

Logistic Regression – це статистична модель, яка використовується для прогнозування ймовірності настання певної події, зокрема в задачах бінарної класифікації. Вона моделює залежність між набором незалежних змінних та ймовірністю належності спостереження до певного класу за допомогою

логістичної функції. Ця модель є інтерпретованою та дозволяє оцінити вплив кожної ознаки на результат. У нашому дослідженні логістична регресія використовується для передбачення ймовірності отримання фільмом номінації або перемоги в премії «Оскар» на основі його характеристик.

Random Forest – це ансамблева модель машинного навчання, яка будує велику кількість дерев рішень під час навчання та об'єднує їх результати для покращення точності прогнозів. Для задач класифікації результатом є клас, обраний більшістю дерев, а для задач регресії – середнє значення прогнозів усіх дерев. Ця модель є стійкою до перенавчання та здатна обробляти великі обсяги даних з високою точністю. У нашому дослідженні Random Forest використовується як для передбачення касових зборів фільмів, так і для оцінки ймовірності отримання нагород.

XGBoost – це ефективна реалізація градієнтного бустингу, яка забезпечує високу продуктивність та точність. Вона використовує ансамбль слабких моделей (зазвичай дерев рішень), які навчаються послідовно, кожна нова модель фокусується на помилках попередніх. XGBoost включає різні оптимізації, такі як регуляризація, обробка пропущених значень та паралельне обчислення, що робить її однією з найпотужніших моделей для задач регресії та класифікації. У нашому дослідженні XGBoost застосовується для точного прогнозування касових зборів та ймовірності отримання нагород.

Вибір зазначених моделей обумовлений наступними факторами:

1. Здатність працювати з різнотипними ознаками. Моделі ефективно обробляють як числові, так і категоріальні дані;
2. Стійкість до пропущених або шумових даних. Особливо це стосується Random Forest та XGBoost;
3. Інтерпретованість результатів. Логістична регресія дозволяє легко інтерпретувати вплив кожної ознаки на результат;
4. Висока точність прогнозів. XGBoost забезпечує одну з найвищих точностей серед сучасних моделей;

5. Можливість оцінки важливості ознак. Random Forest та XGBoost надають інструменти для визначення значущості кожної ознаки в моделі.

Застосування інтелектуального аналізу даних у дослідженні факторів успіху фільмів дозволяє виявити приховані закономірності та залежності, які можуть бути корисними для кіновиробників, дистриб'юторів та аналітиків. Обрані моделі – логістична регресія, Random Forest та XGBoost – забезпечують баланс між інтерпретованістю, точністю та ефективністю, що робить їх придатними для вирішення поставлених задач у межах даної курсової роботи.

4.2 Попередній аналіз даних

4.2.1 Огляд структури даних

На етапі попереднього аналізу даних необхідно дослідити структуру набору даних, оцінити розподіл значень числових і категоріальних ознак, виявити кореляційні зв'язки між змінними, а також проаналізувати пропуски в даних. Цей етап є важливим для підготовки даних до подальшого моделювання, оскільки дозволяє визначити потенційні проблеми, такі як викиди, аномалії, сильні кореляції між ознаками (мультиколінеарність) і пропуски, які можуть вплинути на якість моделей машинного навчання.

Для виконання попереднього аналізу даних було виконано кілька кроків. Спочатку було підключено до бази даних PostgreSQL за допомогою бібліотеки SQLAlchemy та виконано SQL-запит для об'єднання таблиць, що містять інформацію про фільми, їхні касові збори, рейтинги та номінації на премію Оскар. Отримані дані збережено у DataFrame за допомогою бібліотеки pandas. Далі проведено огляд структури даних через методи `info()` та `head()` для оцінки типів змінних, кількості записів і пропусків.

```

≡ Огляд даних ≡
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9888 entries, 0 to 9887
Data columns (total 21 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   movie_id                             9888 non-null   int64
1   title                                9888 non-null   object
2   year                                 9888 non-null   int64
3   genre                                9888 non-null   object
4   rating                               9811 non-null   object
5   runtime_minutes                      9886 non-null   float64
6   budget                              7591 non-null   float64
7   production_company                  9873 non-null   object
8   country                             9887 non-null   object
9   worldwide                           3665 non-null   float64
10  domestic                             3665 non-null   float64
11  domestic_percent                     3665 non-null   float64
12  foreign                              3665 non-null   float64
13  foreign_percent                      3665 non-null   float64
14  average_rating                       5330 non-null   float64
15  number_of_votes                      5330 non-null   float64
16  approval_index                      5330 non-null   float64
17  production_budget                    5330 non-null   float64
18  domestic_gross                       5330 non-null   float64
19  worldwide_gross                     5330 non-null   float64
20  oscar_nominated                     9888 non-null   int64
dtypes: float64(13), int64(3), object(5)
memory usage: 1.6+ MB
None

```

Рисунок 4.1 – Огляд даних

```

≡ Перші 5 рядків ≡
movie_id                                title  year \
0      1055                             Topsy-Turvy  1999
1      1033                             The Time Machine  2002
2       918                             The Way Back  2010
3       815                             Ed Wood  1994
4       565  The Lord of the Rings: The Fellowship of the Ring  2001

genre rating runtime_minutes    budget production_company \
0 Biography    R          160.0         NaN    Goldwyn Films
1 Action    PG-13          96.0  80000000.0    Warner Bros.
2 Adventure PG-13         133.0  30000000.0    Exclusive Films
3 Biography    R         127.0  18000000.0    Touchstone Pictures
4 Action    PG-13         178.0  93000000.0    New Line Cinema

country worldwide ... domestic_percent foreign \
0 United Kingdom    NaN ...         NaN    NaN
1 United States 123729176.0 ...         0.46  66896682.0
2 United States 24172201.0 ...         0.11  21470342.0
3 United States    NaN ...         NaN    NaN
4 New Zealand 868385360.0 ...         0.36  555021246.0

foreign_percent average_rating number_of_votes approval_index \
0         NaN         NaN         NaN         NaN
1         0.54         6.0      126054.0         5.05
2         0.89         6.7      47905.0         5.18
3         NaN         7.8      178200.0         6.81
4         0.64         8.8     1886597.0         9.22

production_budget domestic_gross worldwide_gross oscar_nominated
0         NaN         NaN         NaN         1
1  80000000.0    56684819.0    98983590.0         1
2  23000000.0    13590514.0    14563409.0         1
3  18000000.0    5828466.0    5828734.0         1
4  93000000.0   315544750.0   891216824.0         1

```

Рисунок 4.2 – Перші 5 рядків

Аналіз структури даних показав, що набір даних містить 9888 записів і 21 стовпець. Змінні включають числові (year, runtime_minutes, budget, worldwide, domestic, foreign, average_rating, number_of_votes, approval_index, production_budget, domestic_gross, worldwide_gross), категоріальні (title, genre, rating, production_company, country) та бінарну змінну (oscar_nominated). Типи даних відповідають очікуваним: числові змінні представлені як float64 або int64, категоріальні – як object, а бінарна змінна – як int64. Проте вже на цьому етапі помітно значну кількість пропусків у стовпцях, таких як worldwide, domestic, average_rating та production_budget, що потребує подальшого аналізу.

4.2.2 Аналіз розподілу числових ознак




Рисунок 4.3 – Гістограми числових ознак

Гістограми числових ознак демонструють сильну асиметрію (праву скісність) у більшості змінних, таких як budget, worldwide, domestic, foreign, number_of_votes, production_budget, domestic_gross та worldwide_gross. Наприклад, значення worldwide_gross і budget мають довгий правий хвіст, що вказує на наявність фільмів із надзвичайно високими бюджетами та зборами

(імовірно, блокбастери), тоді як більшість фільмів мають значно нижчі значення. Змінна `runtime_minutes` має більш нормальний розподіл із піком близько 100–120 хвилин, що є типовим для більшості фільмів. `average_rating` та `approval_index` також мають відносно нормальний розподіл, але з невеликою лівою скісністю, що свідчить про те, що більшість фільмів отримують середні або високі оцінки.




Рисунок 4.4 – Боксплоти числових ознак

Боксплоти підтверджують наявність значних викидів у змінних `budget`, `worldwide`, `domestic`, `foreign`, `number_of_votes`, `production_budget`, `domestic_gross` та `worldwide_gross`. Наприклад, у `worldwide_gross` є значення, що перевищують 2 мільярди доларів, що відповідає відомим блокбастерам, таким як "Месники". Викиди у `runtime_minutes` менш виражені, але є окремі фільми з тривалістю понад 200 хвилин. Ці викиди можуть суттєво вплинути на моделі регресії, особливо на метрики, чутливі до великих відхилень, такі як MSE, тому в

подальшому може знадобитися їхня обробка (наприклад, логарифмування або обрізка).

4.2.3 Аналіз розподілу категоріальних ознак




Рисунок 4.5 – Стовчасті діаграми категоріальних ознак

Стовчасті діаграми категоріальних ознак показують, що серед жанрів (genre) найпоширенішими є "Drama", "Comedy" та "Action", що відображає популярність цих жанрів у кінематографі. У стовпці rating домінують категорії "R" та "PG-13", що вказує на орієнтацію фільмів на дорослу або підліткову аудиторію. Для змінної country більшість фільмів походять із США, що очікувано, враховуючи домінування Голлівуду у світовому кінематографі. Розподіл за роками (year) показує зростання кількості фільмів у пізніші роки (наприклад, після 2000 року), що може бути пов'язано зі збільшенням обсягів виробництва та доступністю даних. Цей аналіз допомагає зрозуміти структуру даних і виявити домінуючі категорії, які можуть бути важливими для подальшого кодування ознак.

4.2.4 Кореляційний аналіз




Рисунок 4.6 – Теплова карта кореляцій

Теплова карта кореляцій числових ознак виявила сильні позитивні кореляції між кількома парами змінних. Наприклад, `worldwide_gross` та `production_budget` мають кореляцію 0.7, що свідчить про те, що фільми з більшим бюджетом, як правило, мають вищі світові збори. Аналогічно, `domestic_gross` та `worldwide_gross` корелюють на рівні 0.95, що логічно, оскільки внутрішні збори є частиною світових. Змінна `number_of_votes` також має помірну кореляцію (0.58) із `worldwide_gross`, що вказує на те, що популярніші фільми (з більшим числом голосів) мають вищі збори.

Цікаво, що `average_rating` має слабку кореляцію (0.3) із `worldwide_gross`, що свідчить про те, що високий рейтинг не завжди гарантує високі касові збори. Змінна `runtime_minutes` демонструє слабку кореляцію з усіма іншими змінними, що вказує на її низький вплив на касові збори чи рейтинги.




Рисунок 4.7 – Діаграми розсіювання

Діаграми розсіювання підтверджують ці висновки: на графіку budget vs worldwide_gross видно позитивний зв'язок, але з великою дисперсією – деякі фільми з високим бюджетом мають низькі збори. На діаграмі average_rating vs worldwide_gross зв'язок слабкий, із розкидом значень по всьому діапазону рейтингів. Графік number_of_votes vs worldwide_gross показує чіткіший зв'язок: фільми з великою кількістю голосів (понад 1 мільйон) зазвичай мають збори понад 500 мільйонів доларів. Ці результати підкреслюють важливість бюджету та популярності (кількості голосів) для прогнозування касових зборів, але вказують на обмежену роль рейтингу.

4.2.5 Аналіз пропусків

```

≡ Відсоток пропусків ≡
rating          0.778722
runtime_minutes 0.020227
budget          23.230178
production_company 0.151699
country         0.010113
worldwide       62.934871
domestic        62.934871
domestic_percent 62.934871
foreign         62.934871
foreign_percent 62.934871
average_rating  46.096278
number_of_votes 46.096278
approval_index  46.096278
production_budget 46.096278
domestic_gross  46.096278
worldwide_gross 46.096278
dtype: float64

```

Рисунок 4.8 – Відсоток пропусків

Аналіз пропусків показав значну проблему з відсутністю даних у кількох стовпцях. Найвищий відсоток пропусків спостерігається у змінних, пов'язаних із касовими зборами: `worldwide`, `domestic`, `foreign`, `domestic_percent` та `foreign_percent` мають 62.93% пропусків. Це може бути пов'язано з тим, що не для всіх фільмів доступна інформація про касові збори, особливо для старих або менш популярних фільмів. Змінні `average_rating`, `number_of_votes`, `approval_index`, `production_budget`, `domestic_gross` та `worldwide_gross` мають 46.10% пропусків, що, ймовірно, пояснюється відсутністю даних про рейтинги та бюджет для частини фільмів.

Стовпець `budget` має 23.23% пропусків, що також є значним, але меншим порівняно з іншими фінансовими змінними. Інші стовпці, такі як `rating` (0.78%), `runtime_minutes` (0.02%), `production_company` (0.15%) та `country` (0.01%), мають мінімальні пропуски, що не становить серйозної проблеми.




Рисунок 4.9 – Теплова карта пропусків

Теплова карта пропусків числових ознак підтверджує ці спостереження: пропуски у змінних *worldwide*, *domestic*, *foreign* та інших фінансових змінних згруповані, тобто якщо для фільму відсутнє значення *worldwide*, то зазвичай відсутні й інші пов'язані змінні. Це може свідчити про систематичний характер пропусків (наприклад, дані не були зібрані для певних фільмів). Для змінних із меншим відсотком пропусків, таких як *runtime_minutes*, пропуски розподілені випадково.

Ці пропуски потребують обробки перед моделюванням. Для змінних із високим відсотком пропусків (понад 60%) варто розглянути можливість їхнього видалення або використання лише тих записів, де ці дані присутні. Для змінних із помірним відсотком пропусків (наприклад, *budget*) можна застосувати імпутацію (наприклад, медіаною), враховуючи розподіл даних. Для категоріальних змінних із мінімальними пропусками (наприклад, *rating*) можна заповнити пропуски найпоширенішою категорією.

4.2.6 Висновки

Попередній аналіз даних виявив кілька ключових аспектів, які необхідно врахувати перед моделюванням. По-перше, числові ознаки мають сильну асиметрію та викиди, що потребує трансформації (наприклад, логарифмування) або обробки викидів. По-друге, категоріальні ознаки демонструють домінування певних категорій (наприклад, США у *country* та "Drama" у *genre*), що може бути використано для кодування ознак. По-третє, кореляційний аналіз показав сильний зв'язок між бюджетом, кількістю голосів і касовими зборами, але слабкий вплив рейтингу, що важливо для вибору ознак. Нарешті, значна кількість пропусків у фінансових і рейтингових змінних потребує ретельної обробки, щоб уникнути втрати даних або спотворення результатів.

4.3 Підготовка даних

Цей етап спрямований на очищення даних та їх підготовку до подальшого моделювання, що є ключовим для забезпечення якості прогнозів. Мета полягає

в усуненні пропусків, кодуванні категоріальних ознак і створенні нових ознак для підвищення інформативності даних. Ці дії дозволять уникнути помилок у моделях, таких як спотворення через пропущені значення, а також адаптувати категоріальні змінні до числового формату, придатного для алгоритмів машинного навчання.

Для підготовки даних виконано три основні кроки. Спочатку проведено обробку пропусків у даних. Категоріальні змінні, такі як `rating`, `production_company` і `country`, заповнено найпоширенішими значеннями: `rating` заповнено значенням "R", `production_company` – значенням "Unknown", а `country` – значенням "United States", оскільки ці значення є домінуючими в наборі даних. Для числових змінних `runtime_minutes` і `budget` використано медіану як метод імпутації, враховуючи асиметрію розподілу та наявність викидів, що робить медіану більш стійкою до спотворень порівняно зі середнім значенням.

Другим кроком було кодування категоріальних ознак. Для змінних `genre` і `rating` застосовано `one-hot encoding`, що створило бінарні стовпці для кожного унікального значення, уникаючи припущень про порядок між категоріями. Для змінної `country`, з огляду на велику кількість унікальних значень, спочатку відібрано топ-5 країн (США, Великобританія, Франція, Канада, Німеччина), а решту об'єднано в категорію "Other", після чого також використано `one-hot encoding`. Цей підхід зменшує розмірність даних і зберігає ключову інформацію.

Третім кроком обрано ознаки для моделювання, включаючи числові змінні (`year`, `runtime_minutes`, `budget`) та закодовані категоріальні змінні. Дані розбито на два набори: для регресії, де цільовою змінною є `worldwide_gross` (світові касові збори), і для класифікації, де цільовою змінною є `oscar_nominated` (номінація на Оскар). Для регресії використано лише рядки з наявними значеннями `worldwide_gross`, а для класифікації – усі доступні дані. Розбиття на навчальну (80%) і тестову (20%) вибірки виконано з використанням `train_test_split` із фіксованим випадковим станом (`random_state=42`) для відтворюваності результатів.

```

=== Перевірка виконаної роботи ===

Структура DataFrame після кодування:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9888 entries, 0 to 9887
Data columns (total 55 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   movie_id                             9888 non-null   int64
1   title                                9888 non-null   object
2   year                                 9888 non-null   int64
3   runtime_minutes                      9888 non-null   float64
4   budget                              9888 non-null   float64
5   production_company                  9888 non-null   object
6   worldwide                           3665 non-null   float64
7   domestic                            3665 non-null   float64
8   domestic_percent                    3665 non-null   float64
9   foreign                             3665 non-null   float64
10  foreign_percent                     3665 non-null   float64
11  average_rating                      5330 non-null   float64
12  number_of_votes                     5330 non-null   float64
13  approval_index                     5330 non-null   float64
14  production_budget                   5330 non-null   float64
15  domestic_gross                      5330 non-null   float64
16  worldwide_gross                     5330 non-null   float64
17  oscar_nominated                     9888 non-null   int64
18  genre_Action                        9888 non-null   bool
19  genre_Adventure                     9888 non-null   bool
20  genre_Animation                     9888 non-null   bool
21  genre_Biography                     9888 non-null   bool
22  genre_Comedy                        9888 non-null   bool
23  genre_Crime                         9888 non-null   bool
24  genre_Drama                         9888 non-null   bool
25  genre_Family                        9888 non-null   bool
26  genre_Fantasy                       9888 non-null   bool
27  genre_History                       9888 non-null   bool
28  genre_Horror                        9888 non-null   bool
29  genre_Music                         9888 non-null   bool
30  genre_Musical                       9888 non-null   bool
31  genre_Mystery                       9888 non-null   bool
32  genre_Romance                       9888 non-null   bool
33  genre_Sci-Fi                        9888 non-null   bool
34  genre_Sport                         9888 non-null   bool
35  genre_Thriller                      9888 non-null   bool
36  genre_Western                       9888 non-null   bool
37  rating_Approved                     9888 non-null   bool
38  rating_G                             9888 non-null   bool
39  rating_NC-17                        9888 non-null   bool
40  rating_Not Rated                    9888 non-null   bool
41  rating_PG                           9888 non-null   bool
42  rating_PG-13                        9888 non-null   bool
43  rating_R                             9888 non-null   bool
44  rating_TV-14                        9888 non-null   bool
45  rating_TV-MA                        9888 non-null   bool
46  rating_TV-PG                        9888 non-null   bool
47  rating_Unrated                      9888 non-null   bool
48  rating_X                             9888 non-null   bool
49  country_Canada                      9888 non-null   bool
50  country_France                      9888 non-null   bool
51  country_Germany                     9888 non-null   bool
52  country_Other                       9888 non-null   bool
53  country_United Kingdom              9888 non-null   bool
54  country_United States               9888 non-null   bool

Перші 5 рядків після кодування:
   movie_id  title  year  \
0    1055    Topsy-Turvy  1999
1    1033    The Time Machine  2002
2     918    The Way Back  2010
3     815    Ed Wood  1994
4    565    The Lord of the Rings: The Fellowship of the Ring  2001

   runtime_minutes  budget  production_company  worldwide  domestic  \
0    160.0  24000000.0    Goldwyn Films      NaN      NaN
1     96.0  80000000.0    Warner Bros.  123729176.0  56832494.0
2    133.0  30000000.0    Exclusive Films  24172201.0  2701859.0
3    127.0  18000000.0    Touchstone Pictures      NaN      NaN
4    178.0  93000000.0    New Line Cinema  868385360.0  313364114.0

   domestic_percent  foreign  ...  rating_TV-MA  rating_TV-PG  \
0      NaN      NaN      ...      False      False
1     0.46  66896682.0      ...      False      False
2     0.11  21470342.0      ...      False      False
3      NaN      NaN      ...      False      False
4     0.36  555021246.0      ...      False      False

   rating_Unrated  rating_X  country_Canada  country_France  country_Germany  \
0      False      False      False      False      False
1      False      False      False      False      False
2      False      False      False      False      False
3      False      False      False      False      False
4      False      False      False      False      False

   country_Other  country_United Kingdom  country_United States
0      False      True      False
1      False      False      True
2      False      False      True
3      False      False      True
4      True      False      False

Обрані ознаки для моделювання:
['year', 'runtime_minutes', 'budget', 'genre_Action', 'genre_Adventure', 'genre_Animation', 'genre_Biography', 'genre_Comedy', 'genre_Crime', 'genre_Drama', 'genre_Family', 'genre_Fantasy', 'genre_History', 'genre_Horror', 'genre_Music', 'genre_Musical', 'genre_Mystery', 'genre_Romance', 'genre_Sci-Fi', 'genre_Sport', 'genre_Thriller', 'genre_Western', 'rating_Approved', 'rating_G', 'rating_NC-17', 'rating_Not Rated', 'rating_PG', 'rating_PG-13', 'rating_R', 'rating_TV-14', 'rating_TV-MA', 'rating_TV-PG', 'rating_Unrated', 'rating_X', 'country_Canada', 'country_France', 'country_Germany', 'country_Other', 'country_United Kingdom', 'country_United States']

Розміри вибірок для перцепції:
X_train_reg: (4264, 40), X_test_reg: (1066, 40)
y_train_reg: (4264,), y_test_reg: (1066,)

Розміри вибірок для класифікації:
X_train_class: (7910, 40), X_test_class: (1978, 40)
y_train_class: (7910,), y_test_class: (1978,)

Розподіл worldwide_gross у навчальній і тестовій вибірках (перцепція):
Навчальна вибірка:
count    4.264000e+03
mean     1.794919e+08
std      2.810611e+08
min      7.396000e+03
25%     3.119125e+07
50%     8.233597e+07
75%     2.090452e+08
max      2.923706e+09
Name: worldwide_gross, dtype: float64
Тестова вибірка:
count    1.066000e+03
mean     1.779604e+08
std      2.687542e+08
min     1.348600e+04
25%     3.189502e+07
50%     8.426418e+07
75%     2.178821e+08
max      2.923706e+09
Name: worldwide_gross, dtype: float64

Розподіл oscar_nominated у навчальній і тестовій вибірках (класифікація):
Навчальна вибірка:
oscar_nominated
0    0.671934
1    0.328066
Name: proportion, dtype: float64
Тестова вибірка:
oscar_nominated
0    0.668857
1    0.331143
Name: proportion, dtype: float64

Дані підготовлено для моделювання.

```

Рисунок 4.10 – Результати обробки даних

Перевірка підтверджує коректність підготовки даних: пропуски в ключових стовпцях усунуто, кодування категоріальних ознак виконано правильно, ознаки обрано відповідно до плану, а розбиття даних відповідає пропорціям 80/20. Розподіл цільових змінних у вибірках є репрезентативним. Дані готові до наступного етапу – побудови моделей.

4.4 Моделювання

4.4.1 Прогнозування комерційного (регресія) та нагородного (класифікація) успіху

На цьому етапі проводиться побудова та оцінка моделей для двох задач: прогнозування комерційного успіху (регресія) та нагородного успіху (класифікація). Для регресії мета полягає в прогнозуванні світових касових зборів (`worldwide_gross`), а для класифікації – у визначенні ймовірності номінації на Оскар (`oscar_nominated`). Використання різних моделей дозволить порівняти їхню ефективність і обрати найкращі для кожної задачі, що є важливим для оцінки фінансового потенціалу фільмів та їхнього престижу.

Для регресії використано три моделі: Лінійну регресію, Random Forest Regressor (з 100 деревами, `random_state=42`) і XGBoost Regressor (з 100 деревами, об'єктивною функцією `reg:squarederror`, `random_state=42`). Оцінка моделей проводилася за метриками MSE (середньоквадратична помилка) та R^2 (коефіцієнт детермінації), які дозволяють оцінити точність прогнозів і пояснену дисперсію відповідно.

Для класифікації використано три моделі: Логістичну регресію (з максимум 1000 ітерацій), Random Forest Classifier (з 100 деревами, `random_state=42`) і XGBoost Classifier (з 100 деревами, об'єктивною функцією `binary:logistic`, `random_state=42`). Оцінка моделей проводилася за метриками Accuracy (точність), F1-score (гармонійне середнє між точністю та повнотою) і ROC-AUC (площа під кривою ROC), що дозволяє врахувати як загальну точність, так і здатність моделей розрізняти класи, особливо в умовах незбалансованості.

Кожна модель навчалася на відповідних навчальних вибірках (X_{train_reg} , y_{train_reg} для регресії; X_{train_class} , y_{train_class} для класифікації) і оцінювалася на тестових (X_{test_reg} , y_{test_reg} для регресії; X_{test_class} , y_{test_class} для класифікації).

```
≡ Регресія ≡
Лінійна регресія:
MSE: 39731296871736072.00, R²: 0.45
Random Forest Regressor:
MSE: 15421971642688486.00, R²: 0.79
XGBoost Regressor:
MSE: 19117421903045784.00, R²: 0.74

≡ Класифікація ≡
Логістична регресія:
Accuracy: 0.79, F1-score: 0.64, ROC-AUC: 0.84
Random Forest Classifier:
Accuracy: 0.91, F1-score: 0.87, ROC-AUC: 0.95
XGBoost Classifier:
Accuracy: 0.88, F1-score: 0.82, ROC-AUC: 0.93
```

Рисунок 4.11 – Результати оцінки моделей

4.4.2 Аналіз результатів регресії

Аналіз результатів регресії показує значні відмінності в продуктивності трьох моделей. Лінійна регресія має найгірші показники: MSE становить 39.73×10^{13} , що є надзвичайно великим значенням, а R^2 дорівнює 0.45, що вказує на те, що модель пояснює лише 45% дисперсії цільової змінної `worldwide_gross`. Це свідчить про обмежену здатність лінійної регресії уловлювати складні нелінійні залежності в даних. Велике значення MSE частково пояснюється сильною асиметрією розподілу `worldwide_gross`, де викиди (наприклад, блокбастери з доходами понад 2 мільярди доларів) значно впливають на середньоквадратичну помилку, яка чутлива до великих відхилень.

Random Forest Regressor демонструє найкращі результати серед регресійних моделей: MSE становить 15.42×10^{13} , що є найнижчим показником, а R^2 дорівнює 0.79, що вказує на те, що модель пояснює 79% дисперсії. Це значне покращення порівняно з лінійною регресією, що пояснюється здатністю Random Forest уловлювати нелінійні зв'язки та взаємодії між ознаками, такими як `budget`, `genre` і `country`. Зниження MSE у 2.5 рази порівняно з лінійною

регресією свідчить про кращу точність прогнозів, хоча значення MSE все ще велике через масштаб цільової змінної та викиди.

XGBoost Regressor показує проміжний результат: MSE становить 19.12×10^{13} , а $R^2 = 0.74$. Це гірше, ніж у Random Forest, але краще, ніж у лінійної регресії. XGBoost зазвичай ефективний для задач із нелінійними залежностями, але в даному випадку поступається Random Forest, можливо, через недостатню оптимізацію гіперпараметрів (наприклад, глибини дерев чи швидкості навчання).

Загалом для регресії Random Forest є найкращою моделлю за обома метриками. Проте варто звернути увагу на масштаб MSE: значення на рівні 10^{13} зумовлене великими значеннями worldwide_gross (у мільйонах доларів), і для кращої інтерпретації можна застосувати логарифмування цільової змінної перед моделюванням, що зменшить вплив викидів і зробить метрики більш інформативними. У майбутньому варто провести трансформацію даних і оптимізацію гіперпараметрів для XGBoost, щоб потенційно покращити його результати.

4.4.3 Аналіз результатів класифікації

Для задачі класифікації результати моделей також демонструють значні відмінності. Логістична регресія має найнижчі показники: Accuracy – 0.79, F1-score – 0.64, ROC-AUC – 0.84. Accuracy 0.79 здається високою, але з огляду на незбалансованість класів (oscar_nominated має співвідношення 67% до 33% у тестовій вибірці), ця метрика може бути оманливою. F1-score 0.64 вказує на середню якість прогнозування позитивного класу (номіновані фільми), що є важливим у цій задачі, оскільки позитивний клас менш представлений. ROC-AUC 0.84 свідчить про непогану здатність моделі розрізняти класи, але є простір для покращення. Логістична регресія, як лінійна модель, має обмеження в уловлюванні складних залежностей, що й пояснює її відносно низькі показники.

Random Forest Classifier демонструє найкращі результати: Accuracy – 0.91, F1-score – 0.87, ROC-AUC – 0.95. Висока Accuracy (0.91) у поєднанні з F1-score 0.87 показує, що модель добре справляється як із загальною точністю, так і з прогнозуванням менш представленого класу. ROC-AUC 0.95 є дуже високим і вказує на відмінну здатність моделі розрізняти номіновані та неноміновані фільми. Random Forest ефективно враховує нелінійні взаємодії між ознаками (наприклад, комбінації жанру, бюджету та країни), що робить її найкращою для цієї задачі.

XGBoost Classifier показує дещо гірші результати порівняно з Random Forest: Accuracy – 0.88, F1-score – 0.82, ROC-AUC – 0.93. Ці показники все ще високі, але поступаються Random Forest за всіма метриками. Наприклад, F1-score на 0.05 нижчий, що може бути критичним для задачі з незбалансованими класами, де важливо точно прогнозувати позитивний клас. ROC-AUC 0.93 є високим, але на 0.02 нижчим, ніж у Random Forest, що вказує на трохи гіршу дискримінаційну здатність. Як і в регресії, XGBoost, ймовірно, потребує оптимізації гіперпараметрів (наприклад, регуляризації чи глибини дерев), щоб досягти кращих результатів.

Загалом Random Forest Classifier є найкращою моделлю для класифікації. Високий F1-score і ROC-AUC підтверджують її здатність ефективно працювати з незбалансованими даними. Проте варто звернути увагу на можливе перенавчання.




Рисунок 4.12 – Візуалізація регресій




Рисунок 4.13 – ROC-криві





Рисунок 4.14 – Важливості ознак для RFR Та XGBoost




Рисунок 4.15 – Матриці невідповідностей




Рисунок 4.16 – Порівняння результатів моделей

ВИСНОВКИ

В результаті виконання курсової роботи було розроблено сховище даних фільмів типу „зірка”, що містить три таблиці фактів (fact_box_office, fact_movie_performance, fact_oscar_awards) та п’ять таблиць вимірів (dim_movie, dim_director, dim_oscar_category, dim_star, dim_writer). Реалізовано ETL-процеси для завантаження, очищення та трансформації даних із кількох джерел (Kaggle), включаючи інкрементальне завантаження та обробку змін за допомогою методів SCD (Slowly Changing Dimensions). Для реалізації поставленої задачі використано PostgreSQL, мову програмування Python із бібліотеками Pandas, Matplotlib, Seaborn та Scikit-learn.

На основі детального опису та проведеного аналізу предметної області інтелектуального аналізу даних для оцінки комерційного та нагородного успіху фільмів було отримано результати, що підтверджують вплив ключових характеристик (бюджет, жанр, рік випуску, країна) на касові збори та ймовірність номінації на Оскар. Попередній аналіз виявив сильну асиметрію в числових ознаках, значні кореляції (наприклад, між бюджетом і світовими зборами – 0.7) та проблему пропусків, що було враховано під час підготовки даних. Для оцінки комерційного успіху використано регресійні моделі (Лінійна регресія, Random Forest Regressor, XGBoost Regressor), а для нагородного – класифікаційні (Логістична регресія, Random Forest Classifier, XGBoost Classifier). Найкращі результати продемонстрував Random Forest: для регресії MSE склало 15.42×10^{13} , R^2 – 0.79, а для класифікації Accuracy – 0.91, F1-score – 0.87, ROC-AUC – 0.95. Результати досліджень показують, що бюджет і популярність (кількість голосів) є ключовими факторами комерційного успіху, тоді як жанр (наприклад, Drama) і рік випуску значною мірою впливають на нагородний успіх.

Отже, поставлені задачі були виконані: проведено аналіз даних, розроблено сховище, виконано візуалізацію та оцінку впливу факторів на успіх фільмів. У майбутньому планується розширення функціоналу для взаємодії зі сховищем даних із додаванням нових ознак (наприклад, акторський склад,

маркетингові бюджети), оптимізацією моделей через крос-валідацію та гіперпараметричний пошук, а також урахуванням часових трендів для прогнозування.

ПЕРЕЛІК ПОСИЛАНЬ

1. PostgreSQL: Documentation. PostgreSQL: The world's most advanced open source database. URL: <https://www.postgresql.org/docs/> (дата звернення: 04.06.2025).
2. PostgreSQL driver for Python – Psycopg. Psycopg. URL: <https://www.psycopg.org/> (дата звернення: 07.05.2025).
3. pandas documentation – pandas 2.2.3 documentation. pandas - Python Data Analysis Library. URL: <https://pandas.pydata.org/docs/> (дата звернення: 04.06.2025).
4. Documentation scikit-learn: machine learning in Python – scikit-learn 0.21.3 documentation. scikit-learn. URL: <https://scikit-learn.org/0.21/documentation.html> (дата звернення: 04.06.2025).
5. IBM. What Is Logistic Regression? | IBM. IBM - United States. URL: <https://www.ibm.com/think/topics/logistic-regression> (дата звернення: 04.06.2025).
6. What Is Random Forest?. IBM - United States. URL: <https://www.ibm.com/think/topics/random-forest> (дата звернення: 04.06.2025).
7. Gradient boosting. Wikipedia. URL: https://en.wikipedia.org/wiki/Gradient_boosting (дата звернення: 04.06.2025).
8. XGBoost Documentation – xgboost 3.0.1 documentation. XGBoost. URL: https://xgboost.readthedocs.io/en/release_3.0.0/ (дата звернення: 04.06.2025).

ДОДАТОК А ТЕКСТИ ПРОГРАМНОГО КОДУ

*Тексти програмного коду аналіз комерційного та нагородного
успіху фільмів*

(Найменування програми (документа))

SSD

(Вид носія даних)

14 арк, 64 Кб

(Обсяг програми (документа). арк..)

студента групи ІІІ-33 ІІ курсу

Соколова Олександра Вячеславовича

```

# Імпорт бібліотек
import warnings
warnings.filterwarnings('ignore')

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import xgboost as xgb

from db_config import CONN_STR
from sqlalchemy import create_engine

from sklearn.metrics import mean_squared_error, r2_score, accuracy_score,
f1_score, roc_auc_score, roc_curve, confusion_matrix
from sklearn.ensemble import RandomForestRegressor,
RandomForestClassifier
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split

# Налаштування стилю графіків
plt.style.use('seaborn-v0_8')
%matplotlib inline

# Підключення до PostgreSQL
engine = create_engine(CONN_STR)

# SQL-запит для об'єднання таблиць
query = ""

```

```

SELECT
    m.movie_id, m.title, m.year, m.genre, m.rating, m.runtime_minutes,
m.budget, m.production_company, m.country,
    bo.worldwide, bo.domestic, bo.domestic_percent, bo.foreign,
bo.foreign_percent,
    mp.average_rating, mp.number_of_votes, mp.approval_index,
mp.production_budget, mp.domestic_gross, mp.worldwide_gross,
    CASE WHEN oa.winner IS NOT NULL THEN 1 ELSE 0 END AS
oscar_nominated
FROM main.dim_movie m
LEFT JOIN main.fact_box_office bo ON m.movie_id = bo.movie_id
LEFT JOIN main.fact_movie_performance mp ON m.movie_id =
mp.movie_id
LEFT JOIN main.fact_oscar_awards oa ON m.movie_id = oa.movie_id
""""

# Завантаження даних
df = pd.read_sql(query, engine)

# Огляд структури даних
print("=== Огляд даних ===")
print(df.info())
print("\n=== Перші 5 рядків ===")
print(df.head())

# 1.1 Аналіз розподілу числових ознак
numeric_cols = ['budget', 'worldwide', 'domestic', 'foreign', 'runtime_minutes',
                'average_rating', 'number_of_votes', 'approval_index',
'production_budget',
                'domestic_gross', 'worldwide_gross']

```



```
plt.figure(figsize=(15, 10))
for i, col in enumerate(numeric_cols, 1):
    plt.subplot(4, 3, i)
    sns.histplot(df[col].dropna(), bins=30, kde=True)
    plt.title(f'Розподіл {col}')
    plt.xlabel(col)
    plt.ylabel('Частота')
plt.tight_layout()
plt.show()
```

Boxplot для виявлення викидів

```
plt.figure(figsize=(15, 10))
for i, col in enumerate(numeric_cols, 1):
    plt.subplot(4, 3, i)
    sns.boxplot(y=df[col].dropna())
    plt.title(f'Boxplot {col}')
plt.tight_layout()
plt.show()
```

1.1 Аналіз розподілу категоріальних ознак

```
categorical_cols = ['genre', 'rating', 'country', 'year']
plt.figure(figsize=(15, 10))
for i, col in enumerate(categorical_cols, 1):
    plt.subplot(2, 2, i)
    sns.countplot(y=df[col], order=df[col].value_counts().index[:10])
    plt.title(f'Розподіл {col}')
    plt.xlabel('Кількість')
    plt.ylabel(col)
plt.tight_layout()
plt.show()
```

```
# 1.2 Кореляційний аналіз
```

```
plt.figure(figsize=(12, 8))  
corr = df[numeric_cols].corr()  
sns.heatmap(corr, annot=True, cmap='coolwarm', fmt='.2f')  
plt.title('Теплова карта кореляцій')  
plt.show()
```

```
# Діаграми розсіювання для ключових пар
```

```
plt.figure(figsize=(15, 5))  
plt.subplot(1, 3, 1)  
sns.scatterplot(x='budget', y='worldwide_gross', data=df)  
plt.title('Бюджет vs Світові збори')  
plt.subplot(1, 3, 2)  
sns.scatterplot(x='average_rating', y='worldwide_gross', data=df)  
plt.title('Рейтинг vs Світові збори')  
plt.subplot(1, 3, 3)  
sns.scatterplot(x='number_of_votes', y='worldwide_gross', data=df)  
plt.title('Кількість голосів vs Світові збори')  
plt.tight_layout()  
plt.show()
```

```
# 1.3 Аналіз пропусків
```

```
print("\n=== Відсоток пропусків ===")  
missing = df.isnull().mean() * 100  
print(missing[missing > 0])
```

```
# Візуалізація пропусків
```

```
plt.figure(figsize=(10, 6))  
sns.heatmap(df[numeric_cols].isnull(), cbar=False, cmap='viridis')
```

```

plt.title('Пропуски в числових ознаках')
plt.show()

# 1. Обробка пропусків
# Категоріальні колонки
df['rating'].fillna('R', inplace=True)
df['production_company'].fillna('Unknown', inplace=True)
df['country'].fillna('United States', inplace=True)

# Числові колонки
df['runtime_minutes'].fillna(df['runtime_minutes'].median(), inplace=True)
df['budget'].fillna(df['budget'].median(), inplace=True)

# 2. Кодування категоріальних ознак
# One-hot encoding для genre та rating
df = pd.get_dummies(df, columns=['genre', 'rating'], prefix=['genre', 'rating'])

# Для country: топ-5 країн, решта — 'Other'
top_countries = ['United States', 'United Kingdom', 'France', 'Canada',
'Germany']

df['country'] = df['country'].apply(lambda x: x if x in top_countries else 'Other')
df = pd.get_dummies(df, columns=['country'], prefix='country')

# 3. Вибір ознак
features = ['year', 'runtime_minutes', 'budget'] + \
    [col for col in df.columns if col.startswith('genre_') or
    col.startswith('rating_') or col.startswith('country_')]

# 4. Дані для регресії
df_reg = df[df['worldwide_gross'].notnull()]

```

```
X_reg = df_reg[features]
y_reg = df_reg['worldwide_gross']
X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X_reg, y_reg, test_size=0.2, random_state=42
)
```

5. Дані для класифікації

```
X_class = df[features]
y_class = df['oscar_nominated']
X_train_class, X_test_class, y_train_class, y_test_class = train_test_split(
    X_class, y_class, test_size=0.2, random_state=42
)
```

6. Перевірка виконаної роботи

```
print("\n=== Перевірка виконаної роботи ===")
```

6.1. Перевірка структури даних після кодування

```
print("\nСтруктура DataFrame після кодування:")
print(df.info())
print("\nПерші 5 рядків після кодування:")
print(df.head())
```

6.2. Перевірка обраних ознак

```
print("\nОбрані ознаки для моделювання:")
print(features)
```

6.3. Перевірка розмірів вибірок

```
print("\nРозміри вибірок для регресії:")
print(f'X_train_reg: {X_train_reg.shape}, X_test_reg: {X_test_reg.shape}')
print(f'y_train_reg: {y_train_reg.shape}, y_test_reg: {y_test_reg.shape}')
```

```

print("\nРозміри вибірок для класифікації:")
print(f"X_train_class: {X_train_class.shape}, X_test_class:
{X_test_class.shape}")
print(f"y_train_class: {y_train_class.shape}, y_test_class:
{y_test_class.shape}")

# 6.4. Перевірка розподілу цільових змінних
print("\nРозподіл worldwide_gross у навчальній і тестовій вибірках
(регресія):")
print("Навчальна вибірка:")
print(y_train_reg.describe())
print("Тестова вибірка:")
print(y_test_reg.describe())

print("\nРозподіл oscar_nominated у навчальній і тестовій вибірках
(класифікація):")
print("Навчальна вибірка:")
print(y_train_class.value_counts(normalize=True))
print("Тестова вибірка:")
print(y_test_class.value_counts(normalize=True))

print("\nДані підготовлено для моделювання.")

# Масштабування числових ознак
scaler = StandardScaler()
numeric_features = ['year', 'runtime_minutes', 'budget']
X_train_reg[numeric_features] =
scaler.fit_transform(X_train_reg[numeric_features])

```

```

X_test_reg[numeric_features] =
scaler.transform(X_test_reg[numeric_features])

X_train_class[numeric_features] =
scaler.fit_transform(X_train_class[numeric_features])

X_test_class[numeric_features] =
scaler.transform(X_test_class[numeric_features])

# Функція для оцінки регресійних моделей
def evaluate_regression_model(model, X_train, y_train, X_test, y_test):
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    mse = mean_squared_error(y_test, y_pred)
    r2 = r2_score(y_test, y_pred)
    print(f'MSE: {mse:.2f}, R²: {r2:.2f}')
    return y_pred, mse, r2

# Функція для оцінки класифікаційних моделей
def evaluate_classification_model(model, X_train, y_train, X_test, y_test):
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    y_pred_proba = model.predict_proba(X_test)[: , 1]
    accuracy = accuracy_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)
    roc_auc = roc_auc_score(y_test, y_pred_proba)
    print(f'Accuracy: {accuracy:.2f}, F1-score: {f1:.2f}, ROC-AUC:
{roc_auc:.2f}')
    return y_pred, y_pred_proba, accuracy, f1, roc_auc

# Моделі для регресії
print('=== Регресія ===')

```

```

lin_reg = LinearRegression()
rf_reg = RandomForestRegressor(n_estimators=100, random_state=42)
xgb_reg = xgb.XGBRegressor(objective='reg:squarederror', n_estimators=100,
random_state=42)

print('Лінійна регресія:')
y_pred_lin_reg, mse_lin_reg, r2_lin_reg = evaluate_regression_model(lin_reg,
X_train_reg, y_train_reg, X_test_reg, y_test_reg)
print('Random Forest Regressor:')
y_pred_rf_reg, mse_rf_reg, r2_rf_reg = evaluate_regression_model(rf_reg,
X_train_reg, y_train_reg, X_test_reg, y_test_reg)
print('XGBoost Regressor:')
y_pred_xgb_reg, mse_xgb_reg, r2_xgb_reg =
evaluate_regression_model(xgb_reg, X_train_reg, y_train_reg, X_test_reg,
y_test_reg)

# Моделі для класифікації
print('\n=== Класифікація ===')
log_reg = LogisticRegression(max_iter=1000)
rf_class = RandomForestClassifier(n_estimators=100, random_state=42)
xgb_class = xgb.XGBClassifier(objective='binary:logistic', n_estimators=100,
random_state=42)

print('Логістична регресія:')
y_pred_log_reg, y_pred_proba_log_reg, acc_log_reg, fl_log_reg,
roc_auc_log_reg = evaluate_classification_model(log_reg, X_train_class,
y_train_class, X_test_class, y_test_class)
print('Random Forest Classifier:')

```

```

y_pred_rf_class, y_pred_proba_rf_class, acc_rf_class, fl_rf_class,
roc_auc_rf_class = evaluate_classification_model(rf_class, X_train_class,
y_train_class, X_test_class, y_test_class)

print('XGBoost Classifier:')

y_pred_xgb_class, y_pred_proba_xgb_class, acc_xgb_class, fl_xgb_class,
roc_auc_xgb_class = evaluate_classification_model(xgb_class, X_train_class,
y_train_class, X_test_class, y_test_class)

```

```

# Візуалізація для регресії
plt.figure(figsize=(15, 5))
plt.subplot(1, 3, 1)
plt.scatter(y_test_reg, y_pred_lin_reg, alpha=0.5)
plt.xlabel('Фактичні значення')
plt.ylabel('Прогнозовані значення')
plt.title('Лінійна регресія')

plt.subplot(1, 3, 2)
plt.scatter(y_test_reg, y_pred_rf_reg, alpha=0.5)
plt.xlabel('Фактичні значення')
plt.ylabel('Прогнозовані значення')
plt.title('Random Forest Regressor')

plt.subplot(1, 3, 3)
plt.scatter(y_test_reg, y_pred_xgb_reg, alpha=0.5)
plt.xlabel('Фактичні значення')
plt.ylabel('Прогнозовані значення')
plt.title('XGBoost Regressor')

plt.tight_layout()
plt.show()

```

```

# Візуалізація для класифікації (ROC-криві)
plt.figure(figsize=(10, 8))

```



```

fpr, tpr, _ = roc_curve(y_test_class, y_pred_proba_log_reg)
plt.plot(fpr, tpr, label='Логістична регресія')
fpr, tpr, _ = roc_curve(y_test_class, y_pred_proba_rf_class)
plt.plot(fpr, tpr, label='Random Forest Classifier')
fpr, tpr, _ = roc_curve(y_test_class, y_pred_proba_xgb_class)
plt.plot(fpr, tpr, label='XGBoost Classifier')
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC-криві')
plt.legend()
plt.show()

# Важливість ознак для Random Forest Regressor
importances = rf_reg.feature_importances_
indices = np.argsort(importances)[::-1]
plt.figure(figsize=(12, 6))
plt.title('Важливість ознак (Random Forest Regressor)')
plt.bar(range(X_train_reg.shape[1]), importances[indices], align='center')
plt.xticks(range(X_train_reg.shape[1]), X_train_reg.columns[indices],
rotation=90)
plt.show()

# Важливість ознак для XGBoost Classifier
importances = xgb_class.feature_importances_
indices = np.argsort(importances)[::-1]
plt.figure(figsize=(12, 6))
plt.title('Важливість ознак (XGBoost Classifier)')
plt.bar(range(X_train_class.shape[1]), importances[indices], align='center')

```

```

plt.xticks(range(X_train_class.shape[1]), X_train_class.columns[indices],
rotation=90)

plt.show()

# Матриці невідповідностей для класифікації
plt.figure(figsize=(15, 5))
cm_log_reg = confusion_matrix(y_test_class, y_pred_log_reg)
plt.subplot(1, 3, 1)
sns.heatmap(cm_log_reg, annot=True, fmt='d', cmap='Blues')
plt.title('Матриця невідповідностей (Логістична регресія)')
plt.xlabel('Прогнозовані')
plt.ylabel('Фактичні')
cm_rf_class = confusion_matrix(y_test_class, y_pred_rf_class)
plt.subplot(1, 3, 2)
sns.heatmap(cm_rf_class, annot=True, fmt='d', cmap='Blues')
plt.title('Матриця невідповідностей (Random Forest Classifier)')
plt.xlabel('Прогнозовані')
plt.ylabel('Фактичні')
cm_xgb_class = confusion_matrix(y_test_class, y_pred_xgb_class)
plt.subplot(1, 3, 3)
sns.heatmap(cm_xgb_class, annot=True, fmt='d', cmap='Blues')
plt.title('Матриця невідповідностей (XGBoost Classifier)')
plt.xlabel('Прогнозовані')
plt.ylabel('Фактичні')
plt.tight_layout()
plt.show()

# Порівняння моделей: Стовпчасті діаграми для регресії
plt.figure(figsize=(12, 6))
models_reg = ['Лінійна регресія', 'Random Forest', 'XGBoost']

```

```

mse_values = [mse_lin_reg, mse_rf_reg, mse_xgb_reg]
r2_values = [r2_lin_reg, r2_rf_reg, r2_xgb_reg]

plt.subplot(1, 2, 1)
plt.bar(models_reg, mse_values, color=['blue', 'green', 'red'])
plt.title('Порівняння MSE (Регресія)')
plt.ylabel('MSE')
plt.yscale('log') # Логарифмічна шкала для кращої видимості

plt.subplot(1, 2, 2)
plt.bar(models_reg, r2_values, color=['blue', 'green', 'red'])
plt.title('Порівняння R2 (Регресія)')
plt.ylabel('R2')
plt.ylim(0, 1) # Обмеження до діапазону [0, 1] для R2
plt.tight_layout()
plt.show()

# Порівняння моделей: Стовпчасті діаграми для класифікації
plt.figure(figsize=(15, 5))
models_class = ['Логістична регресія', 'Random Forest', 'XGBoost']
acc_values = [acc_log_reg, acc_rf_class, acc_xgb_class]
f1_values = [f1_log_reg, f1_rf_class, f1_xgb_class]
roc_auc_values = [roc_auc_log_reg, roc_auc_rf_class, roc_auc_xgb_class]

plt.subplot(1, 3, 1)
plt.bar(models_class, acc_values, color=['blue', 'green', 'red'])
plt.title('Порівняння Accuracy (Класифікація)')
plt.ylabel('Accuracy')
plt.ylim(0, 1)

```

```
plt.subplot(1, 3, 2)
```

```
plt.bar(models_class, f1_values, color=['blue', 'green', 'red'])
```

```
plt.title('Порівняння F1-score (Класифікація)')
```

```
plt.ylabel('F1-score')
```

```
plt.ylim(0, 1)
```

```
plt.subplot(1, 3, 3)
```

```
plt.bar(models_class, roc_auc_values, color=['blue', 'green', 'red'])
```

```
plt.title('Порівняння ROC-AUC (Класифікація)')
```

```
plt.ylabel('ROC-AUC')
```

```
plt.ylim(0, 1)
```

```
plt.tight_layout()
```

```
plt.show()
```