



Міністерство освіти та науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря
Сікорського» Факультет інформатики та обчислювальної
техніки
Кафедра інформатики і програмної інженерії

Звіт
з дисципліни «Аналіз даних в інформаційних системах»
Лабораторні роботи №1-2
"Створення процедур завантаження даних"

Виконав:

Студент II курсу
гр. ІП-33
Соколов О. В.

Перевірів:

Олійник Ю. О.

Лабораторні роботи № 1-2.

Створення процедур завантаження даних

Мета

Ознайомитись з підходами до створення сховищ даних; знайти дані для курсової роботи. ER-моделі предметної області (діаграм «Сутність-Зв'язок»)

Постановка задачі

При виконанні лабораторної роботи необхідно виконати наступні дії:

- 1) Самостійно обрати не менше 3-х джерел/файлів відкритих даних. У цілому в джерелах/файлах мають бути спільні 2+ виміри (наприклад, країни, континенти та роки) та сховище повинно містити не менше 5 вимірів;
- 2) Спроекувати модель сховища даних та Stage зони для ETL процесів;
- 3) Створити ETL засоби:
 - а. завантажити дані до Stage зони;
 - б. створити набір процедур/функцій для перетворення та завантаження даних до основного сховища (або створити засобами програмних ETL засобів);
 - с. передбачити можливість завантаження змінених та додаткових даних.

Виконання

Для виконання лабораторної роботи було обрано декілька наборів даних з сайту <https://www.kaggle.com/>, які пов'язані з індустрією кіно-фільмів.

Опис джерел даних

Файл movies.csv містить інформацію про 6820 фільмів випущених в 1986-2016 роках, 220 фільмів на кожен рік. Джерело: <https://www.kaggle.com/danielgrijalvas/movies>.

Таблиця 1.1 – Структура movies.csv

Назва поля	Призначення
name	Name of the movie
budget	The budget of a movie
company	The production company
country	Country of origin
director	The director
genre	Main genre of the movie.
gross	Revenue of the movie
rating	Rating of the movie (R, PG, etc.)
released	Release date (YYYY-MM-DD)
runtime	Duration of the movie
score	Imdb user rating
votes	Number of user votes
star	Main actor/actress
writer	Writer of the movie
year	Year of release

Файл the_oscar_award.csv містить інформацію про результати конкурсу «Оскар» з 1927 по 2025 роки. Джерело: <https://www.kaggle.com/datasets/unanimad/the-oscar-award>.

Таблиця 1.2 – Структура the_oscar_award.csv

Назва поля	Призначення
year_film	Film screened at
year_ceremony	Ceremony happened at
ceremony	Number of ceremony
category	Name of the category (as per official nomination)
canon_category	Name of the category, consistent across years
name	Slash separated names of the nominees
film	Film's title
winner	True if winner

Файли “2000-2009 Movies Box Office Collection.csv”, “2010-2024 Movies Box Office Collection.csv” і “2024 Movies Box Office Collection.csv” містять інформацію про касові збори фільмів з 2000 по 2024 роки відповідно. Джерело: <https://www.kaggle.com/datasets/parthdande/movies-box-office-collection-data-2000-2024>.

Таблиця 1.3 – Структура файлів “Movies Box Office Collection”

Назва поля	Призначення
Rank	Rank of a film
Release Group	Name of a film
Worldwide	Worldwide revenue
Domestic	The total earnings (in USD) from the domestic market (e.g., United States)
Domestic_percent	The percentage of the movie's total revenue that was earned domestically.
Foreign	The total earnings (in USD) from international markets (outside the domestic market)
Foreign_percent	The percentage of the movie's total revenue that was earned from foreign markets.
year	The release year of the movie.

Файл «movie_statistic_dataset.csv» містить загальну інформацію про фільм, режисера, бюджет. Джерело: <https://www.kaggle.com/datasets/alessandrolobello/the-ultimate-film-statistics-dataset-for-ml>.

Таблиця 1.4 – Структура файлу “movie_statistic_dataset.csv”

Назва поля	Призначення
Movie_title	Movie name
Production_date	Date of production
Genres	Genres
Runtime_minutes	Runtime in minutes
Director_name (primaryName)	Name of the director
Director_professions (primaryProfession)	Director professions
Director_birthYear	Director year of birth
Director_deathYear	Director year of death
Movie_averageRating	Average rating
Movie_numberOfVotes	Number of votes
Approval_Index	Is a normalized indicator (on scale 0-10) calculated by multiplying the logarithm of the number of
Production_budget	Production budget in \$
Domestic_gross	Domestic gross in \$
Worldwide_gross	Worldwide gross in \$

Підготовка даних

Для зручної подальшої роботи з даними, було створено нові csv файли на основі обраних наборів даних. Зміни, які були зроблені:

Очищення колонок в наборах даних:

1. Box Office:
 - a. Видалення колонки "Rank".
 - b. Очищення колонок Worldwide, Domestic, Foreign: видалення ком, перетворення значень на числа.
 - c. Очищення колонок Domestic_percent та Foreign_percent: видалення знаків %, заміна <0.1 на 0, перетворення значень на десяткові числа (ділення на 100).

- d. Перетворення значення року (year) в ціле число.
 - e. Перейменування колонок для узгодження з базою даних.
2. Movies:
- a. Очищення колонок score та votes (перетворення на числові значення, заміна помилок на NaN).
 - b. Очищення колонок budget та gross (перетворення на числові значення).
 - c. Очищення колонки runtime (перетворення на числове значення).
 - d. Обробка дат випуску (вилучення формату дати і перетворення в datetime).
 - e. Видалення рядків без дат випуску.
 - f. Перетворення року на ціле число.
3. Oscar Awards:
- a. Видалення рядків з відсутніми значеннями.
 - b. Перетворення колонок year_film, year_ceremony та ceremony в цілі числа.
 - c. Перетворення колонки winner в булевий тип.
4. Movie Budget:
- a. Перейменування колонок для узгодження з базою даних.
 - b. Очищення колонок runtime_minutes, movie_average_rating, movie_number_of_votes, approval_index, production_budget, domestic_gross, worldwide_gross (перетворення на числові значення, заміна помилок на NaN).
 - c. Очищення дати виробництва (production_date), перетворення на datetime.
 - d. Очищення колонок director_birth_year та director_death_year, заміна недійсних значень на NaN.
 - e. Перетворення колонок director_birth_year та director_death_year на цілі числа.
 - f. Форматування колонок director_professions та genres у відповідний формат для бази даних (масиви).
 - g. Заміна недійсних значень на NaN.

Код скрипту:

```
import pandas as pd
import os
```

```
os.makedirs("da_lab1/clean_data", exist_ok=True)
```

```

def clean_box_office_data(file_path, output_path):
    """Clean specific columns in the box office dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df = df.drop(columns=["Rank"])

    df["Worldwide"] = df["Worldwide"].replace({" ": ""},
regex=True).astype(float)
    df["Domestic"] = df["Domestic"].replace({" ": ""},
regex=True).astype(float)
    df["Foreign"] = df["Foreign"].replace({" ": ""},
regex=True).astype(float)

    df["Domestic_percent"] = (
        df["Domestic_percent"]
        .replace({" ": "", "%": "", "<0.1": "0"}, regex=True)
        .astype(float)
        / 100
    )
    df["Foreign_percent"] = (
        df["Foreign_percent"]
        .replace({" ": "", "%": "", "<0.1": "0"}, regex=True)
        .astype(float)
        / 100
    )

    df["year"] = df["year"].astype(int)

    df = df.rename(
        columns={
            "Release Group": "release_group",
            "Worldwide": "worldwide",
            "Domestic": "domestic",
            "Domestic_percent": "domestic_percent",
            "Foreign": "foreign",
            "Foreign_percent": "foreign_percent",
            "year": "year",
        }
    )

    df.to_csv(output_path, index=False)
    print(f"✅ Cleaned data saved to {output_path}")

```

```

def clean_movie_data(file_path, output_path):
    """Clean specific columns in the movie dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df["score"] = pd.to_numeric(df["score"], errors="coerce")

    df["votes"] = (
        df["votes"]
        .apply(lambda x: int(float(x)) if pd.notnull(x) else None)
        .astype(pd.Int64Dtype())
    )

    df["budget"] = pd.to_numeric(df["budget"], errors="coerce")
    df["gross"] = pd.to_numeric(df["gross"], errors="coerce")

    df["runtime"] = pd.to_numeric(df["runtime"], errors="coerce")

    df["released"] = df["released"].str.extract(r"([a-zA-Z]+)\s\d{1,2},\s\d{4}")
    df["released"] = pd.to_datetime(df["released"],
    errors="coerce")

    df = df.dropna(subset=["released"])

    df["year"] = df["year"].astype(int)

    df.to_csv(output_path, index=False)
    print(f"✅ Cleaned data saved to {output_path}")

```

```

def clean_oscar_award_data(file_path, output_path):
    """Clean specific columns in the oscar award dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df = df.dropna()

    df["year_film"] = df["year_film"].astype(int)
    df["year_ceremony"] = df["year_ceremony"].astype(int)

```



```

df["ceremony"] = df["ceremony"].astype(int)

df["winner"] = df["winner"].astype(bool)

df.to_csv(output_path, index=False)
print(f"✅ Cleaned data saved to {output_path}")

def clean_movie_budget_data(file_path, output_path):
    """Clean specific columns in the movie budget dataset."""
    print(f"Processing {file_path}...")

    df = pd.read_csv(file_path)

    df = df.rename(
        columns={
            "movie_title": "movie_title",
            "production_date": "production_date",
            "genres": "genres",
            "runtime_minutes": "runtime_minutes",
            "director_name": "director_name",
            "director_professions": "director_professions",
            "director_birthYear": "director_birth_year",
            "director_deathYear": "director_death_year",
            "movie_averageRating": "movie_average_rating",
            "movie_numOfVotes": "movie_number_of_votes",
            "approval_Index": "approval_index",
            "Production budget $": "production_budget",
            "Domestic gross $": "domestic_gross",
            "Worldwide gross $": "worldwide_gross",
        }
    )

    df["runtime_minutes"] = pd.to_numeric(df["runtime_minutes"],
errors="coerce")
    df["movie_average_rating"] = pd.to_numeric(
        df["movie_average_rating"], errors="coerce"
    )
    df["movie_number_of_votes"] = pd.to_numeric(
        df["movie_number_of_votes"], errors="coerce"
    ).astype("Int64")
    df["approval_index"] = pd.to_numeric(df["approval_index"],
errors="coerce")

```

```

df["production_budget"] =
pd.to_numeric(df["production_budget"], errors="coerce")
df["domestic_gross"] = pd.to_numeric(df["domestic_gross"],
errors="coerce")
df["worldwide_gross"] = pd.to_numeric(df["worldwide_gross"],
errors="coerce")

df["production_date"] = pd.to_datetime(df["production_date"],
errors="coerce")

df["director_birth_year"] = df["director_birth_year"].replace(
    ["-", "\\N", "alive"], pd.NA
)
df["director_death_year"] = df["director_death_year"].replace(
    ["-", "\\N", "alive"], pd.NA
)

df["director_birth_year"] =
df["director_birth_year"].astype(pd.Int64Dtype())
df["director_death_year"] =
df["director_death_year"].astype(pd.Int64Dtype())

df["director_professions"] = df["director_professions"].apply(
    lambda x: "{" + x.replace(",", " ") + "}" if pd.notnull(x)
else None
)

df["genres"] = df["genres"].apply(
    lambda x: "{" + ",".join(x.split(",")) + "}" if
pd.notnull(x) else None
)

df.replace({"-": pd.NA, "{-}": pd.NA}, inplace=True)

df.to_csv(output_path, index=False)
print(f"✅ Cleaned data saved to {output_path}")

clean_box_office_data(
    "da_lab1/data/box_office.csv",
    "da_lab1/clean_data/box_office.csv"
)

```

```
clean_movie_data("da_lab1/data/movies.csv",  
"da_lab1/clean_data/movies.csv")
```

```
clean_oscar_award_data(  
    "da_lab1/data/oscar_award.csv",  
    "da_lab1/clean_data/oscar_award.csv"  
)
```

```
clean_movie_budget_data(  
    "da_lab1/data/movie_budget.csv",  
    "da_lab1/clean_data/movie_budget.csv"  
)
```

```
print("✅ Data cleaning complete! Cleaned files are in  
'clean_data/'")
```





Рис. 2.1 – Діаграма сутностей stage зони

Таблиця **box_office** містить:

1. **id** — це автоматично збільшуване ціле число (SERIAL), яке використовується як первинний ключ для ідентифікації кожного запису.
2. **release_group** — текстове поле (TEXT), яке зберігає назву групи фільмів або франшизи, до якої належить фільм.
3. **worldwide** — числове поле (NUMERIC(15, 2)), яке містить загальні світові збори фільму в доларах США.
4. **domestic** — числове поле (NUMERIC(15, 2)), яке містить суму зборів фільму в домашньому (вітчизняному) ринку (наприклад, США).
5. **domestic_percent** — числове поле (NUMERIC(5, 2)), яке відображає відсоток зборів фільму, отриманих на вітчизняному ринку.

6. `foreign` — числове поле (`NUMERIC(15, 2)`), яке містить збори фільму на міжнародному ринку.
7. `foreign_percent` — числове поле (`NUMERIC(5, 2)`), яке відображає відсоток зборів фільму, отриманих на міжнародному ринку.
8. `year` — ціле число (`INTEGER`), яке містить рік випуску фільму.

Таблиця `movie_budget` містить:

1. `id` — це автоматично збільшуване ціле число (`SERIAL`), яке використовується як первинний ключ для ідентифікації кожного запису.
2. `movie_title` — текстове поле (`TEXT`), яке містить назву фільму.
3. `production_date` — дата (`DATE`), яка вказує на дату виробництва фільму.
4. `genres` — текстове поле (`TEXT`), яке містить жанри фільму, розділені комами.
5. `runtime_minutes` — числове поле (`NUMERIC(5, 1)`), яке вказує тривалість фільму в хвилинали.
6. `director_name` — текстове поле (`TEXT`), яке зберігає ім'я режисера фільму.
7. `director_professions` — масив текстових значень (`TEXT[]`), який містить професії режисера (наприклад, режисер, продюсер тощо).
8. `director_birth_year` — ціле число (`INTEGER`), яке вказує рік народження режисера.
9. `director_death_year` — ціле число (`INTEGER`), яке вказує рік смерті режисера (якщо застосовно).
10. `movie_average_rating` — числове поле (`NUMERIC(3, 1)`), яке містить середній рейтинг фільму.
11. `movie_number_of_votes` — велике ціле число (`BIGINT`), яке містить кількість голосів за фільм.
12. `approval_index` — числове поле (`NUMERIC(5, 2)`), яке є індексом схвалення фільму, розрахованим як логарифм кількості голосів, помножений на середній рейтинг.
13. `production_budget` — числове поле (`NUMERIC(15, 2)`), яке містить бюджет виробництва фільму в доларах.

14. `domestic_gross` — числове поле (`NUMERIC(15, 2)`), яке містить збори фільму на вітчизняному ринку в доларах.

15. `worldwide_gross` — числове поле (`NUMERIC(15, 2)`), яке містить збори фільму на світовому рівні в доларах.

Таблиця `movies` містить:

1. `id` — це автоматично збільшуване ціле число (`SERIAL`), яке використовується як первинний ключ для ідентифікації кожного запису.

2. `name` — текстове поле (`TEXT`), яке містить назву фільму.

3. `rating` — текстове поле (`TEXT`), яке вказує рейтинг фільму (наприклад, R, PG тощо).

4. `genre` — текстове поле (`TEXT`), яке містить основний жанр фільму.

5. `year` — ціле число (`INTEGER`), яке містить рік випуску фільму.

6. `released` — дата (`DATE`), яка вказує на дату виходу фільму.

7. `score` — числове поле (`NUMERIC(3, 1)`), яке вказує оцінку фільму на IMDb.

8. `votes` — велике ціле число (`BIGINT`), яке містить кількість голосів на IMDb.

9. `director` — текстове поле (`TEXT`), яке містить ім'я режисера фільму.

10. `writer` — текстове поле (`TEXT`), яке містить ім'я сценариста фільму.

11. `star` — текстове поле (`TEXT`), яке містить ім'я головного актора чи актриси.

12. `country` — текстове поле (`TEXT`), яке містить країну виробництва фільму.

13. `budget` — числове поле (`NUMERIC(15, 2)`), яке містить бюджет фільму (може бути нульовим, якщо не вказано).

14. `gross` — числове поле (`NUMERIC(15, 2)`), яке містить загальні збори фільму.

15. `company` — текстове поле (`TEXT`), яке містить назву компанії, яка виробила фільм.

16. runtime — числове поле (NUMERIC(5, 1)), яке містить тривалість фільму в хвилинах.

Таблиця oscar_awards містить:

- id — це автоматично збільшуване ціле число (SERIAL), яке використовується як первинний ключ для ідентифікації кожного запису.
- year_film — ціле число (INTEGER), яке вказує рік, у якому фільм був випущений.
- year_ceremony — ціле число (INTEGER), яке вказує рік церемонії вручення Оскарів.
- ceremony — ціле число (INTEGER), яке вказує на номер церемонії.
- category — текстове поле (TEXT), яке містить назву категорії нагороди.
- canon_category — текстове поле (TEXT), яке містить стандартну назву категорії, яка використовується на всіх церемоніях.
- name — текстове поле (TEXT), яке містить імена номінантів, розділені слешем.
- film — текстове поле (TEXT), яке містить назву фільму, який був номінований.
- winner — булеве значення (BOOLEAN), яке вказує, чи виграв фільм в цій категорії.

Код створення stage зони:

```
CREATE SCHEMA IF NOT EXISTS staging;
```

```
CREATE TABLE staging.box_office
(
    id SERIAL PRIMARY KEY,
    release_group TEXT NOT NULL,
    worldwide NUMERIC(15, 2) NOT NULL,
    domestic NUMERIC(15, 2) NOT NULL,
    domestic_percent NUMERIC(5, 2) NOT NULL,
    "foreign" NUMERIC(15, 2) NOT NULL,
    foreign_percent NUMERIC(5, 2) NOT NULL,
    year INTEGER NOT NULL
);
```

```
CREATE TABLE staging.movie_budget
(
    id SERIAL PRIMARY KEY,
    movie_title TEXT NOT NULL,
    production_date DATE NOT NULL,
    genres TEXT NOT NULL,
    runtime_minutes NUMERIC(5, 1) NOT NULL,
    director_name TEXT NULL,
    director_professions TEXT[],
    director_birth_year INTEGER NULL,
    director_death_year INTEGER NULL,
    movie_average_rating NUMERIC(3, 1) NOT NULL,
    movie_number_of_votes BIGINT NOT NULL,
    approval_index NUMERIC(5, 2) NOT NULL,
    production_budget NUMERIC(15, 2) NOT NULL,
    domestic_gross NUMERIC(15, 2) NOT NULL,
    worldwide_gross NUMERIC(15, 2) NOT NULL
);
```

```
CREATE TABLE staging.movies
(
    id SERIAL PRIMARY KEY,
    name TEXT NOT NULL,
    rating TEXT NULL,
    genre TEXT NOT NULL,
    year INTEGER NOT NULL,
    released DATE NOT NULL,
    score NUMERIC(3, 1) NULL,
```

```

votes      BIGINT          NULL,
director   TEXT            NULL,
writer     TEXT            NULL,
star       TEXT            NULL,
country    TEXT            NULL,
budget     NUMERIC(15, 2)  NULL,
gross      NUMERIC(15, 2)  NULL,
company    TEXT            NULL,
runtime    NUMERIC(5, 1)   NULL
);

CREATE TABLE staging.oscar_awards
(
    id          SERIAL PRIMARY KEY,
    year_film   INTEGER NOT NULL,
    year_ceremony INTEGER NOT NULL,
    ceremony    INTEGER NOT NULL,
    category    TEXT     NOT NULL,
    canon_category TEXT   NOT NULL,
    name        TEXT     NOT NULL,
    film        TEXT     NOT NULL,
    winner      BOOLEAN NOT NULL
);

```

Заповнення stage зони

```
COPY staging.box_office (release_group, worldwide, domestic,  
domestic_percent, "foreign", foreign_percent, year)  
FROM '/private/tmp/box_office.csv' DELIMITER ',' CSV HEADER;
```

```
COPY staging.movies (name, rating, genre, year, released, score,  
votes, director, writer, star, country, budget, gross, company,  
runtime)  
FROM '/private/tmp/movies.csv' DELIMITER ',' CSV HEADER;
```

```
COPY staging.oscar_awards(year_film, year_ceremony, ceremony,  
category, canon_category, name, film, winner)  
FROM '/private/tmp/oscar_award.csv' DELIMITER ',' CSV HEADER;
```

```
COPY staging.movie_budget (movie_title, production_date, genres,  
runtime_minutes, director_name, director_professions,  
director_birth_year, director_death_year, movie_average_rating,  
movie_number_of_votes, approval_index, production_budget,  
domestic_gross, worldwide_gross)  
FROM '/private/tmp/movie_budget.csv' DELIMITER ',' CSV HEADER;
```

	1	2	3	4	5	6	7	8
id	1	2	3	4	5	6	7	8
release_group	Mission: Impossible II	Gladiator	Cast Away	What Women Want	Dinosaur	How the Grinch Stole Christmas	Meet the Parents	The Perfection
worldwide	546388108.00	460583960.00	429632142.00	374111707.00	349822765.00	345842198.00	330444045.00	328718430.00
domestic	215409889.00	187705427.00	233632142.00	182811707.00	137748063.00	260745620.00	166244045.00	182618430.00
domestic_percent	0.39	0.41	0.54	0.49	0.39	0.75	0.50	0.56
foreign	330978219.00	272878533.00	196000000.00	191300000.00	212074702.00	85096578.00	164200000.00	146100000.00
foreign_percent	0.61	0.59	0.46	0.51	0.61	0.25	0.50	0.44
year	2000	2000	2000	2000	2000	2000	2000	2000

Рис. 3.1 – Таблиця stage зони box_office

	1	2	3	4	5
id	1	2	3	4	5
movie_title	Avatar: The Way of Water	Avengers: Endgame	Pirates of the Caribbean: On Stranger Tides	Avengers: Age of Ultron	Avengers
production_date	2022-12-09	2019-04-23	2011-05-20	2015-04-22	2018-04-
genres	{Action,Adventure,Fantasy}	{Action,Adventure,Drama}	{Action,Adventure,Fantasy}	{Action,Adventure,Sci-Fi}	{Action,
runtime_minutes	192.0	181.0	137.0	141.0	149.0
director_name	James Cameron	<null>	Rob Marshall	Joss Whedon	<null>
director_professions	{writer,producer,director}	<null>	{director,miscellaneous,producer}	{writer,producer,director}	<null>
director_birth_year	1954	<null>	1968	1964	<null>
director_death_year	<null>	<null>	<null>	<null>	<null>
movie_average_rating	7.8	8.4	6.6	7.3	8.4
movie_number_of_votes	277543	1143642	533763	878573	1091968
approval_index	7.06	8.49	6.27	7.21	8.46
production_budget	460000000.00	400000000.00	379000000.00	365000000.00	300000000.00
domestic_gross	667830256.00	858373000.00	241071802.00	459005868.00	67881548
worldwide_gross	2265935552.00	2794731755.00	1045713802.00	1395316979.00	20483597

Рис. 3.2 – Таблица stage зоны movie_budget

	1	2	3	4	5	6	7
id	80	81	82	83	84	85	86
name	The Shining	The Blue Lagoon	Star Wars: Episode V – The Empire Strikes Back	Airplane!	Caddyshack	Friday the 13th	The E
rating	R	R	PG	PG	R	R	R
genre	Drama	Adventure	Action	Comedy	Comedy	Horror	Action
year	1980	1980	1980	1980	1980	1980	1980
released	1980-06-13	1980-07-02	1980-06-20	1980-07-02	1980-07-25	1980-05-09	1980-
score	8.4	5.8	8.7	7.7	7.3	6.4	7.9
votes	927000	65000	1200000	221000	108000	123000	18800
director	Stanley Kubrick	Randal Kleiser	Irvin Kershner	Jim Abrahams	Harold Ramis	Sean S. Cunningham	John
writer	Stephen King	Henry De Vere Stacpoole	Leigh Brackett	Jim Abrahams	Brian Doyle-Murray	Victor Miller	Dan A
star	Jack Nicholson	Brooke Shields	Mark Hamill	Robert Hays	Chevy Chase	Betsy Palmer	John
country	United Kingdom	United States	United States	United Stat.	United States	United States	United
budget	19000000.00	4500000.00	18000000.00	3500000.00	6000000.00	550000.00	27000
gross	46998772.00	58853106.00	538375067.00	83453539.00	39846344.00	39754601.00	11522
company	Warner Bros.	Columbia Pictures	Lucasfilm	Paramount P.	Orion Pictures	Paramount Pictures	Unive
runtime	146.0	104.0	124.0	88.0	98.0	95.0	133.0

Рис. 3.3 – Таблица stage зоны movies

	1	2	3	4	5	6
id	1	2	3	4	5	6
year_film	1927	1927	1927	1927	1927	1927
year_ceremony	1928	1928	1928	1928	1928	1928
ceremony	1	1	1	1	1	1
category	ACTOR	ACTOR	ACTOR	ACTOR	ACTRESS	ACTRESS
canon_category	ACTOR IN A LEADING ROLE	ACTOR IN A LEADING ROLE	ACTOR IN A LEADING ROLE	ACTOR IN A LEADING ROLE	ACTRESS IN A LEADING ROLE	ACTRESS IN A LEADING ROLE
name	Richard Barthelmess	Richard Barthelmess	Emil Jannings	Emil Jannings	Louise Dresser	Janet Gaynor
film	The Noose	The Patent Leather Kid	The Last Command	The Way of All Flesh	A Ship Comes In	7th Heaven
winner	false	false	true	true	false	true

Рис. 3.4 – Таблиця stage зони oscar_awards

Дані було успішно завантажено до stage зони.

Модель основного сховища




Рис. 4.1 – Діаграма сутностей main зони

Таблиця dim_movie:

Це таблиця виміру, яка містить основну інформацію про фільми. Вона використовується для зберігання атрибутів фільмів, таких як назва, жанр, рік випуску, бюджет та країна виробництва. Вона дозволяє проводити аналіз фільмів за різними характеристиками, такими як жанр або рік випуску.

Таблиця dim_director:

Це таблиця виміру, яка містить інформацію про режисерів фільмів. Вона дозволяє пов'язувати фільми з їх режисерами та здійснювати аналіз на основі кар'єри та впливу режисера на успіх фільму. Ця таблиця також містить дані про професії режисера.

Таблиця dim_oscar_category:

Це таблиця виміру, яка зберігає категорії нагород Оскара. Вона допомагає класифікувати фільми за номінаціями та дозволяє аналізувати результати Оскарів у різних категоріях.

Таблиця dim_star:

Це таблиця виміру, яка містить інформацію про акторів, що знімалися у фільмах. Вона дозволяє встановлювати зв'язки між фільмами та акторами для аналізу їх впливу на популярність фільмів.

Таблиця dim_writer:

Це таблиця виміру, яка зберігає дані про сценаристів фільмів. Вона дозволяє здійснювати аналіз творчості сценаристів та їхнього впливу на успіх фільмів.

Таблиця fact_box_office:

Це фактова таблиця, яка містить дані про касові збори фільмів. Вона містить інформацію про збори на внутрішньому ринку, міжнародному ринку, а також відсоткове співвідношення цих зборів до загальних доходів фільму. Ця таблиця є основним джерелом для аналізу фінансового успіху фільмів.

Таблиця fact_movie_performance:

Це фактова таблиця, яка зберігає дані про продуктивність фільмів, включаючи середній рейтинг, кількість голосів, індекс схвалення, а також бюджет і збори. Вона дозволяє оцінити успішність фільму з точки зору аудиторії та фінансів.

Таблиця fact_oscar_awards:

Це фактова таблиця, яка містить дані про нагороди Оскара. Вона зберігає інформацію про переможців та номінантів у різних категоріях на кожній церемонії Оскара. Ця таблиця дозволяє аналізувати успіх фільмів у різних номінаціях та церемоніях.

Таблиця movie_stars:

Це таблиця зв'язку, яка відображає зв'язки між фільмами та акторами. Вона дозволяє здійснювати аналіз впливу конкретних акторів на успіх фільмів та взаємодію між фільмами та їх зірками.

Таблиця movie_writers:

Це таблиця зв'язку, яка зберігає зв'язки між фільмами та сценаристами. Вона дозволяє досліджувати взаємозв'язок між сценаристами та фільмами, які вони написали.

Код створення main зони:

```
CREATE SCHEMA IF NOT EXISTS main;
```

```
CREATE TABLE main.dim_movie
(
    movie_id          SERIAL PRIMARY KEY,
    title             TEXT      NOT NULL,
    release_date      DATE      NOT NULL,
    year              INTEGER    NOT NULL,
    genre             TEXT      NOT NULL,
    rating            TEXT      NULL,
    runtime_minutes   NUMERIC(5, 1) NULL,
    budget            NUMERIC(15, 2) NULL,
    production_company TEXT      NULL,
    country           TEXT      NULL
);
```

```
CREATE TABLE main.dim_director
(
    director_id SERIAL PRIMARY KEY,
    name        TEXT      NOT NULL,
    birth_year  INTEGER NULL,
    death_year  INTEGER NULL,
    professions TEXT[]  NULL
);
```



```
);
```

```
CREATE TABLE main.dim_oscar_category
```

```
(  
    category_id    SERIAL PRIMARY KEY,  
    category       TEXT NOT NULL,  
    canon_category TEXT NOT NULL  
);
```

```
CREATE TABLE main.dim_star
```

```
(  
    star_id SERIAL PRIMARY KEY,  
    name    TEXT NOT NULL  
);
```

```
CREATE TABLE main.dim_writer
```

```
(  
    writer_id SERIAL PRIMARY KEY,  
    name      TEXT NOT NULL  
);
```

```
CREATE TABLE main.fact_box_office
```

```
(  
    fact_id          SERIAL PRIMARY KEY,  
    movie_id         INTEGER REFERENCES main.dim_movie  
(movie_id),  
    worldwide        NUMERIC(15, 2) NOT NULL,  
    domestic          NUMERIC(15, 2) NOT NULL,  
    domestic_percent  NUMERIC(5, 2)  NOT NULL,  
    "foreign"        NUMERIC(15, 2) NOT NULL,  
    foreign_percent   NUMERIC(5, 2)  NOT NULL,  
    year             INTEGER          NOT NULL  
);
```

```
CREATE TABLE main.fact_movie_performance
```

```
(  
    fact_id          SERIAL PRIMARY KEY,  
    movie_id         INTEGER REFERENCES main.dim_movie  
(movie_id),  
    director_id      INTEGER REFERENCES main.dim_director  
(director_id),  
    average_rating    NUMERIC(3, 1)  NOT NULL,  
    number_of_votes   BIGINT          NOT NULL,  
    approval_index    NUMERIC(5, 2)  NOT NULL,
```

```

        production_budget NUMERIC(15, 2) NOT NULL,
        domestic_gross    NUMERIC(15, 2) NOT NULL,
        worldwide_gross   NUMERIC(15, 2) NOT NULL
    );

CREATE TABLE main.fact_oscar_awards
(
    fact_id          SERIAL PRIMARY KEY,
    movie_id         INTEGER REFERENCES main.dim_movie (movie_id),
    category_id      INTEGER REFERENCES main.dim_oscar_category
(category_id),
    ceremony         INTEGER NOT NULL,
    year_film        INTEGER NOT NULL,
    year_ceremony    INTEGER NOT NULL,
    winner           BOOLEAN NOT NULL
);

CREATE TABLE main.movie_stars
(
    movie_id INTEGER REFERENCES main.dim_movie (movie_id),
    star_id  INTEGER REFERENCES main.dim_star (star_id),
    PRIMARY KEY (movie_id, star_id)
);

CREATE TABLE main.movie_writers
(
    movie_id INTEGER REFERENCES main.dim_movie (movie_id),
    writer_id INTEGER REFERENCES main.dim_writer (writer_id),
    PRIMARY KEY (movie_id, writer_id)
);

```

director_id	name	birth_year	death_year	professions
1	Matt Piedmont			{writer,director,producer}
2	Craig R. Baxley			{stunts,assistant_director,director}
3	Feroz Abbas Khan			{director,writer}
4	Jesse V. Johnson	1971		{stunts,director,writer}
5	John Carpenter	1948		{soundtrack,writer,composer}
6	Brett Haley	1983		{director,writer,producer}
7	Walter Salles	1956		{director,producer,writer}
8	George Hickenlooper	1963	2010	{director,writer,producer}
9	Nigel Cole	1959		{director,actor,assistant_director}
10	Ashish R. Mohan			{assistant_director,actor,casting_director}
11	D.W. Griffith	1875	1948	{director,writer,producer}
12	David Singleton			{producer,director,script_department}
13	Nelson Dilipkumar	1984		{director,writer}
14	Louis C.K.	1967		{writer,producer,actor}
15	Kasi Lemmons	1961		{actress,director,producer}
16	Tim Hill	1958		{writer,producer,director}
17	Mateo Gil	1972		{writer,director,assistant_director}
18	Dito Montiel	1965		{director,writer,soundtrack}
19	Denis Villeneuve	1967		{director,writer,editor}
20	Robert Duvall	1931		{actor,producer,soundtrack}
21	Roberto Benigni	1952		{actor,writer,director}
22	Fred Walton			{director,writer,actor}
23	Henry Selick	1952		{director,animation_department,writer}
24	Michael Caton-Jones	1957		{director,producer,actor}
25	Paul Verhoeven	1938		{director,producer,writer}
26	Matthew Hastings	1967		{producer,director,music_department}

Рис 5.1 – Заповнена таблиця main зони “dim_director”

movie_id	1	2	3	4	5	6	7
title	Henry & June	That Was Then... This Is Now	I Love You Phillip Morris	Sideways	Moving	The Interview	Su
release_date	1990-10-05	1985-11-08	2011-01-07	2004-10-22	1988-03-04	2014-12-24	19
year	1990	1985	2009	2004	1988	2014	19
genre	Biography	Crime	Biography	Comedy	Comedy	Action	Co
rating	NC-17	R	R	R	R	R	PG
runtime_minutes	136.0	102.0	98.0	127.0	89.0	112.0	10
budget			13000000.00	16000000.00		44000000.00	15
production_company	Universal Pictures	Media Ventures	EuropaCorp	Fox Searchlight Pictures	Warner Bros.	Columbia Pictures	Th
country	United States	United States	France	United States	United States	United States	Un
valid_from	2025-03-14	2025-03-14	2025-03-14	2025-03-14	2025-03-14	2025-03-14	20
valid_to							<n
is_current	true	true	true	true	true	true	tr

Рис 5.1 – Заповнена таблиця main зони “dim_movie”

dim_oscar_category [data_analysis@docker]

336 rows

category_id	category	canon_category
1	1 ANIMATED SHORT FILM	SHORT FILM (Animated)
2	2 MUSIC (Music Score of a Dramatic Picture)	MUSIC (Original Score)
3	3 CINEMATOGRAPHY (Black-and-White)	CINEMATOGRAPHY (Black-and-White)
4	4 SPECIAL EFFECTS	VISUAL EFFECTS
5	5 MAKEUP	MAKEUP AND HAIRSTYLING
6	6 ART DIRECTION (Color)	ART DIRECTION (Color)
7	7 SPECIAL ACHIEVEMENT AWARD	SPECIAL ACHIEVEMENT AWARD
8	8 BEST MOTION PICTURE	BEST PICTURE
9	9 VISUAL EFFECTS	VISUAL EFFECTS
10	10 ACTOR IN A SUPPORTING ROLE	ACTOR IN A SUPPORTING ROLE
11	11 MUSIC (Music Score—substantially original)	MUSIC (Original Score)
12	12 WRITING (Motion Picture Story)	WRITING (Original Story)
13	13 ENGINEERING EFFECTS	VISUAL EFFECTS
14	14 SPECIAL ACHIEVEMENT AWARD (Sound Effects)	SPECIAL ACHIEVEMENT AWARD (Sound Effects)
15	15 WRITING	WRITING (Adapted Screenplay)
16	16 SHORT SUBJECT (Two-reel)	SHORT SUBJECT (Two-reel)
17	17 SPECIAL FOREIGN LANGUAGE FILM AWARD	SPECIAL FOREIGN LANGUAGE FILM AWARD
18	18 FOREIGN LANGUAGE FILM	INTERNATIONAL FEATURE FILM
19	19 SHORT FILM (Live Action)	SHORT FILM (Live Action)
20	20 MUSIC (Score of a Musical Picture—original or adaptation)	MUSIC (Original Song Score or Adaptation Score)
21	21 UNIQUE AND ARTISTIC PICTURE	UNIQUE AND ARTISTIC PICTURE
22	22 WRITING (Screenplay Based on Material from Another Medium)	WRITING (Adapted Screenplay)
23	23 WRITING (Story and Screenplay—based on material not prev...	WRITING (Original Screenplay)
24	24 PRODUCTION DESIGN	ART DIRECTION
25	25 SHORT SUBJECT (One-reel)	SHORT SUBJECT (One-reel)
26	26 SPECIAL VISUAL EFFECTS	VISUAL EFFECTS

Рис 5.1 – Заповнена таблиця main зони “dim_oscar_category”

dim_star [data_analysis@docker]

1-500 of 501+

star_id	name
1	1 John Standing
2	2 Bette Davis
3	3 Scott Glenn
4	4 John Rhys-Davies
5	5 Peter Ustinov
6	6 Michael Reilly Burke
7	7 Cillian Murphy
8	8 Christina Applegate
9	9 Billy Zane
10	10 Sophia Loren
11	11 Sergio Castellitto
12	12 Chloë Sevigny
13	13 Agata Kulesza
14	14 Jane Adams
15	15 Miko Hughes
16	16 Constance Wu
17	17 Noémie Merlant
18	18 Amy Madigan
19	19 Richard Farnsworth
20	20 Edward Furlong
21	21 Melissa Joan Hart
22	22 Jennifer Jason Leigh
23	23 Demetrius Shipp Jr.
24	24 Coral Browne
25	25 Melanie Martinez
26	26 Louis Gossett Jr.

SUM: Not enough values

Рис 5.1 – Заповнена таблиця main зони “dim_star”

dim_writer [data_analysis@docker]

fact_box_office [data_analysis@docker] x dim_writer [data_analysis@docker] x dim_star [data_analysis@docker]

WHERE ORDER BY

writer_id	name
1	Tom O'Connor
2	Marianne Wibberley
3	Barry Michael Cooper
4	H.F. Saint
5	Tom Ropelewski
6	Etan Cohen
7	Richard Matheson
8	Vijay Krishna Acharya
9	J. David Stem
10	Georges Bataille
11	Scott M. Gimple
12	Robert Kurtzman
13	Noel Ashman
14	Seth Margolis
15	David Ambrose
16	Louis Venosta
17	Dan Gordon
18	Josh Goldsmith
19	Sabrina Dhawan
20	Dick Clement
21	Linda Palmer
22	Matthew Sand
23	Doug Taylor
24	Eric Bernt
25	Chris Sanders
26	Dan Hageman

Рис 5.1 – Заповнена таблиця main зони “dim_writer”

fact_box_office [data_analysis@docker]

fact_box_office [data_analysis@docker] x dim_writer [data_analysis@docker] x dim_star [data_analysis@docker]

WHERE ORDER BY

fact_id	movie_id	worldwide	domestic	domestic_percent	foreign	foreign_percent	year
1	1	20768906.00	2037459.00	0.10	18731447.00	0.90	2009
2	2	109706931.00	71503593.00	0.65	38203338.00	0.35	2004
3	3	353133890.00	144801023.00	0.41	208332875.00	0.59	2004
4	4	68072848.00	24633730.00	0.36	43439118.00	0.64	2006
5	5	68349884.00	30113491.00	0.44	38236393.00	0.56	2002
6	6	41627431.00	24850922.00	0.60	16776509.00	0.40	2008
7	7	449220945.00	198542554.00	0.44	250678391.00	0.56	2001
8	8	204313400.00	100018837.00	0.49	104294563.00	0.51	2008
9	9	56722693.00	28848693.00	0.51	27874000.00	0.49	2016
10	10	1140703091.00	377027325.00	0.33	763654686.00	0.67	2003
11	11	94935764.00	66818548.00	0.70	28117216.00	0.30	2002
12	12	176506819.00	66486205.00	0.38	110020614.00	0.62	2012
13	13	25272752.00	23900304.00	0.95	1292448.00	0.05	2001
14	14	79799880.00	64460211.00	0.81	15339669.00	0.19	2015
15	15	76432727.00	50863742.00	0.67	25568985.00	0.34	2000
16	16	333535934.00	154696080.00	0.46	178839854.00	0.54	2005
17	17	10229331.00	10097538.00	0.99	131793.00	0.01	2001
18	18	89431890.00	2201923.00	0.03	87229967.00	0.98	2006
19	19	198413428.00	120908074.00	0.61	77505354.00	0.39	2004
20	20	67918658.00	40160800.00	0.59	27750578.00	0.41	2010
21	21	29907685.00	20264436.00	0.68	9643249.00	0.32	2006
22	22	16872671.00	14448589.00	0.86	2424082.00	0.14	2002
23	23	80547866.00	36661504.00	0.46	43886362.00	0.55	2010
24	24	35442935.00	19363565.00	0.55	16079370.00	0.45	2007
25	25	385680446.00	257730019.00	0.67	127950427.00	0.33	2009
26	26	101564935.00	56127162.00	0.55	45437773.00	0.45	2003

Рис 5.1 – Заповнена таблиця main зони “fact_box_office”

	1	2	3	4	5	6	7	8	9	10	11
fact_id	1	2	3	4	5	6	7	8	9	10	11
movie_id	4	4	6	9	9	10	10	13	13	16	16
director_id	3260	1426	<null>	2929	1095	1848	14	3483	1649	2727	893
average_rating	7.5	7.5	6.5	7.2	7.2	5.2	5.2	7.0	7.0	5.3	5.3
number_of_votes	194048	194048	336694	198381	198381	14584	14584	88925	88925	2843	2843
approval_index	6.59	6.59	5.95	6.33	6.33	3.54	3.54	5.74	5.74	2.97	2.97
production_budget	17000000.00	17000000.00	44000000.00	6500000.00	6500000.00	3500000.00	3500000.00	10000000.00	10000000.00	20000000.00	20000000.00
domestic_gross	71502303.00	71502303.00	6105175.00	4002293.00	4002293.00	3293258.00	3293258.00	25697647.00	25697647.00	18826490.00	18826490.00
worldwide_gross	109726800.00	109726800.00	12342632.00	20412841.00	20412841.00	3293258.00	3293258.00	25707698.00	25707698.00	18826490.00	18826490.00

Рис 5.1 – Заповнена таблиця main зони “fact_movie_performance”

	fact_id	movie_id	category_id	ceremony	year_film	year_ceremony	winner
1	1	1055	5	72	1999	2000	true
2	2	1033	5	75	2002	2003	false
3	3	918	5	83	2010	2011	false
4	4	815	5	67	1994	1995	true
5	5	565	5	74	2001	2002	true
6	6	564	5	81	2008	2009	false
7	7	537	5	61	1988	1989	true
8	8	477	5	61	1988	1989	false
9	9	368	5	71	1998	1999	false
10	10	297	5	83	2010	2011	false
11	11	127	5	63	1990	1991	true
12	12	87	5	82	2009	2010	true
13	13	51	5	76	2003	2004	true
14	14	2078	5	71	1998	1999	true
15	15	1945	5	70	1997	1998	false
16	16	1754	5	70	1997	1998	true
17	17	1678	5	55	1982	1983	false
18	18	1315	5	74	2001	2002	false
19	19	1314	5	58	1985	1986	true
20	20	1262	5	79	2006	2007	false
21	21	3216	5	72	1999	2000	false
22	22	3044	5	82	2009	2010	false
23	23	3011	5	62	1989	1990	true
24	24	2933	5	66	1993	1994	false
25	25	2912	5	62	1989	1990	false
26	26	2781	5	54	1981	1982	false

Рис 5.1 – Заповнена таблиця main зони “fact_oscar_awards”

	movie_id	star_id
1	12308	452
2	6991	2146
3	4560	1420
4	7137	192
5	4283	4935
6	13488	4530
7	1447	2511
8	1207	4072
9	494	3433
10	7279	2909
11	6976	2322
12	8330	4901
13	13159	3610
14	30	4593
15	5950	2030
16	3124	795
17	12503	2031
18	5208	1116
19	1696	3046
20	691	658
21	7012	4384
22	12940	955
23	364	4999
24	9249	1060
25	2440	3541
26	7938	3783

Рис 5.1 – Заповнена таблиця main зони “movie_stars”

	movie_id	writer_id
1	15218	6369
2	15218	1857
3	15217	7560
4	15217	3048
5	15216	6643
6	15216	2131
7	15215	8517
8	15215	4005
9	15214	6269
10	15214	1757
11	15213	6874
12	15213	2362
13	15212	5631
14	15212	1119
15	15211	4651
16	15211	139
17	15210	7929
18	15210	7293
19	15210	3417
20	15210	2781
21	15209	8966
22	15209	4454
23	15208	7113
24	15208	2601
25	15207	8969
26	15207	4457

Рис 5.1 – Заповнена таблиця main зони “movie_writers”

Завантаження змінених даних

База даних містить інформацію про фільми, режисерів, сценаристів, акторів, нагороди та касові збори. Деякі з цих даних можуть змінюватися з часом, тому застосовується SCD (Slowly Changing Dimensions) для їхнього правильного зберігання та обробки.

1. dim_movie – SCD Type 2 (збереження історії змін)

Ця таблиця містить основну інформацію про фільми, зокрема назву, дату випуску, жанр, рейтинг, бюджет та інші характеристики.

Оскільки такі атрибути, як жанр, рейтинг та тривалість, можуть змінюватися з часом, використовується SCD Type 2:

Коли змінюється будь-який з цих атрибутів, створюється новий запис, що відображає оновлений стан фільму. Попередній запис позначається як неактуальний, але зберігається для аналізу історичних змін. Це дозволяє відстежувати зміни у характеристиках фільму та оцінювати їхній вплив на його популярність і фінансові результати.

2. dim_director – SCD Type 1 (перезапис значень)

Таблиця містить інформацію про режисерів, включаючи ім'я, рік народження, рік смерті та професії. Оскільки зміни в цих даних зазвичай не потребують збереження історії, застосовується SCD Type 1. Якщо оновлюється будь-який з атрибутів (наприклад, стає відомим рік смерті режисера або змінюється перелік його професій), старе значення перезаписується.

Такий підхід підходить для випадків, коли важливо зберігати лише найактуальнішу інформацію.

3. dim_oscar_category – SCD Type 1 (перезапис значень)

Ця таблиця містить категорії нагород «Оскар», які можуть змінюватися або уточнюватися з часом.

Застосовується SCD Type 1, оскільки історія змін у назвах категорій не є критично важливою. Якщо назва категорії змінюється або коригується, нове значення перезаписується, без збереження попередніх записів.

Це забезпечує підтримку актуальної класифікації нагород без дублювання даних.

4. dim_star та dim_writer – SCD Type 1 (перезапис значень)

Таблиці містять інформацію про акторів та сценаристів, які брали участь у створенні фільмів.

Застосовується SCD Type 1, оскільки їхні імена та інші атрибути не потребують історичного збереження. Якщо змінюється ім'я (наприклад, у разі виправлення помилки або використання сценічного псевдоніма), запис перезаписується. Це дозволяє забезпечити актуальність даних без ускладнення моделі.

Код:

```
-- SCD Type 2
ALTER TABLE main.dim_movie
    ADD COLUMN valid_from DATE DEFAULT CURRENT_DATE,
    ADD COLUMN valid_to DATE NULL,
    ADD COLUMN is_current BOOLEAN DEFAULT TRUE;

-- 1. Оновлення dim_movie (SCD Type 2)
WITH new_movies AS (SELECT DISTINCT name AS title,
                                released AS release_date,
                                year,
                                genre,
                                rating,
                                runtime,
                                budget,
                                company AS production_company,
                                country
                        FROM staging.movies)

INSERT
INTO main.dim_movie (title, release_date, year, genre, rating,
runtime_minutes, budget, production_company, country,
                    valid_from, valid_to, is_current)
SELECT nm.*, CURRENT_DATE, NULL, TRUE
FROM new_movies nm
    LEFT JOIN main.dim_movie dm ON nm.title = dm.title AND
nm.year = dm.year
WHERE dm.movie_id IS NULL
    OR (dm.is_current = TRUE AND (
    nm.genre <> dm.genre OR nm.rating <> dm.rating OR nm.runtime <>
dm.runtime_minutes
));

-- Закриття старих записів у разі змін
```

```

UPDATE main.dim_movie
SET valid_to    = CURRENT_DATE,
    is_current  = FALSE
WHERE is_current = TRUE
    AND movie_id IN (SELECT old.movie_id
                      FROM main.dim_movie old
                      JOIN staging.movies new ON old.title =
new.name AND old.year = new.year
                      WHERE old.genre <> new.genre
                        OR old.rating <> new.rating
                        OR old.runtime_minutes <> new.runtime);

```

```

-- 2. Оновлення dim_director (SCD Type 1)
INSERT INTO main.dim_director (name, birth_year, death_year,
professions)
SELECT DISTINCT director_name, director_birth_year,
director_death_year, director_professions
FROM staging.movie_budget
WHERE director_name IS NOT NULL
ON CONFLICT (director_id) DO UPDATE
    SET birth_year    = EXCLUDED.birth_year,
        death_year    = EXCLUDED.death_year,
        professions    = EXCLUDED.professions;

```

```

-- 3. Оновлення dim_oscar_category
INSERT INTO main.dim_oscar_category (category, canon_category)
SELECT DISTINCT category, canon_category
FROM staging.oscar_awards
ON CONFLICT (category_id) DO NOTHING;

```

```

-- 4. Оновлення dim_star
INSERT INTO main.dim_star (name)
SELECT DISTINCT star
FROM staging.movies
WHERE star IS NOT NULL
ON CONFLICT (star_id) DO NOTHING;

```

```

-- 5. Оновлення dim_writer
INSERT INTO main.dim_writer (name)
SELECT DISTINCT writer
FROM staging.movies
WHERE writer IS NOT NULL
ON CONFLICT (writer_id) DO NOTHING;

```

Завантаження нових даних

База даних містить фактичні таблиці (`fact_box_office`, `fact_movie_performance`, `fact_oscar_awards`), а також зв'язкові таблиці (`movie_stars`, `movie_writers`), які можуть змінюватися з часом. Оскільки ці таблиці містять динамічні дані, використовується інкрементальне завантаження для оновлення та додавання нових записів без дублювання даних.

1. `fact_box_office` – оновлення фінансових показників

Ця таблиця містить інформацію про касові збори фільмів, які можуть оновлюватися з часом.

Метод оновлення:

Якщо запис вже існує (за `movie_id` та `year`), дані про світові та локальні збори оновлюються. Якщо запису немає, він додається як новий.

Цей підхід дозволяє коригувати попередні фінансові дані, що змінюються після виходу фільму.

2. `fact_movie_performance` – оновлення рейтингів та зборів

Таблиця містить оцінки фільмів, кількість голосів та бюджетні показники.

Метод оновлення:

Якщо запис вже існує (`movie_id`), оновлюються середній рейтинг, кількість голосів, касові збори.

Якщо запису немає, додається новий.

Такий підхід важливий, оскільки рейтинг фільму та кількість голосів змінюються з часом (наприклад, через нові оцінки користувачів).

3. `fact_oscar_awards` – додавання нових переможців

Ця таблиця містить інформацію про номінації та перемоги на «Оскарі».

Метод оновлення:

Якщо фільм вже був номінований у категорії (`movie_id`, `category_id`, `year_film`), запис не змінюється, щоб зберегти історичні дані. Якщо з'являється нова номінація або переможець, запис додається.

Це дозволяє коректно обробляти оновлення списку переможців та нові номінації.

4. movie_stars та movie_writers – унікальні зв'язки

Ці таблиці містять відношення фільмів до акторів (movie_stars) і сценаристів (movie_writers).

Метод оновлення:

Якщо зв'язок вже існує, він не дублюється. Якщо актор або сценарист новий для фільму, запис додається. Це забезпечує правильне відображення касту та команди фільму без зайвих записів.

Код:

```
-- 1. Завантаження fact_box_office (оновлення даних)
INSERT INTO main.fact_box_office (movie_id, worldwide, domestic,
domestic_percent, "foreign", foreign_percent, year)
SELECT dm.movie_id, bo.worldwide, bo.domestic,
bo.domestic_percent, bo.foreign, bo.foreign_percent, bo.year
FROM staging.box_office bo
      JOIN main.dim_movie dm ON bo.release_group = dm.title
AND bo.year = dm.year
ON CONFLICT (movie_id, year) DO UPDATE SET worldwide      =
EXCLUDED.worldwide,
                                                domestic      =
EXCLUDED.domestic,
                                                domestic_percent =
EXCLUDED.domestic_percent,
                                                "foreign"      =
EXCLUDED.foreign,
                                                foreign_percent =
EXCLUDED.foreign_percent;

-- 2. Завантаження fact_movie_performance (рейтинги та збори
можуть змінюватися)
INSERT INTO main.fact_movie_performance (movie_id, director_id,
average_rating, number_of_votes, approval_index,
                                                production_budget,
domestic_gross, worldwide_gross)
SELECT dm.movie_id,
       dd.director_id,
       mb.movie_average_rating,
       mb.movie_number_of_votes,
       mb.approval_index,
       mb.production_budget,
       mb.domestic_gross,
```

```

        mb.worldwide_gross
FROM staging.movie_budget mb
        JOIN main.dim_movie dm ON mb.movie_title = dm.title AND
mb.production_date = dm.release_date
        LEFT JOIN main.dim_director dd ON mb.director_name =
dd.name
ON CONFLICT (movie_id) DO UPDATE SET average_rating =
EXCLUDED.average_rating,
                                number_of_votes =
EXCLUDED.number_of_votes,
                                approval_index =
EXCLUDED.approval_index,
                                domestic_gross =
EXCLUDED.domestic_gross,
                                worldwide_gross =
EXCLUDED.worldwide_gross;

```

-- 3. Завантаження fact_oscar_awards (можуть з'являтися нові переможці)

```

INSERT INTO main.fact_oscar_awards (movie_id, category_id,
ceremony, year_film, year_ceremony, winner)
SELECT dm.movie_id, dc.category_id, oa.ceremony, oa.year_film,
oa.year_ceremony, oa.winner
FROM staging.oscar_awards oa
        JOIN main.dim_movie dm ON oa.film = dm.title AND
oa.year_film = dm.year
        JOIN main.dim_oscar_category dc ON oa.category =
dc.category
ON CONFLICT (movie_id, category_id, year_film) DO NOTHING;

```

-- 4. Завантаження зв'язків між фільмами та акторами

```

INSERT INTO main.movie_stars (movie_id, star_id)
SELECT DISTINCT dm.movie_id, ds.star_id
FROM staging.movies m
        JOIN main.dim_movie dm ON m.name = dm.title AND m.year
= dm.year
        JOIN main.dim_star ds ON m.star = ds.name
ON CONFLICT (movie_id, star_id) DO NOTHING;

```

-- 5. Завантаження зв'язків між фільмами та сценаристами

```

INSERT INTO main.movie_writers (movie_id, writer_id)
SELECT DISTINCT dm.movie_id, dw.writer_id
FROM staging.movies m

```

```
JOIN main.dim_movie dm ON m.name = dm.title AND m.year  
= dm.year  
JOIN main.dim_writer dw ON m.writer = dw.name  
ON CONFLICT (movie_id, writer_id) DO NOTHING;
```

Висновок:

У ході виконання лабораторної роботи було здійснено збір та підготовку даних, що включало вибір кількох джерел відкритої інформації, пов'язаної з індустрією кіно, а також очищення та трансформацію цих даних для подальшого використання. Було спроектовано модель сховища даних, створено таблиці для Stage зони та основного сховища, а також розроблено ETL-процеси, які забезпечують завантаження даних на проміжний етап та їх подальше перетворення для основного сховища. Реалізовано процеси завантаження та оновлення даних, зокрема методи SCD для обробки змінних даних, що дозволило підтримувати історичну точність інформації. В результаті дані були успішно підготовлені для подальшого аналізу, а створені таблиці вимірів і фактів дозволяють виконувати широкий спектр аналітичних запитів. Таким чином, усі поставлені завдання виконано, що дозволило створити ефективну систему для зберігання та аналізу даних про кіноіндустрію.