

✓ Підготовка даних до аналізу

Мета

Ознайомитись з методикою первинної обробки даних. Після завершення цієї лабораторної роботи ви зможете:

- Досліджувати структуру завантажених даних
- Виправляти формати даних
- Знаходити та заповнювати пропуски в даних
- Знаходити викиди та некоректні значення
- Будувати прості візуалізації

✓

Завдання, що оцінюються

1. Скачати дані із файлу ['Data2.csv'](#). Записати дані у dataframe. Дослідити структуру даних.
2. Виправити помилки в даних.
3. Заповнити пропуски.
4. Додати стовпчик із щільністю населення.
5. Побудувати діаграми розмаху та гістограми.

✓

Завдання #1:

Дослідити структуру даних

Зчитую дані з файлу у датафрейм

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from pandas import read_csv
```

```
DATA_PATH = 'data/Data.csv'
```

```
df = read_csv(DATA_PATH, sep=';', encoding='cp1252')
```

► Натисніть тут, щоб побачити підказку

Досліджую структуру даних

Напишіть ваш код нижче та натисніть Shift+Enter для виконання
df.head(20)



	Country Name	Region	GDP per capita	Populatiion	C02 emission	Area
0	Afghanistan	South Asia	561,7787463	34656032.0	9809,225	652860
1	Albania	Europe & Central Asia	4124,98239	2876101.0	5716,853	28750
2	Algeria	Middle East & North Africa	3916,881571	40606052.0	145400,217	2381740
3	American Samoa	East Asia & Pacific	11834,74523	55599.0	NaN	200
4	Andorra	Europe & Central Asia	36988,62203	77281.0	462,042	470
5	Angola	Sub-Saharan Africa	3308,700233	28813463.0	34763,16	1246700
6	Antigua and Barbuda	Latin America & Caribbean	14462,17628	100963.0	531,715	440
7	Argentina	Latin America & Caribbean	12440,32098	43847430.0	204024,546	2780400
8	Armenia	Europe & Central Asia	3614,688357	2924816.0	5529,836	29740
9	Aruba	Latin America & Caribbean	NaN	104822.0	872,746	180
10	Australia	East Asia & Pacific	49755,31548	24127159.0	361261,839	7741220
11	Austria	Europe & Central Asia	44757,6349	8747358.0	58712,337	83879
12	Azerbaijan	Europe & Central Asia	3878,709257	9762274.0	37487,741	86600

df.dtypes



Country Name	object
Region	object
GDP per capita	object
Populatiion	float64
C02 emission	object
Area	object
dtype:	object

```
df.describe(include='all')
```



	Country Name	Region	GDP per capita	Populatiion	CO2 emission	Area
count	217	217	190	2.160000e+02	205	217
unique	217	7	190	NaN	202	213
top	Afghanistan	Europe & Central Asia	561,7787463	NaN	6318,241	460
freq	1	58	1	NaN	2	3
mean	NaN	NaN	NaN	3.432256e+07	NaN	NaN
std	NaN	NaN	NaN	1.347600e+08	NaN	NaN
min	NaN	NaN	NaN	1.109700e+04	NaN	NaN
25%	NaN	NaN	NaN	7.900265e+05	NaN	NaN
50%	NaN	NaN	NaN	6.221590e+06	NaN	NaN
75%	NaN	NaN	NaN	2.350337e+07	NaN	NaN

Бачу наступні проблеми в даних:

1. Запис нецілих чисел у різних колонках відрізняється (кома, крапка)
2. Неправильний тип у більшості стовпців
3. Від'ємні значення
4. Є пропущені значення в "GDP per capital", "CO2 emission", "Population"



Завдання #2:

Виправити помилки в даних

Проблема 1: Запис нецілих чисел у різних колонках відрізняється (кома, крапка)

Для виправлення приведу записи до одного виду – запис через крапку.

```
headers = [
    'country_name',
    'region',
    'gdp_per_capita',
    'population',
    'co2_emission',
    'area',
]
```

```
df.columns = headers
```

```
float_columns = [
    'co2_emission',
    'area',
]
```

```
for column in float_columns:
    df[column] = df[column].str.replace(',', '')
```

```
integer_columns = [
    'gdp_per_capita',
]
```

```
for column in integer_columns:
    df[column] = df[column].str.replace(',', '')
```

```
df.head(20)
```



	country_name	region	gdp_per_capita	population	co2_emission	area
0	Afghanistan	South Asia	5617787463	34656032.0	9809.225	652860
1	Albania	Europe & Central Asia	412498239	2876101.0	5716.853	28750
2	Algeria	Middle East & North Africa	3916881571	40606052.0	145400.217	2381740
3	American Samoa	East Asia & Pacific	1183474523	55599.0	NaN	200
4	Andorra	Europe & Central Asia	3698862203	77281.0	462.042	470
5	Angola	Sub-Saharan Africa	3308700233	28813463.0	34763.16	1246700
6	Antigua and Barbuda	Latin America & Caribbean	1446217628	100963.0	531.715	440
7	Argentina	Latin America & Caribbean	1244032098	43847430.0	204024.546	2780400
8	Armenia	Europe & Central Asia	3614688357	2924816.0	5529.836	29740
9	Aruba	Latin America & Caribbean	NaN	104822.0	872.746	180
10	Australia	East Asia & Pacific	4975531548	24127159.0	361261.839	7741220

Проблема 2: Неправильний тип у більшості стовпців

Для виправлення зміню тип даних на підходящий.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from numpy import nan

df.head()

df.replace(r'^\s*$', nan, regex=True, inplace=True)

df[['country_name', 'region']] = df[['country_name', 'region']].astype('string')
df[['gdp_per_capita', 'co2_emission', 'area', 'population']] = df[['gdp_per_capit

# колонки population та gdp_per_capita мають бути цілими числами, але оскільки в
# тип колонок змінимо пізніше

df.dtypes
```

```
country_name    string[python]
region          string[python]
gdp_per_capita  float64
population      float64
co2_emission    float64
area            float64
dtype: object
```

Проблема 2: Від'ємні значення

Для виправлення візьму абсолютне значення записів із від'ємним числом.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
columns_with_negative_values = [
    'area',
    'gdp_per_capita',
]

for column in columns_with_negative_values:
    df[column] = df[column].apply(lambda x: abs(x) if x < 0 else x)
```

▼

Завдання #3:

Заповнити пропуски

Проблема 3: Є пропущені значення в "GDP per capital", "CO2 emission", "Population"

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
missing_data = df.isnull()

for column in missing_data.columns.values.tolist():
    print(missing_data[column].value_counts(), end='\n\n')
```

```
country_name
False      217
Name: count, dtype: int64

region
False      217
Name: count, dtype: int64

gdp_per_capita
False      190
True        27
Name: count, dtype: int64

population
False      216
True         1
Name: count, dtype: int64

co2_emission
False      205
True        12
Name: count, dtype: int64

area
False      217
Name: count, dtype: int64
```

Для виправлення зроблю наступне:

- gdp_per_capita: 27 відсутніх значень. заміню їх медіаною, щоб не було помітного впливу на загальну статистику
- population: 1 відсутнє значення. заповню даними із зовнішніх ресурсів
- co2_emission: 12 відсутніх значень. видаляю їх, оскільки це те – що ми хочемо передбачити

```
# gdp_per_capita
df['gdp_per_capita'] = df['gdp_per_capita'].fillna(df['gdp_per_capita'].median())

# population
eritrea = df[df['country_name'] == 'Eritrea']

eritrea_population = 3_579_283 # https://www.worldometers.info/world-population/
```

```
df[df['country_name'] == 'Eritrea'] = df[df['country_name'] == 'Eritrea'].fillna(

# co2_emission
df.dropna(subset=['co2_emission'], axis=0, inplace=True)
df.reset_index(drop=True, inplace=True)
```

Досліджую структуру даних, чи всі пропуски заповнено

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
missing_data = df.isnull()
```

```
for column in missing_data.columns.values.tolist():
    print(missing_data[column].value_counts(), end='\n\n')
```

```
⇒ country_name
False    205
Name: count, dtype: int64

region
False    205
Name: count, dtype: int64

gdp_per_capita
False    205
Name: count, dtype: int64

population
False    205
Name: count, dtype: int64

co2_emission
False    205
Name: count, dtype: int64

area
False    205
Name: count, dtype: int64
```

На даному етапі всі пропуски заповнено / видалено, тому ми можемо привести колонку до правильного типу

```
df[['population', 'gdp_per_capita']] = df[['population', 'gdp_per_capita']].astype
df.dtypes
```

```
⇒ country_name    string[python]
region           string[python]
gdp_per_capita    int64
population        int64
co2_emission      float64
```

```
area  
dtype: object
```

```
float64
```



Завдання #4:

Додати стовпчик із щільністю населення

Щільність населення розрахую по формулі кількість населення поділена на площу країни. Додам результат у новий стовпчик "population_density"

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання  
df['population_density'] = df['population'] / df['area']  
df.head(20)
```




	country_name	region	gdp_per_capita	population	co2_emission	area
0	Afghanistan	South Asia	5617787463	34656032	9809.225	652860.0
1	Albania	Europe & Central Asia	412498239	2876101	5716.853	28750.0
2	Algeria	Middle East & North Africa	3916881571	40606052	145400.217	2381740.0
3	Andorra	Europe & Central Asia	3698862203	77281	462.042	470.0
4	Angola	Sub-Saharan Africa	3308700233	28813463	34763.160	1246700.0
5	Antigua and Barbuda	Latin America & Caribbean	1446217628	100963	531.715	440.0
6	Argentina	Latin America & Caribbean	1244032098	43847430	204024.546	2780400.0
7	Armenia	Europe & Central Asia	3614688357	2924816	5529.836	29740.0
8	Aruba	Latin America & Caribbean	3675459700	104822	872.746	180.0
9	Australia	East Asia	4975531548	24127159	361261.839	7741220.0



Завдання #5:

Побудувати діаграми розмаху та гістограми

Для побудови графіків скористайтесь бібліотекою Matplotlib. Спробуйте погратись з кольорами, розмірами та підписами.

```
# Напишіть ваш код нижче та натисніть Shift+Enter для виконання
import matplotlib.pyplot as plt

fig, axs = plt.subplots(1, 4, figsize=(16, 4))
```

```
fig.suptitle('Діаграми розмаху', fontsize=16)

axs[0].set_title('GDP per capita')
axs[0].boxplot(df['gdp_per_capita'])

axs[1].set_title('Population')
axs[1].boxplot(df['population'])

axs[2].set_title('CO2 emission')
axs[2].boxplot(df['co2_emission'])


axs[3].set_title('Area')
axs[3].boxplot(df['area'])

plt.show()



fig, ax = plt.subplots(figsize=(8, 6))
fig.suptitle('Гістограма GDP per Capita', fontsize=16, fontweight='bold')

ax.hist(df['gdp_per_capita'], bins=15, color='royalblue', edgecolor='black', alph
ax.set_title('GDP per Capita', fontsize=12, fontweight='bold')
ax.set_xlabel('GDP per Capita', fontsize=10)
ax.set_ylabel('Frequency', fontsize=10)
ax.grid(True, linestyle='--', alpha=0.5)

plt.tight_layout(rect=[0, 0, 1, 0.96])
plt.show()
```



Гістограма GDP per Capita



► Натисніть тут, щоб побачити підказку



Додаткове завдання:

Дайте відповіді на питання

1. Яка країна має найбільший ВВП на людину (GDP per capita)?
2. Яка країна має найменшу площу?
3. Знайдіть країну з найбільшою щільністю населення у світі? У Європі та центральній Азії?
4. Покажіть топ 5 країн та 5 останніх країн по ВВП на людину.

► Натисніть тут, щоб побачити підказку

```
# Яка країна має найбільший ВВП на людину (GDP per capita)?
print('\n' + df.loc[df['gdp_per_capita'].idxmax(), 'country_name'] + ' має найбіл

# Яка країна має найменшу площу (area)?
print('\n' + df.loc[df['area'].idxmin(), 'country_name'] + ' має найменшу площу')

# Знайдіть країну з найбільшою щільністю населення у світі
print('\n' + df.loc[df['population_density'].idxmax(), 'country_name'] + ' має на

# Знайдіть країну з найбільшою щільністю населення у Європі та центральній Азії
europe_central_asia = df[df['region'] == 'Europe & Central Asia']
print('\n' + europe_central_asia.loc[europe_central_asia['population_density'].id

# Покажіть топ 5 країн та 5 останніх країн по ВВП на людину.

top_5_gdp_per_capita = df.nlargest(5, 'gdp_per_capita')
last_5_gdp_per_capita = df.nsmallest(5, 'gdp_per_capita')

print('\nТоп 5 країн по ВВП на людину:')
print(top_5_gdp_per_capita[['country_name', 'gdp_per_capita']])

print('\n5 останніх країн по ВВП на людину:')
print(last_5_gdp_per_capita[['country_name', 'gdp_per_capita']])
```