

Пошуковий аналіз даних

Мета

Ознайомитись з методами перевірки статистичних гіпотез. Після завершення цієї лабораторної роботи ви зможете:

- Досліджувати дані за допомогою візуалізацій
- Робити описовий аналіз
- Групувати дані для аналізу
- Знаходити зв'язок між ознаками
- Перевіряти гіпотези про значущість коефіцієнта кореляції та про вигляд закону розподілу
- Робити дисперсійний аналіз

Завдання, що оцінюються

1. Скачати дані із файлу, який зберегли наприкінці попередньої роботи (з виправленими помилками та заповненими пропусками). Записати дані у dataframe. Дослідити ознаки з метою виявлення зв'язку між ними, побудувавши їх візуалізації. Візуально оцініть наявність та силу зв'язку між ознаками.
2. Порахувати кореляцію між всіма кількісними ознаками
3. Побудувати діаграми розсіювання для кількісних ознак та 'CO2 emission'. Які кількісні ознаки можуть бути предикторами кількості викидів CO2?
4. Побудувати діаграму розмаху для 'CO2 emission' по регіонам.
5. Виконати дисперсійний аналіз для кількості викидів CO2, згрупувати дані по регіонам

Завдання #1:

Дослідити ознаки з метою виявлення зв'язку між ними, побудувавши їх візуалізації

Зчитую дані з файлу у датафрейм

```
In [2]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

DATA_PATH = 'data/clean_data.csv'

df = pd.read_csv(DATA_PATH, sep=';', encoding='cp1252')

df[['country_name', 'region']] = df[['country_name', 'region']].astype('object')
df.dtypes
```

```
Out[2]: country_name      string[python]
        region           string[python]
        gdp_per_capita      int64
        population         int64
        co2_emission       float64
        area               float64
        population_density  float64
        dtype: object
```

```
In [3]: df.head(20)
```

Out [3]:

	country_name	region	gdp_per_capita	population	co2_emission	area
0	Afghanistan	South Asia	5617787463	34656032	9809.225	652860.0
1	Albania	Europe & Central Asia	412498239	2876101	5716.853	28750.0
2	Algeria	Middle East & North Africa	3916881571	40606052	145400.217	2381740.0
3	Andorra	Europe & Central Asia	3698862203	77281	462.042	470.0
4	Angola	Sub-Saharan Africa	3308700233	28813463	34763.160	1246700.0
5	Antigua and Barbuda	Latin America & Caribbean	1446217628	100963	531.715	440.0
6	Argentina	Latin America & Caribbean	1244032098	43847430	204024.546	2780400.0
7	Armenia	Europe & Central Asia	3614688357	2924816	5529.836	29740.0
8	Aruba	Latin America & Caribbean	3675459700	104822	872.746	180.0
9	Australia	East Asia & Pacific	4975531548	24127159	361261.839	7741220.0
10	Austria	Europe & Central Asia	447576349	8747358	58712.337	83879.0
11	Azerbaijan	Europe & Central Asia	3878709257	9762274	37487.741	86600.0
12	Bahamas, The	Latin America & Caribbean	2878547767	391232	2416.553	13880.0
13	Bahrain	Middle East & North Africa	2257909342	1425171	31338.182	771.0
14	Bangladesh	South Asia	1358779029	162951560	73189.653	147630.0

	country_name	region	gdp_per_capita	population	co2_emission	area
15	Barbados	Latin America & Caribbean	1589162655	284996	1272.449	430.0
16	Belarus	Europe & Central Asia	4989427763	9507120	63497.772	207600.0
17	Belgium	Europe & Central Asia	4127148215	11348159	93350.819	30530.0
18	Belize	Latin America & Caribbean	4744736397	366954	495.045	22970.0
19	Benin	Sub-Saharan Africa	7894404107	10872298	6318.241	114760.0


Будую діаграми

In [4]: *# Напишіть ваш код нижче та натисніть Shift+Enter для виконання*

```
headers = [
    'country_name',
    'region',
    'gdp_per_capita',
    'population',
    'co2_emission',
    'area',
]

sns.regplot(x='gdp_per_capita', y='co2_emission', data=df)
plt.ylim(0,)
```


Out[4]: (0.0, 10819758.898183722)



Зі збільшенням ввп на душу населення викиди CO2 трохи зменшуються. Це вказує на слабку кореляцію між цими двома ознаками. Однак, є винятки, коли країни з високим ВВП мають відносно високі показники викидів CO2

```
In [5]: sns.regplot(x='population_density', y='population', data=df)
plt.ylim(0,)
```


```
Out[5]: (0.0, 1451427467.3843935)
```



Ця діаграма не показує кореляцію між цими двома показниками

```
In [6]: sns.regplot(x='population', y='co2_emission', data=df)
plt.ylim(0,)
```

```
Out[6]: (0.0, 12128379.195517158)
```



Цей графік вказує на майже відсутність кореляції між цими двома ознаками. Однак, є винятки, коли країни з високою популяцією мають відносно високі показники викидів CO2

Завдання #2:

Порахувати кореляцію між всіма кількісними ознаками

Рахую кореляцію між всіма кількісними ознаками

In [7]: `# Напишіть ваш код нижче та натисніть Shift+Enter для виконання`
`df.corr(numeric_only=True)`

Out [7]:

	gdp_per_capita	population	co2_emission	area	populati
gdp_per_capita	1.000000	0.062268	0.143575	0.172900	
population	0.062268	1.000000	0.803804	0.451147	
co2_emission	0.143575	0.803804	1.000000	0.587480	
area	0.172900	0.451147	0.587480	1.000000	
population_density	0.123302	-0.021892	-0.022537	-0.063490	


Завдання #3:

Побудувати діаграми розсіювання для кількісних ознак та 'CO2 emission'.
Візуально оцінити наявність та силу зв'язку між цими ознаками.

Будую діаграму розсіювання для кількісних ознак та 'CO2 emission'


```
In [8]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
sns.regplot(x='population', y='co2_emission', data=df)
plt.ylim(0,)
```

```
Out[8]: (0.0, 12541891.94202421)
```



```
In [9]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
sns.regplot(x='area', y='co2_emission', data=df)
plt.ylim(0,)
```


```
Out[9]: (0.0, 10844260.077813366)
```

Зі збільшенням площі викиди CO2 майже не змінюються. Це вказує на слабку кореляцію між цими двома ознаками. Однак, є винятки, коли країни з великою площею мають відносно високі показники викидів CO2

```
In [10]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
sns.regplot(x='population_density', y='co2_emission', data=df)
plt.ylim(0,)
```

```
Out[10]: (0.0, 10858305.617231632)
```



Ця діаграма не показує кореляцію між цими двома показниками

Які кількісні ознаки можуть бути предикторами кількості викидів CO2?

Обчислюю коефіцієнт кореляції Пірсона та P-value для всіх кількісних змінних та 'CO2 emission'

```
In [11]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання

import scipy.stats as stats

quantitative_features = ['gdp_per_capita', 'population', 'area', 'population_density']

correlation_results = {}
for feature in quantitative_features:
    corr, p_value = stats.pearsonr(df[feature], df['co2_emission'])
    correlation_results[feature] = {'Pearson Correlation': corr, 'P-value': p_value}

correlation_df = pd.DataFrame.from_dict(correlation_results, orient='index')
print(correlation_df)
```

	Pearson Correlation	P-value
gdp_per_capita	0.143575	3.999822e-02
population	0.803804	1.128895e-47
area	0.587480	2.061861e-20
population_density	-0.022537	7.483995e-01

1. **gdp_per_capita** (ВВП на душу населення)

- Слабка позитивна кореляція ($r = 0.1436$).

- P-value < 0.05, кореляція статистично значуща.
- Висновок: Більш розвинені країни мають трохи вищі викиди CO₂, але зв'язок слабкий.

2. **population** (Населення)

- Сильна позитивна кореляція (**r = 0.8038**).
- P-value ≈ 0, зв'язок дуже значущий.
- Висновок: Чим більше населення, тим вищі викиди CO₂.

3. **area** (Площа країни)

- Середня позитивна кореляція (**r = 0.5875**).
- P-value ≈ 0, зв'язок значущий.
- Висновок: Великі країни мають вищі викиди, можливо, через індустріалізацію.

4. **population_density** (Густота населення)

- Майже нульова кореляція (**r = -0.0225**).
- P-value > 0.05, зв'язок незначущий.
- Висновок: Густанаселені країни можуть мати різні рівні викидів.

Кількісні ознаки, які можуть бути предикторами кількості викидів CO₂:

- population – найсильніший предиктор (r = 0.8038, P-value ≈ 0). Велике населення сприяє вищим викидам CO₂.
- area – середній позитивний зв'язок (r = 0.5875, P-value ≈ 0). Великі країни часто мають більше промисловості та транспорту.
- gdp_per_capita – слабкий, але статистично значущий зв'язок (r = 0.1436, P-value = 0.03999). Економічний розвиток впливає на викиди, але не є ключовим фактором.


✗ population_density – не є предиктором (r = -0.0225, P-value = 0.7484), оскільки не має значущого впливу на викиди CO₂.

Завдання #4:

Побудувати діаграму розмаху для 'CO2 emission' по регіонам.

In [12]: *# Напишіть ваш код нижче та натисніть Shift+Enter для виконання*

```
plt.figure(figsize=(12, 6))
sns.boxplot(x="region", y="co2_emission", data=df)
plt.xticks(rotation=45)
plt.title("Розподіл викидів CO2 за регіонами")
plt.show()
```



Ми бачимо що розподіл по регіонах сильно збігається, тому регіон не буде хорошим показником CO2, лише North America вирізняється

Завдання #5:

Виконати дисперсійний аналіз для кількості викидів CO2, згрупувати дані по регіонам

Групуємо дані, щоб побачити чи впливає 'Region' на 'CO2 emission'.

```
In [13]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
co2_emission_by_region = df[["region", "co2_emission"]].groupby("region")
co2_emission_by_region.head()
```


Out[13]:

	region	co2_emission
0	South Asia	9.809225e+03
1	Europe & Central Asia	5.716853e+03
2	Middle East & North Africa	1.454002e+05
3	Europe & Central Asia	4.620420e+02
4	Sub-Saharan Africa	3.476316e+04
5	Latin America & Caribbean	5.317150e+02
6	Latin America & Caribbean	2.040245e+05
7	Europe & Central Asia	5.529836e+03
8	Latin America & Caribbean	8.727460e+02
9	East Asia & Pacific	3.612618e+05
10	Europe & Central Asia	5.871234e+04
11	Europe & Central Asia	3.748774e+04
12	Latin America & Caribbean	2.416553e+03
13	Middle East & North Africa	3.133818e+04
14	South Asia	7.318965e+04
15	Latin America & Caribbean	1.272449e+03
19	Sub-Saharan Africa	6.318241e+03
20	North America	5.757190e+02
21	South Asia	1.001091e+03
24	Sub-Saharan Africa	7.033306e+03
27	East Asia & Pacific	9.108828e+03
29	Sub-Saharan Africa	2.849259e+03
30	Sub-Saharan Africa	4.400400e+02
32	East Asia & Pacific	6.684941e+03
34	North America	5.371935e+05
39	East Asia & Pacific	1.029193e+07
52	Middle East & North Africa	7.223990e+02
56	Middle East & North Africa	2.018940e+05
63	East Asia & Pacific	1.169773e+03
85	South Asia	2.238377e+06
87	Middle East & North Africa	6.494807e+05
116	South Asia	1.334788e+03
196	North America	5.254279e+06

Перевіряю розподіл даних в групах, щоб обрати вид дисперсійного аналізу.

Візуальний аналіз

```
In [14]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
plt.figure(figsize=(12, 6))
sns.boxplot(x="region", y="co2_emission", data=df)
plt.xticks(rotation=45)
plt.title("Розподіл викидів CO2 за регіонами")
plt.show()
```



Перевірка нормальності

```
In [15]: from scipy.stats import shapiro

for region, group in co2_emission_by_region:
    stat, p = shapiro(group["co2_emission"])
    print(f"{region}: p-value = {p}")
```

East Asia & Pacific: p-value = 3.9250569772172254e-12
Europe & Central Asia: p-value = 8.532206356599176e-13
Latin America & Caribbean: p-value = 8.0228733839871e-11
Middle East & North Africa: p-value = 1.0810064373215058e-05
North America: p-value = 0.17751878061974782
South Asia: p-value = 4.837926661431852e-06
Sub-Saharan Africa: p-value = 1.3856710673018501e-14

Перевірка гомогенності дисперсії

```
In [16]: from scipy.stats import levene

stat, p = levene(*[group["co2_emission"] for _, group in co2_emission_by_
print(f"Тест Левене: p-value = {p}")
```

Тест Левене: $p\text{-value} = 0.006575550992920958$

Аналіз результатів тестів Перевірка нормальності (Тест Шапіро-Уїлка):

Для більшості регіонів $p\text{-value} < 0.05$, що свідчить про нормальність, що не виконується. Лише для North America $p\text{-value} > 0.05$, що означає, що лише ця група може мати нормальний розподіл. Перевірка гомогенності дисперсій (Тест Левене):

$p\text{-value} = 0.0066 (< 0.05) \rightarrow$ дисперсії неоднорідні. Це означає, що класичний ANOVA не можна використовувати, оскільки порушується припущення про рівність дисперсій. Висновок: Оскільки:

Нормальність даних не виконується у більшості груп. Гомогенність дисперсій не виконується. Маємо застосувати непараметричний тест Краскела-Уоліса

Для отримання F-test score та P-value скористаюсь функцією `< kruskal` з модуля "stats" для непараметричного дисперсійного аналізу Краскела-Уоліса.

```
In [17]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
from scipy.stats import kruskal

stat, p_val = kruskal(*[group["co2_emission"] for _, group in co2_emission_by_region.groups()])
print(f"F-статистика: {stat}")
print(f"Тест Краскела-Уоліса: p-value = {p_val}")
```

F-статистика: 39.36585270526004

Тест Краскела-Уоліса: $p\text{-value} = 6.067666583117367e-07$

Результат із F-статистикою 39.37 та P-value 6.07e-07 показує, що існує статистично значуща різниця між досліджуваними групами. Але чи означає це, що досліджувані групи значуще відрізняються між собою?

Розглянемо їх окремо.

```
In [18]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання

region_list = co2_emission_by_region.groups.keys()

for region in region_list:
    print(f"{region}:")

    for region2 in region_list:
        if region == region2:
            continue

        stat, p_val = kruskal(
            co2_emission_by_region.get_group(region)["co2_emission"],
            co2_emission_by_region.get_group(region2)["co2_emission"]
        )

        print(f"p-value для регіонів {region} та {region2}: {p_val}")
```

East Asia & Pacific:

p-value для регіонів East Asia & Pacific та Europe & Central Asia: 0.04636
197871881841

p-value для регіонів East Asia & Pacific та Latin America & Caribbean: 0.9
735342225866741

p-value для регіонів East Asia & Pacific та Middle East & North Africa: 0.
01638310067292146

p-value для регіонів East Asia & Pacific та North America: 0.1817468642563
1176

p-value для регіонів East Asia & Pacific та South Asia: 0.3365857568465174

p-value для регіонів East Asia & Pacific та Sub-Saharan Africa: 0.40751008
53429865

Europe & Central Asia:

p-value для регіонів Europe & Central Asia та East Asia & Pacific: 0.04636
197871881841

p-value для регіонів Europe & Central Asia та Latin America & Caribbean:
0.0009992329177339616

p-value для регіонів Europe & Central Asia та Middle East & North Africa:
0.16977763338246388

p-value для регіонів Europe & Central Asia та North America: 0.29971278124
74501

p-value для регіонів Europe & Central Asia та South Asia: 0.71644616008949
22

p-value для регіонів Europe & Central Asia та Sub-Saharan Africa: 6.941200
757547244e-08

Latin America & Caribbean:

p-value для регіонів Latin America & Caribbean та East Asia & Pacific: 0.9
735342225866741

p-value для регіонів Latin America & Caribbean та Europe & Central Asia:
0.0009992329177339616

p-value для регіонів Latin America & Caribbean та Middle East & North Afri
ca: 0.00024547542807548754

p-value для регіонів Latin America & Caribbean та North America: 0.1496582
7504953202

p-value для регіонів Latin America & Caribbean та South Asia: 0.1335452358
026177

p-value для регіонів Latin America & Caribbean та Sub-Saharan Africa: 0.27
65070384366163

Middle East & North Africa:

p-value для регіонів Middle East & North Africa та East Asia & Pacific: 0.
01638310067292146

p-value для регіонів Middle East & North Africa та Europe & Central Asia:
0.16977763338246388

p-value для регіонів Middle East & North Africa та Latin America & Caribbe
an: 0.00024547542807548754

p-value для регіонів Middle East & North Africa та North America: 0.465208
8184521427

p-value для регіонів Middle East & North Africa та South Asia: 0.203597381
0264136

p-value для регіонів Middle East & North Africa та Sub-Saharan Africa: 3.1
435974548245275e-07

North America:

p-value для регіонів North America та East Asia & Pacific: 0.1817468642563
1176

p-value для регіонів North America та Europe & Central Asia: 0.29971278124
74501

p-value для регіонів North America та Latin America & Caribbean: 0.1496582
7504953202

p-value для регіонів North America та Middle East & North Africa: 0.465208
8184521427

p-value для регіонів North America та South Asia: 0.5402913746074198
 p-value для регіонів North America та Sub-Saharan Africa: 0.2001848041775763
 South Asia:
 p-value для регіонів South Asia та East Asia & Pacific: 0.3365857568465174
 p-value для регіонів South Asia та Europe & Central Asia: 0.7164461600894922
 p-value для регіонів South Asia та Latin America & Caribbean: 0.1335452358026177
 p-value для регіонів South Asia та Middle East & North Africa: 0.2035973810264136
 p-value для регіонів South Asia та North America: 0.5402913746074198
 p-value для регіонів South Asia та Sub-Saharan Africa: 0.023133627400309605
 Sub-Saharan Africa:
 p-value для регіонів Sub-Saharan Africa та East Asia & Pacific: 0.4075100853429865
 p-value для регіонів Sub-Saharan Africa та Europe & Central Asia: 6.941200757547244e-08
 p-value для регіонів Sub-Saharan Africa та Latin America & Caribbean: 0.2765070384366163
 p-value для регіонів Sub-Saharan Africa та Middle East & North Africa: 3.1435974548245275e-07
 p-value для регіонів Sub-Saharan Africa та North America: 0.2001848041775763
 p-value для регіонів Sub-Saharan Africa та South Asia: 0.023133627400309605

Висновки на основі тесту Краскела-Уоліса

1. Регіони зі значними відмінностями в середніх значеннях викидів CO₂:

- **East Asia & Pacific і Europe & Central Asia:** p-value = 0.046. Це свідчить про статистично значущу різницю між середніми значеннями викидів CO₂ в цих двох регіонах.
- **Europe & Central Asia і Latin America & Caribbean:** p-value = 0.000999. Різниця є статистично значущою.
- **Latin America & Caribbean і Middle East & North Africa:** p-value = 0.000245. Це вказує на значущу різницю між цими двома регіонами.
- **Sub-Saharan Africa та Europe & Central Asia:** p-value = 6.94e-08. Це показує, що є значущі відмінності між цими двома регіонами за викидами CO₂.

2. Регіони, де відмінностей у середніх значеннях викидів CO₂ немає:

- **East Asia & Pacific і Latin America & Caribbean:** p-value = 0.973. Різниця не є статистично значущою.
- **North America та South Asia:** p-value = 0.540. Відмінності між цими регіонами незначущі.

- **Middle East & North Africa і North America:** p-value = 0.465. Відмінності також не є статистично значущими.

Додаткове завдання:

Дайте відповіді на питання

1. По результатам дисперсійного аналізу для кількості викидів CO2 по регіонам, вкажіть пару регіонів, що відрізняються найсильніше.
2. Створіть якісну ознаку 'Rich country', згрупувавши дані 'GDP per capita' в кілька категорій (багаті-бідні країни, 3-5 категорій). Побудуйте діаграму розмаху для 'CO2 emission' по категоріям 'Rich country'. Візуально оцініть наявність зв'язку між цими ознаками.
3. Виконайте дисперсійний аналіз для 'CO2 emission', згрупувавши дані по категоріям 'Rich country'.

► Натисніть тут, щоб побачити підказку

```
In [19]: # Напишіть ваш код нижче та натисніть Shift+Enter для виконання
regions_result = [float('-inf'), None, None, None] # [F-stat, region1, region2, p]
group_names = list(co2_emission_by_region.groups.keys())

for i1, (region1, group1) in enumerate(co2_emission_by_region):
    for i2, (region2, group2) in enumerate(co2_emission_by_region):
        if i1 >= i2:
            continue
        f, p = stats.f_oneway(group1['co2_emission'], group2['co2_emission'])
        if f > regions_result[0] and p < 0.05:
            regions_result = [f, region1, region2, p]

# Регіони, що відрізняються найсильніше
r1 = regions_result[1]
r2 = regions_result[2]
f = regions_result[0]
p = regions_result[3]
print(f'Пара регіонів, що відрізняються найсильніше: {r1} та {r2}\nF={f} P={p}')
```

Пара регіонів, що відрізняються найсильніше: North America та Sub-Saharan Africa

F=29.889184991922967 P=1.5319132629213808e-06


```
In [20]: def categorize_gdp(gdp):
    if gdp < 1_000_000_000:
        return 'Poor'
    if gdp < 5_000_000_000:
        return 'Medium'
    return 'Rich'

df['rich_country'] = df['gdp_per_capita'].apply(categorize_gdp)

# Діаграма розмаху для 'CO2 emission' по категоріям 'Rich country'
```

```
plt.figure(figsize=(10, 5))
sns.boxplot(x='rich_country', y='co2_emission', data=df)
plt.title('CO2 Emission by Rich Country Categories')
plt.show()

print("Кількість викидів вуглекислого газу не має лінійного зв'язку з тим
```



Кількість викидів вуглекислого газу не має лінійного зв'язку з тим, наскільки багата країна

```
In [21]: grouped_df = df[['rich_country', 'co2_emission']].groupby(['rich_country'])
group_names = grouped_df['rich_country'].unique()

groups = [grouped_df.get_group((group[0],))['co2_emission'] for group in

f_val, p_val = stats.f_oneway(*groups)
print("ANOVA results: F =", f_val, ", P =", p_val)

for i, group in enumerate(groups):
    print(f'{group_names.iloc[i][0]}:\n' + f'{stats.shapiro(group)}')

print(stats.kruskal(*groups))
```

ANOVA results: F = 2.50678405901519 , P = 0.08406368117095847

Medium:

ShapiroResult(statistic=np.float64(0.36180357045389644), pvalue=np.float64(1.3678834572539401e-21))

Poor:

ShapiroResult(statistic=np.float64(0.6596769025781342), pvalue=np.float64(4.18209289184713e-05))

Rich:

ShapiroResult(statistic=np.float64(0.2566824101565216), pvalue=np.float64(3.5170662028047138e-15))

KruskalResult(statistic=np.float64(2.00671325153792), pvalue=np.float64(0.36664667767964293))

Виконав студент групи ІП-33
Соколов Олександр

